



National Technical University of Athens
School of Electrical and Computer Engineering

Division of Signals, Control and Robotics
Computer Vision and Signal Processing Lab

Initialization and Optimization of Neural Networks with Ranking Layers

DIPLOMA THESIS

of

Iason Kalogiannis

Supervisor: Petros Maragos
Professor Emeritus, NTUA

Athens, July 2026



National Technical University of Athens

School of Electrical and Computer Engineering

Division of Signals, Control and Robotics

Computer Vision and Signal Processing Lab

Initialization and Optimization of Neural Networks with Ranking Layers

DIPLOMA THESIS

of

Iason Kalogiannis

Supervisor: Petros Maragos
Professor Emeritus, NTUA

Approved by the three-member committee on July 21, 2026.

.....
Petros Maragos
Professor Emeritus, NTUA

.....
Athanasios Rontogiannis
Associate Professor, NTUA

.....
Gerasimos Potamianos
Associate Professor, UTH

Athens, July 2026

.....
Iason Kalogiannis
Graduate of Electrical and Computer Engineering,
NTUA

Copyright © – All rights reserved Iason Kalogiannis, 2026.

It is prohibited to copy, store and distribute this work, in whole or in part, for commercial purposes. Reproduction, storage and distribution for a non-profit, educational or research nature are permitted, provided the source of origin is indicated and the present message maintained. Enquiries regarding use for profit should be directed to the author.

The views and conclusions contained in this document are those of the author and should not be construed as representing the official positions of the National Technical University of Athens.

Περίληψη

Η παρούσα διπλωματική εργασία μελετά το morphological/ranking/linear (MRL) δίκτυο που εισήγαγαν οι Pessoa και Μαραγκός, ένα μορφολογικό νευρωνικό δίκτυο στο οποίο κάθε κόμβος είναι κυρτός συνδυασμός του τυπικού γραμμικού κόμβου και ενός ranking κόμβου, ο οποίος επιστρέφει το r -οστό μικρότερο στοιχείο του διανύσματος εισόδου. Λόγω της μη διαφορισιμότητας της ranking συνάρτησης, η εκπαίδευση των MRL δικτύων γινόταν αρχικά με heuristic gradient υπολογισμούς. Στο πρώτο μέρος της εργασίας, εκμεταλλευόμαστε το γεγονός πως η ranking συνάρτηση είναι τοπικά Lipschitz συνεχής, επομένως ορίζεται το υποδιαφορικό (subdifferential) Clarke της, και διατυπώνουμε μία μαθηματικά αυστηρή μη λεία εκδοχή της οπισθοδιάδοσης (backpropagation) για τα MRL δίκτυα. Στο δεύτερο και κύριο μέρος, αναλύουμε τη διάδοση των forward και backward σημάτων σε βαθιά MRL δίκτυα κατά την αρχικοποίηση, επεκτείνοντας τις μέσου-πεδίου (mean-field) αναλύσεις των τυπικών feedforward δικτύων. Η κύρια δυσκολία έγκειται στο ότι η πράξη του ranking εισάγει εξαρτήσεις στις συντεταγμένες της εισόδου της, κάτι το οποίο καθιστά δύσκολη την εκτίμηση των στατιστικών δεύτερης ροπής του ranking κλάδου. Δείχνουμε πως παρακάμπτεται αυτό, αναλύοντας τα MRL δίκτυα σε ένα γραμμικό καθεστώς. Αξιοσημείωτο είναι ότι, σε αντίθεση με τα τυπικά feedforward δίκτυα, οι forward και backward κρίσιμότητες (criticalities) στα MRL δίκτυα δεν συμπίπτουν, καθώς η συνεισφορά του ranking κλάδου επηρεάζει το backward pass. Μια καλή αρχικοποίηση για ένα βαθύ MRL δίκτυο επομένως απαιτεί ισορροπία μεταξύ δύο διαφορετικών κρίσιμων σημείων. Πειράματα πάνω στο MNIST συμφωνούν με την ανάλυσή μας, συγκεκριμένα, καθώς το βάθος αυξάνεται, η εκπαιδευσιμη (trainable) περιοχή στενεύει προς τη ζώνη μεταξύ των δύο κρίσιμων αρχικοποιήσεων.

Λέξεις-κλειδιά: Νευρωνικά δίκτυα, μορφολογικά νευρωνικά δίκτυα, ranking επίπεδα, εκπαιδευσιμότητα, διατεταγμένες στατιστικές, ανάλυση κατά την αρχικοποίηση, ανάλυση μέσου πεδίου, διάδοση σήματος, μη λεία βελτιστοποίηση, βαθιά μάθηση

Abstract

This thesis studies the morphological/ranking/linear (MRL) network introduced by Pessoa and Maragos, a morphological neural network in which each node is a convex combination of the standard linear node and a ranking node which returns the r -th smallest entry of the input vector. Owing to the nondifferentiability of the ranking function, the training of MRL networks was originally performed with heuristic gradient computations. In the first part of this thesis, we leverage the fact that the ranking function is locally Lipschitz continuous, hence admits a Clarke subdifferential, and derive a rigorous nonsmooth backpropagation of MRL networks. In the second and main part, we analyze forward and backward signal propagations in deep MRL networks at initialization by extending mean-field analyses of standard feedforward networks. The main difficulty lies in the coupling of input coordinates by the ranking operation, which makes tracking the second moment statistics of the ranking branch difficult. We show how to sidestep this by analyzing MRL networks at a *linear* regime. Notably, unlike in standard feedforward networks, forward and backward criticalities in MRL networks do not coincide, as the ranking branch's contribution affects the backward pass. A good initialization for a deep MRL network is therefore a balance between two distinct critical points. Experiments on MNIST support our analysis, namely, as depth increases, the trainable region narrows toward the band between the two critical initializations.

Keywords: neural networks, morphological neural networks, ranking layers, trainability, order statistic, at initialization analysis, mean field analysis, signal propagation, nonsmooth optimization, deep learning

Ευχαριστίες

Αρχικά, οφείλω να ευχαριστήσω θερμά τον επιβλέποντα καθηγητή της εργασίας, κ. Πέτρο Μαραγκό, για την εμπιστοσύνη που μου έδειξε, τόσο με την ανάθεσή της όσο και καθ' όλη τη διάρκειά της. Το μάθημά του, Όραση Υπολογιστών, ήταν κομβικής σημασίας για εμένα και συνεχίζει μέχρι και σήμερα να είναι το αγαπημένο μου μάθημα. Μπορώ να πω με βεβαιότητα ότι οι διαλέξεις του υπήρξαν για μένα πηγή έμπνευσης και μου έκαναν σαφές ότι θέλω να ακολουθήσω την επιστημονική έρευνα. Επιπλέον, ένα μεγάλο ευχαριστώ οφείλω στον διδάκτορα, πλέον, Νίκο Τσιλιβή, ο οποίος με μύησε στον κόσμο της Βαθιάς Μάθησης και της έρευνας γενικότερα. Τον ευχαριστώ για την ανιδιοτέλεια με την οποία μου προσέφερε τις γνώσεις του, τη βοήθειά του, την υποστήριξή του και γενικότερα την καθοδήγησή του. Εύχομαι η συνεργασία μας να συνεχιστεί και στο μέλλον. Ειδική μνεία οφείλω στον φίλο και συμφοιτητή μου, Γιώργο Απαλό, χάρη στη βοήθεια του οποίου η δυσκολία της σχολής κατέστη περατή.

Η παράγραφος αυτή θα ήταν λειψή εάν δεν ευχαριστούσα τους γονείς μου — στους οποίους και αφιερώνω την εργασία αυτή — καθώς και τα αδέρφια μου, τον Φοίβο, τη Δέσποινα και τον Βασίλη, για όλα τα χρόνια στήριξης και αγάπης. Τέλος, θέλω να ευχαριστήσω τους φίλους μου, τον Αντρέα, τον Βασίλη, τη Γιούλη, τον Γιώργο Θ., τον Λουκά, τον Μάρκο, τον Ματέο και τη Χαρά, για όλες τις φορές που μου σταθήκανε.

Contents

Περίληψη	5
Abstract	7
Ευχαριστίες	9
Contents	11
List of Figures	13
Εκτενής ελληνική περίληψη	14
Εισαγωγή	14
Το MRL δίκτυο	17
Μη λεία οπισθοδιάδοση για τα δίκτυα MRL	19
Ανάλυση μέσου-πεδίου των MRL networks κατά την αρχικοποίηση	24
Εκπαίδευση MRL δικτύων: πειράματα	32
Συμπεράσματα & Μελλοντικές επεκτάσεις	34
1 Introduction	36
1.1 Introduction and motivation	36
1.2 Neural networks	36
1.3 Morphological neural networks	37
2 The MRL network	39
2.1 The ranking function	39
2.2 Architecture of the MRL network	39
3 Nonsmooth backpropagation for MRL networks	41
3.1 Subdifferential of the ranking function	41
3.1.1 The ranking function as a difference of convex functions	41
3.1.2 Clarke subdifferential of the ranking function	42
3.2 Clarke's chain rule	42
3.3 Nonsmooth backpropagation	42
3.3.1 Helper mappings	42
3.3.2 Error signal $\delta_i^{(l)}$	43
3.3.3 Parameter subgradients	43
3.3.4 Backward error recursion	44
4 Mean field analysis of MRL networks at initialization	46
4.1 Pure ranking networks as a preliminary analysis	47
4.1.1 Model definition and assumptions	47
4.1.2 Mean and variance of the pure-ranking network	47
4.1.3 Two-input covariance and correlation of the pure-ranking branch	51
4.2 Hybrid MRL neural networks	55
4.2.1 Model definition	55
4.2.2 Mean field approximation	56
4.2.3 Mean and variance	56

4.2.4	Two-input covariance and correlation	59
4.2.5	Forward depth scale	61
4.2.6	Backward depth scale	65
5	Training MRL networks: experiments	67
6	Conclusions & Future work	69
6.1	Conclusions	69
6.2	Future work	70
A	Preliminary Theory	71
A.1	Elements of convex analysis	71
A.1.1	Convex sets and convex hulls	71
A.1.2	Convex functions	71
A.1.3	Convex subgradients and subdifferentials	72
A.1.4	Lipschitz and locally Lipschitz functions	72
A.1.5	Clarke subdifferential	73
A.2	Elements of asymptotic statistics	73
A.2.1	Convergence in probability and convergence in distribution	73
A.2.2	o_p and O_p notation	74
A.2.3	Useful convergence results	74
A.2.4	Empirical distribution function, order statistics and quantiles	75
A.2.5	Bahadur representation	76
B	Auxiliary proofs and derivations for Chapter 3	77
B.1	Derivation of the error signal $\delta_i^{(l)}$	77
B.2	Derivation of parameter subgradients	78
B.3	Upper estimate of $\partial_c E_l(\mathbf{y}^{(l)})$	79
B.4	Derivation of $\partial_c h_{\boldsymbol{\theta}_i^{(l+1)}}(\mathbf{y}^{(l)})$	80
C	Auxiliary proofs and derivations for Chapter 4	81
C.1	Rank parametrization and ranking-input distributions	81
C.1.1	Order of $r_i^{(l)}/N_{l-1}$ convergence	81
C.1.2	Marginal distribution of the ranking input $y_j^{(l-1)} + A_{ij}^{(l)}$	82
C.1.3	Density of the ranking input $y_j^{(l-1)} + A_{ij}^{(l)}$	82
C.2	Pure ranking asymptotics beyond the first layer	83
C.2.1	Vanishing threshold covariance	83
C.2.2	Convergence of the empirical cdf $\hat{F}_N$ to the marginal cdf F_N	83
C.2.3	Convergence of the marginal cdf F_N to the limiting marginal cdf F	85
C.2.4	Order of the ranking preactivation variance $\text{Var}(\alpha_i^{(l)})$	85
C.3	Two-input ranking Covariance $\text{Cov}(\alpha_{i;a}^{(l)}, \alpha_{i;b}^{(l)})$	86
C.3.1	Distribution of the joint ranking input $(y_{j;a}^{(l-1)} + A_{ij}^{(l)}, y_{j;b}^{(l-1)} + A_{ij}^{(l)})$	86
C.3.2	Order of the two-input ranking covariance $\text{Cov}(\alpha_{i;a}^{(l)}, \alpha_{i;b}^{(l)})$	87
C.4	Hybrid MRL derivations	89
C.4.1	MRL preactivation mean $\mathbb{E}[z_i^{(l)}]$ derivation	89
C.4.2	MRL preactivation variance $\text{Var}(z_i^{(l)})$ derivation	89
C.4.3	Vanishing threshold covariance for MRL layers	90
C.4.4	Convergence of the marginal cdf F_N to the limiting marginal cdf F (MRL)	91
C.4.5	MRL preactivation two-input covariance $\text{Cov}(z_{i;a}^{(l)}, z_{i;b}^{(l)})$ derivation	91
C.5	Signal propagation derivations	93
C.5.1	Gaussian ansatz versions of the cdf's and densities	93
C.5.2	Forward recurrence relations derivations	94
C.5.3	Backward recurrence relations derivations	96
	Bibliography	100

List of Figures

2.1	Structure of the l -th layer of the MRL network.	40
4.1	Scaled empirical variance $N\widehat{\text{Var}}(\alpha_i^{(l)})$ for the pure ranking network.	51
4.2	Scaled empirical covariance $N\widehat{\text{Cov}}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)})$ for the pure ranking network.	54
4.3	Mean-field criticality in MRL networks	62
4.4	Second moment and correlation tracking for MRL networks.	63
4.5	Experimental validation of the backward gradient propagation theory in randomly initialized MRL networks.	66
5.1	Mean MNIST training accuracy of MRL networks as a function of depth L and initial weight variance.	67
5.2	Mean MNIST testing accuracy of MRL networks as a function of depth L and initial weight variance.	68

Εκτενής ελληνική περίληψη

Κεφάλαιο 1

Εισαγωγή

Η παρούσα διπλωματική εργασία μελετά τα morphological/ranking/linear δίκτυα, εν συντομία MRL, που εισήγαγαν οι Pessoa και Μαραγκός [1]. Ανήκουν στην κλάση των μορφολογικών νευρωνικών δικτύων. Συγκεκριμένα, κάθε MRL κόμβος είναι κυρτός συνδυασμός ενός γραμμικού κόμβου, και ενός ranking κόμβου. Ο ranking κόμβος αποτελεί γενίκευση του κλασικού μορφολογικού κόμβου [2]. Εισήχθη από τους Pessoa και Μαραγκό στο [3] και επιστρέφει το r -οστό μικρότερο στοιχείο του διανύσματος εισόδου μετατοπισμένου κατά ένα ranking bias.

Εν γένει, η ranking συνάρτηση είναι μη διαφορίσιμη και γι' αυτό η εκπαίδευση των MRL δικτύων γινόταν αρχικά με heuristic gradient υπολογισμούς. Στο πρώτο μέρος της εργασίας αυτής, εκμεταλλευόμαστε το γεγονός πως η ranking συνάρτηση είναι τοπικά Lipschitz συνεχής, άρα διαθέτει Clarke υποδιαφορικό (subdifferential), και αποκτούμε μία μαθηματικά αυστηρή μη λεία (nonsmooth) εκδοχή του backpropagation για το MRL δίκτυο.

Στο δεύτερο και κύριο μέρος της εργασίας, αναλύουμε πώς διαδίδονται τα forward και τα backward σήματα μέσα από τα νευρωνικά επίπεδα σε τυχαία αρχικοποιημένα βαθιά MRL δίκτυα, επεκτείνοντας τη mean field ανάλυση που ανέπτυξαν οι Schoenholz κ.ά. στο *Deep Information Propagation* [4] για τα fully connected δίκτυα. Η κύρια δυσκολία έγκειται στο ότι η πράξη του ranking εισάγει εξαρτήσεις στις συντεταγμένες της εισόδου της, κάτι το οποίο καθιστά δύσκολη την εκτίμηση των στατιστικών δεύτερης ροπής του ranking κλαδιού. Παρακάμπτουμε την εκτίμηση αναλύοντας τα MRL δίκτυα σε ένα καθεστώς στο οποίο το γραμμικό κλαδί κυριαρχεί στις στατιστικές αυτές. Αξιοσημείωτο είναι ότι, σε αντίθεση με τα τυπικά feedforward δίκτυα, βρίσκουμε πως οι forward και backward χρισιμότητες στα MRL δίκτυα δεν συμπίπτουν, οπότε μια καλή αρχικοποίηση για ένα βαθύ MRL δίκτυο απαιτεί μία ισορροπία μεταξύ δύο διαφορετικών χρίσιμων σημείων.

Συνοψίζοντας, προσπαθούμε να απαντήσουμε στο ερώτημα «Πώς πρέπει να αρχικοποιήσουμε τα βαθιά MRL δίκτυα ώστε να παραμένουν εκπαιδύσιμα;».

Νευρωνικά δίκτυα

Το 1943 οι McCulloch και Pitts δημοσίευσαν το *A Logical Calculus of the Ideas Immanent in Nervous Activity* [5]. Σε αυτή την εργασία εισήχθη το πρώτο μαθηματικό μοντέλο ενός νευρωνικού δικτύου, ο “νευρώνας McCulloch-Pitts”. Συγκεκριμένα, η εργασία αυτή εισήγαγε τα νευρωνικά δίκτυα ως υπολογιστικό μοντέλο. Το 1958 ο Rosenblatt δημοσίευσε το *The Perceptron: a Probabilistic Model for Information Storage and Organization in the Brain* [6], στο οποίο τα νευρωνικά δίκτυα εισήχθησαν ως μοντέλο μάθησης, αν και δεν εκπαιδευόνταν με το learning που βασίζεται στο gradient όπως σήμερα. Αργότερα, το 1969, οι Minsky και Papert, στο βιβλίο τους *Perceptrons* [7], δείχναν τους περιορισμούς του perceptron μοντέλου ενός επιπέδου (συγκεκριμένα, μεταξύ άλλων, ότι δεν μπορούσε να υπολογίσει την πράξη XOR) και τόνισαν ότι μέχρι τότε δεν υπήρχε ένας αξιόπιστος αλγόριθμος για την εκπαίδευση της πολυεπίπεδης εκδοχής του. Γράφουν χαρακτηριστικά “*There is no reason to suppose that any of these virtues¹ carry over to the many-layered version*”. Αυτό προκάλεσε έναν προβληματισμό γύρω από τα νευρωνικά δίκτυα και συνέβαλε

¹Εδώ, οι Minsky και Papert αναφέρονται στις αρετές του perceptron ενός επιπέδου.

στη μείωση της έρευνας τους, περίπου από το 1969 έως το 1982. Έπειτα, το ενδιαφέρον για τα νευρωνικά δίκτυα αναζωογονήθηκε χάρη στην ευρεία διάδοση του backpropagation με την εργασία των Rumelhart, Hinton κ.ά. του 1986 *Learning Representations by Back-Propagating Errors* [8]. Λίγα χρόνια αργότερα, τα επιτυχή αποτελέσματα των LeCun κ.ά. [9] στην εκπαίδευση νευρωνικών δικτύων πολλαπλών επιπέδων για την αναγνώριση χειρόγραφων ταχυδρομικών κωδικών μέσω backpropagation βοήθησαν να καθιερωθεί το backpropagation ως η βασική μέθοδος εκπαίδευσης πολυεπίπεδων νευρωνικών δικτύων.

Μια σημαντική στροφή έλαβε χώρα το 2012, με το *ImageNet Classification with Deep Convolutional Neural Networks* των Krizhevsky κ.ά. [10]. Σε αυτή την εργασία εκπαίδευσαν ένα βαθύ και μεγάλο συνελικτικό δίκτυο στο ImageNet και αυτό απέδωσε σε μεγάλο βαθμό καλύτερα από τις τότε state-of-the-art μεθόδους υπολογιστικής όρασης. Αυτή η αποτελεσματικότητα, μεταξύ άλλων, των βαθιών δικτύων έθεσε φυσικά το ερώτημα του γιατί είναι χρήσιμο το βάθος. Στην εργασία του *Benefits of depth in neural networks*, ο Telgarsky [11] έδειξε ότι τα βαθιά νευρωνικά δίκτυα μπορούν να προσεγγίσουν (ορισμένες) συναρτήσεις με εκθετικά λιγότερους νευρώνες από όσους χρειάζονται τα ρηχά δίκτυα.

Καθώς τα σύγχρονα νευρωνικά δίκτυα γινόντουσαν όλο και μεγαλύτερα, ήταν φυσικό πλέον να μελετηθούν τα όρια στα οποία αφήνουμε το πλάτος ή το βάθος ενός νευρωνικού δικτύου να τείνει στο άπειρο. Ένα από τα πρώτα και σημαντικά παραδείγματα αυτής της ανάλυσης και της δύναμης της ήταν η εργασία του Neal στο *Priors for Infinite Networks* [12], όπου έδειξε ότι υπό κατάλληλες εκ των προτέρων κατανομές για τα βάρη του δικτύου, καθώς το πλάτος τείνει στο άπειρο, οι έξοδοι του δικτύου συγκλίνουν σε ένα Gaussian process. Αυτό ήταν ένα απτό παράδειγμα του πώς πολύ μεγάλα δίκτυα μπορούν να περιγραφούν, στο όριο άπειρου πλάτους, από απλούστερα μαθηματικά αντικείμενα.

Η εργασία του Neal έδειξε ότι το όριο άπειρου πλάτους μπορούσε να χρησιμοποιηθεί για τη μελέτη δικτύων στην αρχικοποίηση. Μεταγενέστερες εργασίες έδειξαν ότι η λήψη ενός ορίου άπειρου πλάτους ή βάθους μπορεί επίσης να χρησιμοποιηθεί για τη μελέτη της εκπαίδευσης ενός δικτύου. Συγκεκριμένα, για το πρώτο, στο *Neural Tangent Kernel: Convergence and Generalization in Neural Networks* [13], οι Jacot κ.ά. εφάρμοσαν την ανάλυση άπειρου πλάτους για να μελετήσουν τη δυναμική εκπαίδευσης πολύ μεγάλων δικτύων. Για το δεύτερο, ο Jacot στο *Implicit Bias of Large Depth Networks: a Notion of Rank for Nonlinear Functions* [14], χρησιμοποίησε το όριο άπειρου βάθους για να μελετήσει το *implicit bias* βαθιών δικτύων, δηλαδή, να μελετήσει γιατί, κατά την εκπαίδευση, τα βαθιά ομογενή δίκτυα τείνουν να “προτιμούν” ορισμένες συναρτήσεις για το fitting στα δεδομένα εκπαίδευσης.

Την ίδια γενικότερη φιλοσοφία, δηλαδή τη χρήση του ορίου άπειρου πλάτους/βάθους για να αναδειχθούν ιδιότητες που είναι δύσκολο να φανούν σε πεπερασμένα δίκτυα, ακολουθούμε στην παρούσα διπλωματική εργασία για να μελετήσουμε τα μορφολογικά νευρωνικά δίκτυα, μια ειδική κλάση δικτύων που θα εισάγουμε στην επόμενη ενότητα. Συγκεκριμένα, ακολουθώντας στενά την εργασία των Schoenholz κ.ά. στο [4], μελετάμε τη διάδοση σημάτων και των gradients σε τυχαία αρχικοποιημένα βαθιά μορφολογικά δίκτυα και χρησιμοποιούμε προσεγγίσεις μέσου πεδίου και το όριο άπειρου πλάτους για να προσδιορίσουμε αρχικοποιήσεις που βελτιώνουν την εκπαιδευσιμότητα.

Μορφολογικά νευρωνικά δίκτυα

Μέχρι τώρα, τα νευρωνικά δίκτυα που συζητήθηκαν παραπάνω μοιράζονται λίγο πολύ το κοινό αρχιτεκτονικό χαρακτηριστικό του γραμμικού νευρωνικού κόμβου, δηλαδή του γραμμικού κόμβου:

$$z_i = \sum_j W_{ij} y_j + b_i$$

ο οποίος έπεται από μια μη γραμμική συνάρτηση ενεργοποίησης f , όπως τη σιγμοειδή ή τη rectified linear unit, κοινώς γνωστή ως ReLU. Οι Davidson και Hummer [2] το 1993, εμπνευσμένοι από την αποτελεσματικότητα της μαθηματικής μορφολογίας στην επεξεργασία εικόνων, πρότειναν την αντικατάσταση του τυπικού γραμμικού κόμβου με τον μορφολογικό κόμβο, δηλαδή:

$$z_i = \bigvee_j (y_j + A_{ij}) \quad \text{ή} \quad z_i = \bigwedge_j (y_j + A_{ij})$$

όπου το $\bigvee$ δηλώνει τον dilation-based τελεστή και είναι το μέγιστο ως προς j , ενώ το $\bigwedge$ δηλώνει τον erosion-based τελεστή και είναι το ελάχιστο ως προς j . Έτσι, ο συνδυασμός εισόδου δεν είναι πλέον ένας γραμμικός συνδυασμός των βαρών και της εισόδου, αλλά ένα μέγιστο/ελάχιστο μετατοπισμένων συντεταγμένων εισόδου.

Επειδή τα dilation και erosion είναι από μόνα τους μη γραμμικές πράξεις, θεωρήθηκε ότι μια μη γραμμική συνάρτηση ενεργοποίησης δεν ήταν αυστηρά απαραίτητη.

Το 1998, οι Ritter κ.ά. στο *Morphological Associative Memories* [15] υποστήριξαν ότι αν η ισχύς του ηλεκτρικού δυναμικού είναι μια προσθετική διαδικασία και η μετασυναπτική μεμβράνη δέχεται μόνο σήματα ορισμένης μέγιστης ισχύος, τότε τα μορφολογικά δίκτυα έχουν ισχυρή βιολογική βάση.

Οι πράξεις dilation και erosion σχετίζονται άμεσα με τη ranking συνάρτηση, γνωστή και ως order statistic. Πράγματι, οι Maragos και Schafer [16] έδειξαν ότι ο ranking τελεστής, δηλαδή η επιλογή του k -οστού μεγαλύτερου/μικρότερου στοιχείου ενός διανύσματος, μπορεί να αναπαρασταθεί ως το μέγιστο erosions ή ισοδύναμα ως το ελάχιστο dilations. Με βάση τη σύνδεση αυτή, μπορούμε να περάσουμε από νευρώνες dilation/erosion στον γενικότερο ranking νευρώνα. Συγκεκριμένα, οι Maragos και Pessoa [3] εισήγαγαν το ranking νευρωνικό δίκτυο, του οποίου οι ranking κόμβοι ήταν της ακόλουθης μορφής:

$$z_i = R_r(y + a),$$

εδώ, το R_r δηλώνει την ranking συνάρτηση κατά την οποία επιστρέφεται το r -οστό μικρότερο στοιχείο του μετατοπισμένου κατά a διανύσματος y .

Η αρχιτεκτονική που μελετάται στην παρούσα διπλωματική εργασία είναι μια επέκταση αυτού του δικτύου. Συγκεκριμένα, οι Pessoa και Μαραγκός [1], λίγα χρόνια μετά την εισαγωγή των ranking δικτύων, εισήγαγαν το morphological/ranking/linear network, συντομογραφικά MRL, στο οποίο κάθε κόμβος είναι ένα άθροισμα ενός ranking κόμβου και του κλασικού γραμμικού κόμβου από το Perceptron. Συγκεκριμένα, ο MRL κόμβος είναι της ακόλουθης μορφής:

$$z_i = \lambda R_r(y + a) + (1 - \lambda) \left(\sum_j W_{ij} y_j + b_i \right)$$

Πρέπει να σημειωθεί ότι για $\lambda = 0$, ο MRL κόμβος ανάγεται στον γραμμικό κόμβο, και για $\lambda = 1$ ανάγεται στον ranking κόμβο. Όπως όλα τα μορφολογικά νευρωνικά δίκτυα, το MRL δίκτυο εμφανίζει δυσκολίες όσον αφορά την εκπαίδευση του, συγκεκριμένα τη μη διαφορισιμότητα των πράξεων μεγίστου, ελαχίστου και ranking όταν υπάρχει ισοπαλία μεταξύ στοιχείων του διανύσματος $y + a$. Στο [1], για να το αντιμετωπίσουν αυτό, οι Pessoa και Μαραγκός χρησιμοποίησαν ένα heuristic gradient για τη ranking συνάρτηση. Εδώ, θα επανεξετάσουμε την εκπαίδευση του MRL δικτύου με στόχο να δώσουμε μια αυστηρά μαθηματική διατύπωση μέσω υποπαραγώγων (subderivatives).

Τα μορφολογικά δίκτυα έχουν επίσης επανεξεταστεί και στο σύγχρονο πλαίσιο της βαθιάς μάθησης. Οι Δημητριάδης και Μαραγκός [17] μελέτησαν τα dense μορφολογικά δίκτυα και βρήκαν ότι μπορούν να κλαδευτούν (pruned) ιδιαίτερα καλά, με την επίδοσή τους να επιβιώνει ακόμη και όταν αφαιρείται ένα μεγάλο μέρος των παραμέτρων. Οι Φωτόπουλος και Μαραγκός [18] μελέτησαν βαθιές μορφολογικές αρχιτεκτονικές και έδειξαν ότι δίκτυα που αποτελούνται αποκλειστικά από κόμβους dilation/erosion χωρίς συνάρτηση ενεργοποίησης δεν είναι universal approximators, διαφεύδοντας τη μακροχρόνια πεποίθηση ότι τα μορφολογικά δίκτυα δεν απαιτούν συνάρτηση ενεργοποίησης. Επιπλέον, υποστήριξαν ότι η μη γραμμικότητα των μορφολογικών νευρώνων γενικά δεν είναι αρκετή, τα βαθιά MNNs χρειάζονται συνάρτηση ενεργοποίησης, residual connections και υβριδικά γραμμικά-μορφολογικά επίπεδα για να είναι εκφραστικά και εκπαιδύσιμα.

Κεφάλαιο 2

Το MRL δίκτυο

Η ranking συνάρτηση

Πριν ορίσουμε την αρχιτεκτονική του κύριου αντικειμένου της εργασίας, δηλαδή του δικτύου MRL, χρειάζεται πρώτα να ορίσουμε τη συνάρτηση ranking, ευρύτερα γνωστή ως order statistic. Θα εναλλάσσουμε ελεύθερα μεταξύ των δύο όρων.

Ορισμός (ranking function/order statistic). Έστω $t = (t_1, \dots, t_n) \in \mathbb{R}^n$ και r ακέραιος στο $\{1, \dots, n\}$. Υποθέτουμε ότι ταξινομούμε τα στοιχεία του διανύσματος t σε αύξουσα σειρά ως $t_{(1)} \leq \dots \leq t_{(n)}$. Η ranking συνάρτηση, ή το r -οστό order statistic, ορίζεται τότε ως:

$$R_r(t) := t_{(r)}.$$

Παράδειγμα. Έστω $t = (4, 1, 7, 1) \in \mathbb{R}^4$. Ταξινομώντας τα στοιχεία του σε αύξουσα σειρά προκύπτει

$$t_{(1)} = 1, \quad t_{(2)} = 1, \quad t_{(3)} = 4, \quad t_{(4)} = 7.$$

Τότε, το $R_1(t) = \min(t) = 1$ επιστρέφει το μικρότερο στοιχείο, το $R_4(t) = \max(t) = 7$ το μεγαλύτερο, και $R_3(t) = 4$. Σημειώνουμε ότι η τιμή 1 είναι τόσο η πρώτη όσο και η δεύτερη order statistic, οπότε η R_r επιστρέφει καλώς ορισμένη τιμή σε περίπτωση ισοπαλίας.

Αρχιτεκτονική του δικτύου MRL

Θεωρούμε το MRL δίκτυο που εισήγαγαν οι Pessoa και Maragos στο [1], ένα feedforward δίκτυο με L επίπεδα και πλάτη επιπέδων $N_0, \dots, N_L$.

Έστω $f : \mathbb{R} \rightarrow \mathbb{R}$ μία βαθμωτή συνάρτηση ενεργοποίησης, όπως η σιγμοειδής, η tanh και η ReLU. Τότε, για κάθε επίπεδο $l = 1, \dots, L$:

$$\mathbf{y}^{(l)} = \mathbf{F}^{(l)}(\mathbf{z}^{(l)}) = (f(z_1^{(l)}), \dots, f(z_{N_l}^{(l)}))^{\top}, \quad z_i^{(l)} = h(\mathbf{y}^{(l-1)}; \boldsymbol{\theta}_i^{(l)}), \quad i = 1, \dots, N_l,$$

όπου $\mathbf{y}^{(0)}$ είναι η είσοδος του δικτύου και $\mathbf{y}^{(L)}$ είναι η έξοδος του δικτύου.


Κάθε κόμβος είναι κυρτός συνδυασμός ενός γραμμικού μέρους και ενός ranking (μορφολογικού) μέρους

$$z_i^{(l)} = h(\mathbf{y}^{(l-1)}; \boldsymbol{\theta}_i^{(l)}) = \lambda_i^{(l)} \alpha_i^{(l)} + (1 - \lambda_i^{(l)}) \beta_i^{(l)},$$

όπου

$$\alpha_i^{(l)} = R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}), \quad \beta_i^{(l)} = (\mathbf{w}_i^{(l)})^{\top} \mathbf{y}^{(l-1)} + b_i^{(l)} = \sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)}.$$

Η $R_{r_i^{(l)}}$ είναι η ranking συνάρτηση, δηλαδή επιστρέφει το $r_i^{(l)}$ -οστό μικρότερο στοιχείο του διανύσματος $\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}$, το οποίο συμβολίζεται ως $(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)})_{(r_i^{(l)})}$ σύμφωνα με τον συμβολισμό που εισαγάγαμε νωρίτερα.



Σχήμα 1: το l -οστό επίπεδο του δικτύου MRL.

Οι παράμετροι είναι:

το ranking bias $\mathbf{a}_i^{(l)} \in \mathbb{R}^{N_{l-1}}$, όπου

$$\mathbf{a}_i^{(l)} := i\text{-οστή γραμμή του } A^{(l)}, \quad A^{(l)} \in \mathbb{R}^{N_l \times N_{l-1}}$$

τα γραμμικά βάρη $\mathbf{w}_i^{(l)} \in \mathbb{R}^{N_{l-1}}$, όπου:

$$\mathbf{w}_i^{(l)} := i\text{-οστή γραμμή του } W^{(l)}, \quad W^{(l)} \in \mathbb{R}^{N_l \times N_{l-1}}$$

το bias $b_i^{(l)} \in \mathbb{R}$, και το mixing coefficient $\lambda_i^{(l)} \in [0, 1]$.

Τα συλλέγουμε στο

$$\boldsymbol{\theta}_i^{(l)} = (\mathbf{a}_i^{(l)}, \rho_i^{(l)}, \mathbf{w}_i^{(l)}, b_i^{(l)}, \lambda_i^{(l)}),$$

όπου η ranking παράμετρος $r_i^{(l)} \in \{1, \dots, N_{l-1}\}$ δίνεται από το $\rho_i^{(l)} \in \mathbb{R}$ ως εξής:

$$r_i^{(l)} = \left\lfloor N_{l-1} - \frac{N_{l-1} - 1}{1 + \exp(-\rho_i^{(l)})} + \frac{1}{2} \right\rfloor.$$

Σε αντίθεση με τους Pessoa και Maragos [1], όπου το $r_i^{(l)}$ είναι εκπαιδύσιμη παράμετρος, εμείς το θεωρούμε σταθερό.

Κεφάλαιο 3

Μη λεία οπισθοδιάδοση για τα δίκτυα MRL

Η ranking συνάρτηση αποτελεί την κύρια πηγή μη λειότητας (nonsmoothness) στην αρχιτεκτονική MRL. Επομένως, πριν προχωρήσουμε στην ανάλυση του δικτύου, μελετάμε πρώτα τη συνάρτηση αυτή μόνη της. Συγκεκριμένα, θέλουμε να προσδιορίσουμε το υποδιαφορικό Clarke της, καθώς το αντικείμενο αυτό θα αντικαταστήσει αργότερα τη παράγωγο του ranking κλάδου στους τύπους της οπισθοδιάδοσης (backpropagation).

Η δυσκολία έγκειται στο ότι η ranking συνάρτηση R_r είναι διαφορίσιμη όταν υπάρχει μοναδική συντεταγμένη t_j τέτοια ώστε $t_j = t_{(r)}$. Όταν περισσότερες συντεταγμένες παίρνουν την τιμή $t_{(r)}$ η συνάρτηση γενικά παύει να είναι διαφορίσιμη. Το υποδιαφορικό Clarke χρησιμοποιείται για τον χειρισμό τέτοιων μη διαφορίσιμων πράξεων. Πρώτα εκφράζουμε τη ranking συνάρτηση ως διαφορά κυρτών συναρτήσεων για να δείξουμε ότι το υποδιαφορικό Clarke της υπάρχει και είναι καλώς ορισμένο (δηλαδή, ότι η ranking συνάρτηση είναι τοπικά Lipschitz συνεχές), και έπειτα εισάγουμε τον τύπο του Lewis [19] για το υποδιαφορικό Clarke της.

Υποδιαφορικό της ranking συνάρτησης

Η ranking συνάρτηση ως διαφορά κυρτών συναρτήσεων

Για κάθε ακέραιο $m \in \{0, 1, \dots, n\}$, ορίζουμε τη συνάρτηση

$$S_m(t) := \max_{\substack{I \subseteq \{1, \dots, n\} \\ |I|=m}} \sum_{i \in I} t_i,$$

με τη σύμβαση $S_0(t) := 0$. Παρατηρούμε ότι εκ κατασκευής,

$$S_m(t) = t_{(n-m+1)} + \dots + t_{(n)}.$$

και επομένως η ranking συνάρτηση μπορεί να εκφραστεί ως:

$$R_r(t) = S_{n-r+1}(t) - S_{n-r}(t).$$

Ιδιότητες της S_m

Η συνάρτηση S_m μπορεί επίσης να γραφεί σε συμπαγή μορφή με τη χρήση indicator διανυσμάτων. Συγκεκριμένα, έχουμε:

$$S_m(t) = \max_{\substack{I \subseteq \{1, \dots, n\} \\ |I|=m}} \langle \mathbf{1}_I, t \rangle, \quad \text{όπου} \quad (\mathbf{1}_I)_j = \begin{cases} 1, & j \in I, \\ 0, & j \notin I. \end{cases}$$

Η αναπαράσταση αυτή καθιστά σαφείς αρκετές χρήσιμες ιδιότητες:

- Κάθε επιμέρους συνάρτηση $t \mapsto \langle \mathbf{1}_I, t \rangle$ είναι αφινική (affine), άρα κυρτή.
- Η S_m είναι το μέγιστο αφινικών (άρα κυρτών) συναρτήσεων, οπότε είναι και η ίδια κυρτή.
- Αφού η S_m είναι κυρτή, έπεται ότι είναι τοπικά Lipschitz παντού στο εσωτερικό (interior) του πεδίου ορισμού της S_m .

Υποδιαφορικό Clarke της ranking συνάρτησης

Αφού δείξαμε ότι η R_r ισούται με τη διαφορά δύο τοπικά Lipschitz συναρτήσεων, είναι και η ίδια τοπικά Lipschitz. Ως εκ τούτου, το υποδιαφορικό Clarke της υπάρχει και είναι καλώς ορισμένο. Για το ακριβές υποδιαφορικό Clarke, ο τύπος του Lewis [19] για το order statistic μας δίνει

$$\partial_c R_r(t) = \text{co}\{e_j^\top : t_j = t_{(r)}\}.$$

Εδώ, το e_j συμβολίζει το j -οστό διάνυσμα βάσης.

Ο κανόνας αλυσίδας του Clarke

Έχοντας ορίσει τη ranking συνάρτηση, το υποδιαφορικό της και την αρχιτεκτονική του δικτύου MRL, χρησιμοποιώντας τον κανόνα (τους κανόνες) αλυσίδας του Clarke, τον οποίο θα παρουσιάσουμε αμέσως, μπορούμε να πάρουμε μία μη λεία εκδοχή του backpropagation για την εκπαίδευση του δικτύου.

Παρουσιάζουμε τώρα τον κανόνα (τους κανόνες) αλυσίδας του Clarke από το [20].

Θεώρημα (Κανόνας αλυσίδας του Clarke I, [20]). Έστω X χώρος Banach, $h = (h_1, \dots, h_n) : X \rightarrow \mathbb{R}^n$ με κάθε h_i Lipschitz κοντά στο $x \in X$, και έστω $g : \mathbb{R}^n \rightarrow \mathbb{R}$ Lipschitz κοντά στο $h(x)$. Θέτουμε $f = g \circ h$. Ταυτίζοντας τον $(\mathbb{R}^n)^*$ με τον $\mathbb{R}^n$, παίρνουμε κάθε $\alpha \in \partial g(h(x))$ ως $\alpha = (\alpha_1, \dots, \alpha_n)$. Τότε η f είναι Lipschitz κοντά στο x , και

$$\partial_c f(x) \subset \overline{\text{co}} \left\{ \sum_{i=1}^n \alpha_i \zeta_i : \zeta_i \in \partial_c h_i(x), \alpha \in \partial_c g(h(x)) \right\}.$$

Εδώ, το $\overline{\text{co}}$ συμβολίζει την κλειστή κυρτή θήκη.

Αφού βρισκόμαστε σε πεπερασμένης διάστασης Ευκλείδειο χώρο, κάθε συμπαγές σύνολο είναι και κλειστό. Το υποδιαφορικό Clarke των τοπικά Lipschitz συναρτήσεων είναι συμπαγές, επομένως, το σύνολο του οποίου παίρνουμε την κυρτή θήκη στον Κανόνα της αλυσίδας I είναι συμπαγές, ως συνεχής εικόνα πεπερασμένου γινομένου συμπαγών συνόλων. Άρα και η κυρτή θήκη του είναι συμπαγής, και συνεπώς κλειστή. Έτσι, από εδώ και πέρα μπορούμε να γράφουμε co αντί για $\overline{\text{co}}$.

Θεώρημα (Κανόνας αλυσίδας του Clarke II, [20]). Έστω F απεικόνιση από τον X σε έναν άλλο χώρο Banach Y , και έστω g πραγματική συνάρτηση επί του Y . Υποθέτουμε ότι η F είναι ανστηρά διαφορίσιμη στο x και ότι η g είναι Lipschitz κοντά στο $F(x)$. Τότε η $f = g \circ F$ είναι Lipschitz κοντά στο x , και ισχύει

$$\partial_c f(x) \subset [D_s F(x)]^* \partial_c g(F(x)).$$

Μη λείο backpropagation

Για την εκπαίδευση, θεωρούμε ένα επισημασμένο (labeled) παράδειγμα $(\mathbf{x}, \mathbf{d})$ με έξοδο δικτύου $\mathbf{y} = \mathbf{y}^L$, και την τετραγωνική συνάρτηση σφάλματος:

$$E := \|\mathbf{d} - \mathbf{y}\|_2^2 = \|\mathbf{e}\|_2^2 = \sum_{j=1}^{N_L} e_j^2.$$

όπου $\mathbf{e} := \mathbf{d} - \mathbf{y}$ είναι το διάνυσμα σφάλματος.

Βοηθητικές απεικονίσεις

Ορίζουμε τώρα τις ακόλουθες βοηθητικές απεικονίσεις που θα μας βοηθήσουν στην ανάλυσή μας:

$$\phi : \mathbb{R}^{N_L} \rightarrow \mathbb{R}, \quad \phi(\mathbf{u}) = \|\mathbf{d} - \mathbf{u}\|^2$$

Την preactivation απεικόνιση:

$$\mathbf{h}^{(l)} : \mathbb{R}^{N_{l-1}} \rightarrow \mathbb{R}^{N_l}, \quad \mathbf{h}^{(l)}(\mathbf{y}) = (h(\mathbf{y}; \boldsymbol{\theta}_1^{(l)}), \dots, h(\mathbf{y}; \boldsymbol{\theta}_{N_l}^{(l)}))^{\top},$$

όπου όλες οι παράμετροι του δικτύου $\boldsymbol{\theta}^{(l)}$ είναι σταθερές και η μεταβλητή είναι το ενεργοποιημένο διάνυσμα του προηγούμενου επιπέδου $\mathbf{y}^{(l-1)}$.

Την κατά συντεταγμένη απεικόνιση ενεργοποίησης του l -οστού επιπέδου.

$$\mathbf{F}^{(l)} : \mathbb{R}^{N_l} \rightarrow \mathbb{R}^{N_l}, \quad \mathbf{F}^{(l)}(\mathbf{z}) = (f(z_1), \dots, f(z_{N_l}))^{\top},$$

Ορίζουμε την απεικόνιση της προς τα κάτω διάδοσης (propagation) από το επίπεδο l στο επίπεδο εξόδου L :

$$\mathbf{T}_l : \mathbb{R}^{N_l} \rightarrow \mathbb{R}^{N_L} \quad \mathbf{T}_l = \mathbf{F}^{(L)} \circ \mathbf{h}^{(L)} \circ \mathbf{F}^{(L-1)} \circ \mathbf{h}^{(L-1)} \circ \dots \circ \mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)}.$$

Έπειτα, ορίζουμε

$$E_l : \mathbb{R}^{N_l} \rightarrow \mathbb{R}, \quad E_l(\mathbf{y}^{(l)}) = \phi(\mathbf{T}_l(\mathbf{y}^{(l)})).$$

Η απεικόνιση E_l μπορεί να διαβαστεί ως το σφάλμα εξόδου E ως συνάρτηση του διανύσματος ενεργοποίησης του l -οστού επιπέδου $\mathbf{y}^{(l)}$. Τέλος, για κάθε συντεταγμένη i , ορίζουμε τις απεικονίσεις:

$$\psi_i : \mathbb{R} \rightarrow \mathbb{R}, \quad \psi_i(t) := E_l(\mathbf{F}^{(l)}(z_1^{(l)}, \dots, z_{i-1}^{(l)}, t, z_{i+1}^{(l)}, \dots, z_{N_l}^{(l)})).$$

$$\mathbf{J}_i : \mathbb{R} \rightarrow \mathbb{R}^{N_l}, \quad \mathbf{J}_i(t) = \mathbf{z}^{(l)} + (t - z_i^{(l)})\mathbf{e}_i.$$

Σήμα σφάλματος $\delta_i^{(l)}$

Τώρα, θα διατυπώσουμε ένα μη λείο ανάλογο των backpropagation τύπων του [1]. Για κάθε παράμετρο $\theta \in \{\mathbf{w}_i^{(l)}, \mathbf{a}_i^{(l)}, b_i^{(l)}, \lambda_i^{(l)}\}$ θα πάρουμε το μη λείο ισοδύναμο της ταυτότητας του κανόνα αλυσίδας των παραγώγων:

$$\frac{\partial E}{\partial \theta} = \frac{\partial E}{\partial y_i^{(l)}} \frac{\partial y_i^{(l)}}{\partial z_i^{(l)}} \frac{\partial z_i^{(l)}}{\partial \theta}$$

Σημειώνουμε ότι στο μη λείο πλαίσιο μας, πρόκειται για άνω εγκλεισμό αντί για ισότητα.

Από τον κανόνα αλυσίδας του Clarke, επιλέγοντας

$$\sigma_i^{(l)} \in \partial_c f(z_i^{(l)}), \quad \mathbf{e}^{(l)} \in -\frac{1}{2} \partial_c E_l(\mathbf{y}^{(l)}),$$

και ορίζοντας

$$\delta_i^{(l)} := \sigma_i^{(l)} e_i^{(l)},$$

πάρνουμε το μη λείο ισοδύναμο του $\partial E / \partial y_i^{(l)} \cdot \partial y_i^{(l)} / \partial z_i^{(l)}$:

$$\partial_c \psi_i(z_i^{(l)}) \subset \text{co} \left\{ -2\delta_i^{(l)} : \sigma_i^{(l)} \in \partial_c f(z_i^{(l)}), \mathbf{e}^{(l)} \in -\frac{1}{2} \partial_c E_l(\mathbf{y}^{(l)}) \right\}.$$

Βλ. στο Παράρτημα B.1 για τις λεπτομέρειες.

Subgradients παραμέτρων

Τώρα, έχοντας το μη λείο ανάλογο του

$$\frac{\partial E}{\partial y_i^{(l)}} \frac{\partial y_i^{(l)}}{\partial z_i^{(l)}}$$

είμαστε σε θέση να πάρουμε το μη λείο ανάλογο του

$$\frac{\partial E}{\partial \theta} = \frac{\partial E}{\partial y_i^{(l)}} \frac{\partial y_i^{(l)}}{\partial z_i^{(l)}} \frac{\partial z_i^{(l)}}{\partial \theta}, \quad \theta \in \{\mathbf{w}_i^{(l)}, \mathbf{a}_i^{(l)}, b_i^{(l)}, \lambda_i^{(l)}\}$$

Για να το κάνουμε αυτό, θεωρούμε τις ακόλουθες τέσσερις βοηθητικές απεικονίσεις:

$$h_{\mathbf{w}_i^{(l)}} := h(\cdot; \mathbf{y}^{(l-1)}, \boldsymbol{\theta}_i^{(l)} / \{\mathbf{w}_i^{(l)}\}) : \mathbb{R}^{N_{l-1}} \rightarrow \mathbb{R}$$

$$h_{\mathbf{a}_i^{(l)}} := h(\cdot; \mathbf{y}^{(l-1)}, \boldsymbol{\theta}_i^{(l)} / \{\mathbf{a}_i^{(l)}\}) : \mathbb{R}^{N_{l-1}} \rightarrow \mathbb{R}$$

$$h_{b_i^{(l)}} := h(\cdot; \mathbf{y}^{(l-1)}, \boldsymbol{\theta}_i^{(l)} / \{b_i^{(l)}\}) : \mathbb{R} \rightarrow \mathbb{R}$$

$$h_{\lambda_i^{(l)}} := h(\cdot; \mathbf{y}^{(l-1)}, \boldsymbol{\theta}_i^{(l)} / \{\lambda_i^{(l)}\}) : \mathbb{R} \rightarrow \mathbb{R}.$$

Εφαρμόζουμε τον Κανόνα Αλυσίδας I του Clarke στην

$$g = E_l \circ \mathbf{F}^{(l)} \circ \mathbf{J}_i : \mathbb{R} \rightarrow \mathbb{R}$$

και με h την καθεμία από τις τέσσερις παραπάνω απεικονίσεις. Αυτές οι βοηθητικές απεικονίσεις h παραπάνω είναι το preactivation του νευρώνα i στο επίπεδο l ως συνάρτηση της παραμέτρου του δικτύου της επιλογής μας (αυτής ως προς την οποία παίρνουμε την “παράγωγο”), ενώ όλες οι υπόλοιπες παράμετροι και το διάνυσμα ενεργοποίησης του επιπέδου $l-1$, $\mathbf{y}^{(l-1)}$, θεωρούνται σταθερά.

Παίρνουμε τους εγκλεισμούς

$$\partial_c(g \circ h_\theta)(\theta) \subset \text{co}\{\alpha \zeta_\theta : \zeta_\theta \in \partial_c h_\theta(\theta), \alpha \in \partial_c g(h_\theta(\theta))\}, \quad \theta \in \{\mathbf{w}_i^{(l)}, \mathbf{a}_i^{(l)}, b_i^{(l)}, \lambda_i^{(l)}\}.$$

Αφού $h_\theta(\theta) = z_i^{(l)}$, η παραπάνω σχέση δίνει

$$\partial_c g(z_i^{(l)}) \subset \text{co}\{-2\delta_i^{(l)}\},$$

επομένως

$$\partial_c(g \circ h_\theta)(\theta) \subset \text{co}\{-2\delta_i^{(l)} \zeta_\theta : \zeta_\theta \in \partial_c h_\theta(\theta)\}.$$

Αυτό που μένει είναι να υπολογίσουμε τα υποδιαφορικά Clarke $\partial_c h_\theta(\theta)$ των βοηθητικών απεικονίσεων, δηλαδή το μη λείο ισοδύναμο των τοπικών παραγώγων². Από την υποεπνότητα B.2 στο Παράρτημα έχουμε:

$$\begin{aligned} \partial_c(g \circ h_{\mathbf{w}_i^{(l)}})(\mathbf{w}_i^{(l)}) &\subset \text{co}\{-2\delta_i^{(l)}(1 - \lambda_i^{(l)})(\mathbf{y}^{(l-1)})^\top\} \\ \partial_c(g \circ h_{\mathbf{a}_i^{(l)}})(\mathbf{a}_i^{(l)}) &\subset \text{co}\{-2\delta_i^{(l)}\lambda_i^{(l)}\zeta, \zeta \in \partial_c R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)})\} \\ \partial_c(g \circ h_{b_i^{(l)}})(b_i^{(l)}) &\subset \text{co}\{-2\delta_i^{(l)}(1 - \lambda_i^{(l)})\} \\ \partial_c(g \circ h_{\lambda_i^{(l)}})(\lambda_i^{(l)}) &\subset \text{co}\{-2\delta_i^{(l)}(\alpha_i^{(l)} - \beta_i^{(l)})\}, \end{aligned}$$

όπου, από την προηγούμενη υποεπνότητα:

$$\partial_c R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}) = \text{co}\{\mathbf{e}_k^\top : y_k^{(l-1)} + A_{ik}^{(l)} = (\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)})_{(r_i^{(l)})}\}.$$

Αναδρομή backward σφάλματος

Απομένει να προσδιορίσουμε ένα μέγεθος backward σφάλματος το οποίο, ιδανικά, θα ικανοποιούσε

$$\mathbf{e}^{(l)} \in -\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)}).$$

Ωστόσο, καθώς οι κανόνες αλυσίδας του Clarke που χρησιμοποιήθηκαν στην ανάλυσή μας δίνουν εν γένει εγκλεισμούς συνόλων και όχι ισότητες, δεν μπορούμε γενικά να υπολογίσουμε επακριβώς αυτό το υποδιαφορικό Clarke. Αντ’ αυτού, παίρνουμε μία άνω εκτίμηση του $-\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)})$ και τη χρησιμοποιούμε για να ορίσουμε την backward αναδρομή. Από το Παράρτημα B.3, έχουμε:

$$\partial_c E_l(\mathbf{y}^{(l)}) \subset \text{co}\left\{\sum_{j=1}^{N_{l+1}} -2\delta_j^{(l+1)} \mathbf{v}_j^{(l+1)} : \mathbf{e}^{(l+1)} \in -\frac{1}{2}\partial_c E_{l+1}(\mathbf{y}^{(l+1)}), \mathbf{v}_j^{(l+1)} \in \partial_c h_{\theta_j^{(l+1)}}(\mathbf{y}^{(l)}), \sigma_j^{(l+1)} \in \partial_c f(z_j^{(l+1)})\right\} \quad (1)$$

με (βλ. Παράρτημα, ενότητα B.4):

$$\partial_c h_{\theta_j^{(l+1)}}(\mathbf{y}^{(l)}) = \lambda_i^{(l+1)} \text{co}\left\{\mathbf{e}_j^\top : (\mathbf{y}^{(l)} + \mathbf{a}_i^{(l+1)})_j = (\mathbf{y}^{(l)} + \mathbf{a}_i^{(l+1)})_{(r_i^{(l+1)})}\right\} + (1 - \lambda_i^{(l+1)})(\mathbf{w}_i^{(l+1)})^\top$$

²Με το τοπικές παράγωγοι (local derivatives) συνήθως κανείς αναφέρεται στην παράγωγο των preactivations προς τις παραμέτρους του δικτύου.

Τονίζουμε ότι το σύνολο στο δεξί μέλος της (1) είναι άνω εκτίμηση του υποδιαφορικού Clarke. Επομένως, ένα αυθαίρετο στοιχείο επιλεγμένο από το σύνολο αυτό δεν είναι κατ' ανάγκη Clarke subgradient.

Έτσι, για κάθε $j = 1, \dots, N_{l+1}$, επιλέγουμε

$$\mathbf{c}_j^{(l+1)} \in \partial_c R_{r_j^{(l+1)}}(\mathbf{y}^{(l)} + \mathbf{a}_j^{(l+1)}).$$

Τότε

$$\mathbf{v}_j^{(l+1)} = \lambda_j^{(l+1)} \mathbf{c}_j^{(l+1)} + (1 - \lambda_j^{(l+1)}) (\mathbf{w}_j^{(l+1)})^\top \in \partial_c h_{\theta_j^{(l+1)}}(\mathbf{y}^{(l)}).$$

Επομένως, για την backward αναδρομή, έχοντας πλέον προσδιορίσει τα $\mathbf{v}_j^{(l+1)}$, επιλέγουμε το $\mathbf{e}^{(l)}$ από την άνω εκτίμηση της (1):

$$\mathbf{e}^{(l)} \in \text{co} \left\{ \sum_{j=1}^{N_{l+1}} \delta_j^{(l+1)} \left[\lambda_j^{(l+1)} \mathbf{c}_j^{(l+1)} + (1 - \lambda_j^{(l+1)}) (\mathbf{w}_j^{(l+1)})^\top \right] \right\}.$$

Ισοδύναμα, κατά συντεταγμένη,

$$e_i^{(l)} \in \text{co} \left\{ \sum_{j=1}^{N_{l+1}} \delta_j^{(l+1)} \left[\lambda_j^{(l+1)} c_{ji}^{(l+1)} + (1 - \lambda_j^{(l+1)}) W_{ji}^{(l+1)} \right] \right\}.$$

Για το επίπεδο εξόδου, έχουμε ότι

$$E_L(\mathbf{y}^{(L)}) = \|\mathbf{d} - \mathbf{y}^{(L)}\|^2,$$

άρα

$$\partial_c E_L(\mathbf{y}^{(L)}) = \{-2(\mathbf{d} - \mathbf{y}^{(L)})\}.$$

Έτσι, ξεκινώντας από

$$\mathbf{e}^{(L)} = \mathbf{d} - \mathbf{y}^{(L)},$$

παίρνουμε τα μεγέθη των κρυφών επιπέδων $\mathbf{e}^{(l)}$ με αναδρομή προς τα πίσω από τον παραπάνω εγκλεισμό. Στη συνέχεια, υπολογίζουμε τα $\delta_i^{(l)} = \sigma_i^{(l)} e_i^{(l)}$, με $\sigma_i^{(l)} \in \partial_c f(z_i^{(l)})$, που χρησιμοποιούνται για το update των παραμέτρων. Σημειώνουμε ότι τα αναδρομικά επιλεγμένα διανύσματα $\mathbf{e}^{(l)}$, και κατά συνέπεια οι προκύπτουσες κατευθύνσεις ενημέρωσης των παραμέτρων, δεν είναι εν γένει βέβαιο ότι θα αποτελούν στοιχεία των αντίστοιχων υποδιαφορικών Clarke, όπως σημειώσαμε παραπάνω.

Κεφάλαιο 4

Ανάλυση μέσου-πεδίου των MRL networks κατά την αρχικοποίηση

Έχοντας αποκτήσει μία μη-λεία εκδοχή του backpropagation για την εκπαίδευση του MRL δικτύου, φτάνουμε τώρα στην κύρια συνεισφορά της εργασίας αυτής, δηλαδή, την ανάλυση μέσου πεδίου (mean field) του MRL δικτύου κατά την (τυχαία) αρχικοποίηση. Ο στόχος μας στο κεφάλαιο αυτό είναι να κατανοήσουμε πώς διαδίδονται τα σήματα forward και backward μέσα σε ένα βαθύ MRL δίκτυο κατά την αρχικοποίηση, ώστε να προσδιορίσουμε διασπορές αρχικοποίησης των παραμέτρων του δικτύου, $W_{ij}^{(l)}, A_{ij}^{(l)}, b_i^{(l)}$, για τις οποίες το δίκτυο παραμένει εκπαιδεύσιμο για μεγάλα βάθη. Ακολουθούμε στενά την εργασία των Poole κ.ά. [21] και των Schoenholz κ.ά. [4], δηλαδή, δουλεύοντας στο όριο άπειρου πλάτους (infinite width limit) και χρησιμοποιώντας ένα Gaussian ansatz για τα preactivations, αποκτούμε ντετερμινιστικές αναδρομικές σχέσεις για τη διασπορά μόνης εισόδου και τη συσχέτιση δύο εισόδων των preactivations. Η ταχύτητα με την οποία οι αναδρομικές σχέσεις συγκλίνουν στα σταθερά τους σημεία ορίζει τα *forward depth scales*.

Για το backward propagation, η κλίμακα των fluctuations των gradients των βαρών ενός επιπέδου είναι ανάλογη της δεύτερης ροπής της παραγώγου του σφάλματος ως προς τα preactivations του επιπέδου αυτού. Η αναδρομική σχέση για τη δεύτερη αυτή ροπή είναι γραμμική, οπότε τα gradients είτε εκρήγνυνται (explode) είτε φθίνουν (vanish) εκθετικά με το βάθος. Η ταχύτητα του εκθετικού αυτού είναι ακριβώς το *backward depth scale*. Οι Schoenholz κ.ά. ισχυρίζονται στο [4] ότι τα δύο αυτά depth scales υποδεικνύουν την τάξη μεγέθους του μέγιστου βάθους ενός δικτύου πριν πάψουν τα δίκτυα να είναι εκπαιδεύσιμα. Το αξιοσημείωτο είναι ότι στην περίπτωση των τυπικών feedforward δικτύων τα δύο αυτά scales απειρίζονταν για τις ίδιες αρχικοποιήσεις, ενώ στο MRL δίκτυο αυτό δεν ισχύει πλέον. Θα το δούμε αυτό αργότερα, στην υποενότητα Backward depth scale.

Τώρα, για να αποκτήσουμε τις αναδρομικές σχέσεις που αναφέρθηκαν παραπάνω, χρειάζεται φυσικά να εκτιμήσουμε τις στατιστικές του ranking κλάδου. Όμως, ο ranking κλάδος εισάγει εξάρτηση στις συντεταγμένες του, και ως εκ τούτου, τα preactivations του δικτύου πέρα από το πρώτο επίπεδο δεν είναι πλέον iid (ανεξάρτητα και ισόνομα). Καθώς τα περισσότερα κλασικά θεωρήματα των order statistics απαιτούν την iid ιδιότητα, δεν έχουμε πλέον πρόσβαση σε αυτά, και συνεπώς, δεν μπορούμε να παρακολουθήσουμε την πλήρη κατανομή των preactivations του ranking κλάδου από επίπεδο σε επίπεδο. Αντ' αυτού, μπορούμε να βρούμε τη μέση τιμή του και να προσδιορίσουμε την τάξη μεγέθους των στατιστικών δεύτερης ροπής του. Το δεύτερο μας επιτρέπει αργότερα να εντοπίσουμε ένα καθεστώς στο οποίο ο γραμμικός κλάδος κυριαρχεί στις στατιστικές δεύτερης ροπής στο MRL δίκτυο και αυτό είναι το καθεστώς στο οποίο θα συνεχίσουμε την ανάλυση μας για το υπόλοιπο του κεφαλαίου. Ονομάζουμε το καθεστώς αυτό το *γραμμικό καθεστώς* των MRL δικτύων.

Στατιστικές του ranking κλάδου και το γραμμικό καθεστώς

Στην περίληψη αυτή παραθέτουμε μόνο τα αποτελέσματα που είναι απαραίτητα για τη mean-field ανάλυση που ακολουθεί. Για τις πλήρεις αποδείξεις, τις αναγκαίες υποθέσεις και τις ενδιάμεσες πράξεις, ο αναγνώστης παραπέμπεται στις Ενότητες 4.1.2, 4.1.3, 4.2.3 και 4.2.4 του κύριου αγγλικού χειμένου.

Παίρνοντας κοινό λ για όλους τους κόμβους του δικτύου, το hybrid preactivation σε ένα MRL δίκτυο ισούται με:

$$z_{i:a}^{(l)} = \lambda \alpha_{i:a}^{(l)} + (1 - \lambda) \beta_{i:a}^{(l)},$$

όπου $\alpha_{i:a}^{(l)}$ είναι ο ranking κλάδος και $\beta_{i:a}^{(l)}$ είναι ο γραμμικός κλάδος.

Μέση τιμή

Έστω $\alpha_{i:a}^{(l)}$ η έξοδος του ranking κλάδου στο επίπεδο l , για την είσοδο x_a . Στο όριο μεγάλου πλάτους συγκεντρώνεται γύρω από το αντίστοιχο quantile $\xi_a^{(l)}$

$$\alpha_{i:a}^{(l)} \xrightarrow{P} \xi_a^{(l)}, \text{ όπου } \xi_a^{(l)} \text{ ικανοποιεί } p^{(l)} = F_a^{(l)}(\xi_a^{(l)}).$$

Επομένως, για μεγάλο αλλά πεπερασμένο πλάτος,

$$\mathbb{E}[\alpha_{i:a}^{(l)}] \approx \xi_a^{(l)}.$$

Επειδή τα γραμμικά βάρη και τα biases έχουν μηδενική μέση τιμή, ο τύπος που θα χρησιμοποιήσουμε για τη μέση τιμή του preactivation l επιπέδου του MRL δικτύου είναι:

$$\mathbb{E}[z_{i:a}^{(l)}] \approx \lambda \xi_a^{(l)}.$$

Διακύμανση και συνδιακύμανση

Γράφοντας για συντομία $N = N_{l-1}$, προκύπτει ότι τα στατιστικά δεύτερης ροπής του ranking κλάδου έχουν τάξη μεγέθους

$$\text{Var}(\alpha_{i:a}^{(l)}) = O\left(\frac{1}{N}\right), \quad \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) = O\left(\frac{1}{N}\right).$$

Για τον γραμμικό κλάδο έχουμε

$$\text{Var}(\beta_{i:a}^{(l)}) = \sigma_w^2 \mathbb{E}\left[f^2\left(z_{j:a}^{(l-1)}\right)\right] + \sigma_b^2 = O(1),$$

και, για δύο διαφορετικές εισόδους,

$$\text{Cov}(\beta_{i:a}^{(l)}, \beta_{i:b}^{(l)}) = \sigma_w^2 \mathbb{E}[f(z_{j:a}^{(l-1)})f(z_{j:b}^{(l-1)})] + \sigma_b^2 = O(1).$$

Οι συνδιασπορές μεταξύ του ranking και του γραμμικού κλάδου προκύπτει πως μηδενίζονται. Επομένως, η διασπορά και η συνδιασπορά του hybrid preactivation είναι:

$$\begin{aligned} \text{Var}(z_{i:a}^{(l)}) &= \lambda^2 \text{Var}(\alpha_{i:a}^{(l)}) + (1 - \lambda)^2 \text{Var}(\beta_{i:a}^{(l)}) \\ \text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) &= \lambda^2 \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) + (1 - \lambda)^2 \text{Cov}(\beta_{i:a}^{(l)}, \beta_{i:b}^{(l)}) \end{aligned}$$

Χρησιμοποιώντας τώρα τις τάξεις μεγέθους

$$\begin{aligned} \text{Var}(\alpha_{i:a}^{(l)}) &= O\left(\frac{1}{N}\right), \quad \text{Var}(\beta_{i:a}^{(l)}) = O(1), \\ \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) &= O\left(\frac{1}{N}\right), \quad \text{Cov}(\beta_{i:a}^{(l)}, \beta_{i:b}^{(l)}) = O(1) \end{aligned}$$

παίρνουμε

$$\begin{aligned} \text{Var}(z_{i:a}^{(l)}) &= O\left(\frac{\lambda^2}{N}\right) + O((1 - \lambda)^2) \\ \text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) &= O\left(\frac{\lambda^2}{N}\right) + O((1 - \lambda)^2) \end{aligned}$$

Άρα, τόσο στη διασπορά όσο και στη συνδιασπορά, ο γραμμικό κλάδος κυριαρχεί όταν

$$(1 - \lambda)^2 \gg \frac{\lambda^2}{N}, \quad \text{ή ισοδύναμα} \quad 1 - \lambda \gg \frac{\lambda}{\sqrt{N}}.$$

Ονομάζουμε το καθεστώς αυτό το *γραμμικό καθεστώς*. Στο καθεστώς αυτό μπορούμε να αγνοήσουμε τον όρο τάξης $O(1/N)$ που ανήκει στον ranking κλάδο και να χρησιμοποιήσουμε τις ακόλουθες προσεγγίσεις.

$$\text{Var}(z_{i:a}^{(l)}) \approx (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[f^2(z_{j:a}^{(l-1)})] + \sigma_b^2),$$

και

$$\text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) \approx (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[f(z_{j:a}^{(l-1)})f(z_{j:b}^{(l-1)})] + \sigma_b^2).$$

Οι σχέσεις αυτές αποτελούν την αφετηρία της ανάλυσης της forward διάδοσης που ακολουθεί.

Forward depth scale

Θεωρούμε δεδομένο ότι οι παράμετροι λ και N ικανοποιούν τη συνθήκη σύμφωνα με την οποία η διασπορά και η συνδιασπορά του γραμμικού κλάδου υπερισχύουν των αντίστοιχων μεγεθών του κλάδου τάξης, δηλαδή

$$1 - \lambda \gg \frac{\lambda}{\sqrt{N}}.$$

Από εδώ και πέρα, οι ισότητες που ακολουθούν ισχύουν στο πλαίσιο αυτής της προσέγγισης.

Υπόθεση. Υποθέτουμε μία κοινή παράμετρο ρ σε ολόκληρο το νευρωνικό δίκτυο, δηλαδή

$$\rho_i^{(l)} = \rho, \quad i = 1, \dots, N_l, \quad l = 1, \dots, L.$$

Αυτό συνεπάγεται ότι

$$p_i^{(l)} = p, \quad i = 1, \dots, N_l, \quad l = 1, \dots, L.$$

Ακολουθώντας τους Schoenholz κ.ά. στο [4], εξετάζουμε πρώτα την εξέλιξη μίας μόνο εισόδου, $x_{i:a}$, καθώς αυτή διαδίδεται μέσα στο δίκτυο. Η μέση τιμή (ή πρώτη ροπή) του i -οστού preactivation στο επίπεδο l είναι:

$$\mu_a^{(l)} = \mathbb{E}[z_{i:a}^{(l)}] = \lambda \xi_a^{(l)}, \quad (2)$$

με το $\xi_a^{(l)}$ να ικανοποιεί

$$F(\xi_a^{(l)}, \mu_a^{(l-1)}, q_{aa}^{(l-1)}) = p, \quad \text{όπου } F(\xi, \mu, q) = \int \Phi\left(\frac{\xi - f(\mu + \sqrt{q}z)}{\sigma_a}\right) Dz, \quad (3)$$

και $Dz = \frac{dz}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$ είναι το τυπικό Gaussian μέτρο.

Η συνδιασπορά των preactivations στο ίδιο επίπεδο είναι:

$$\text{Cov}(z_{i:a}^{(l)}, z_{j:a}^{(l)}) = q_{aa}^{(l)} \delta_{ij}.$$

Όπου δ_{ij} είναι το δέλτα του Kronecker. Η μεταβλητή $q_{aa}^{(l)}$ είναι η διασπορά του i -οστού preactivation στο επίπεδο l . Χρησιμοποιώντας το Gaussian ansatz, παίρνουμε την ακόλουθη αναδρομική σχέση:

$$q_{aa}^{(l)} = \text{Var}(z_{i:a}^{(l)}) = (1 - \lambda)^2 \left(\sigma_w^2 \int f^2 \left(\sqrt{q_{aa}^{(l-1)}} z + \mu_a^{(l-1)} \right) Dz + \sigma_b^2 \right). \quad (4)$$

Τώρα εξετάζουμε τη διάδοση ενός ζευγαριού σημάτων $x_{i:a}$ και $x_{i:b}$ στο δίκτυο. Οι μέσες τιμές των preactivations ακολουθούν προφανώς τις ίδιες αναδρομικές σχέσεις με την περίπτωση μίας εισόδου. Η συνδιασπορά μεταξύ διαφορετικών preactivations στο ίδιο επίπεδο είναι $\text{Cov}(z_{i:a}^{(l)}, z_{j:b}^{(l)}) = \delta_{ij} q_{ab}^{(l)}$.

Η συνδιασπορά $q_{ab}^{(l)}$, χρησιμοποιώντας πάλι το Gaussian ansatz, δίνεται από:

$$q_{ab}^{(l)} = \text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) = (1 - \lambda)^2 \left(\sigma_w^2 \int f(u_1) f(u_2) Dz + \sigma_b^2 \right), \quad (5)$$

όπου $u_1 = \mu_a^{(l-1)} + \sqrt{q_{aa}^{(l-1)}} z_1$ και $u_2 = \mu_b^{(l-1)} + \sqrt{q_{bb}^{(l-1)}} (c_{ab}^{(l-1)} z_1 + \sqrt{1 - (c_{ab}^{(l-1)})^2} z_2)$, με $c_{ab}^{(l)} = q_{ab}^{(l)} / \sqrt{q_{aa}^{(l)} q_{bb}^{(l)}}$.

Ανάλυση σταθερού σημείου

Το recursive mapping μέσης τιμής-διασποράς είναι:

$$\begin{pmatrix} \mu_a^{(l)} \\ q_{aa}^{(l)} \end{pmatrix} = \begin{pmatrix} \lambda \xi_a^{(l)} \\ (1 - \lambda)^2 \left(\sigma_w^2 \int Dz f^2 \left(\mu_a^{(l-1)} + \sqrt{q_{aa}^{(l-1)}} z \right) + \sigma_b^2 \right) \end{pmatrix}, \quad (6)$$

όπου το $\xi_a^{(l)}$ ικανοποιεί την (3). Υποθέτουμε ότι η απεικόνιση αυτή έχει σταθερό σημείο (μ^*, q^*) για κάθε φραγμένη f , πεπερασμένα $\sigma_w, \sigma_b, \sigma_a > 0$ και σταθερό $p \in (0, 1)$.

Υποθέτοντας ότι τα $\mu^{(l)}, q^{(l)}$ συγκλίνουν γρήγορα στα μ^*, q^* , μπορούμε να υπολογίσουμε το σταθερό σημείο της συσχέτισης c^* , θέτοντας $q_{aa}^{(l)} = q_{bb}^{(l)} = q^*$ και $\mu_a^{(l)} = \mu_b^{(l)} = \mu^*$ στην εξίσωση (5) και διαιρώντας με q^* . Έτσι αποκτούμε μία iterative απεικόνιση του συντελεστή συσχέτισης $\mathcal{C}$ για το $c_{ab}^{(l)}$:

$$c_{ab}^{(l)} = \mathcal{C}(c_{ab}^{(l-1)}, \mu^*, q^* | \sigma_w, \sigma_b, \sigma_a, \lambda, p) \equiv \frac{(1-\lambda)^2}{q^*} \left(\sigma_w^2 \int f(u_1) f(u_2) D z_1 D z_2 + \sigma_b^2 \right), \quad (7)$$

όπου τώρα $u_1 = \mu^* + \sqrt{q^*} z_1$ και $u_2 = \mu^* + \sqrt{q^*} \left(c_{ab}^{(l-1)} z_1 + \sqrt{1 - (c_{ab}^{(l-1)})^2} z_2 \right)$.

Εξετάζοντας την εξίσωση 7, βλέπουμε ότι το $c^* = 1$ είναι σταθερό σημείο της αναδρομικής σχέσης.

Εφαρμόζοντας τον κανόνα αλυσίδας και τον κανόνα γινομένου, καθώς και την ταυτότητα


$$\int D z F(z) z = \int D z F'(z),$$

έχουμε:

$$\chi_1 \equiv \left. \frac{d c_{ab}^{(l)}}{d c_{ab}^{(l-1)}} \right|_{c_{ab}^{(l-1)}=1} = (1-\lambda)^2 \sigma_w^2 \int [f'(\mu^* + \sqrt{q^*} z)]^2 D z.$$

Το σταθερό σημείο $c^* = 1$ είναι τοπικά ευσταθές όταν $\chi_1 < 1$ και ασταθές όταν $\chi_1 > 1$. Επομένως, η συνθήκη $\chi_1 = 1$ ορίζει την κρίσιμη γραμμή μεταξύ μίας ordered φάσης, στην οποία όλες οι εισοδοί καταλήγουν ασυμπτωτικά πλήρως συσχετισμένες (correlated) με $c^* = 1$, και μίας chaotic φάσης, στην οποία όλες οι εισοδοί καταλήγουν ασυμπτωτικά αποσυσχετισμένες (decorrelated) με $c^* < 1$. Σε σύγκριση με την τυπική mean-field θεωρία στα [4] και [21], ο παράγοντας $(1-\lambda)^2$ αποσβένει άμεσα το κέρδος (gain) της συσχέτισης, ενώ οι παράμετροι p και σ_a εισέρχονται έμμεσα μέσω του σταθερού σημείου (μ^*, q^*) .


Θέτοντας $f = \tanh$, $p = 0.75$, $\lambda = 0.2$ και $\sigma_a = 1$, αποκτούμε το διάγραμμα φάσης του Σχήματος 2(a).



Σχήμα 2: Mean-field criticality στο MRL δίκτυο. (a) Το διάγραμμα φάσης μέσου πεδίου, το οποίο δείχνει το σύνορο μεταξύ της ordered και της chaotic φάσης ως συνάρτηση των σ_w^2 και σ_b^2 , όπως προκύπτει από τη συνθήκη χρησιμότητας $\chi_1 = 1$. (b) Η διαφορά $|\mu^{(l)} - \mu^*|$ ως συνάρτηση του βάθους σε λογαριθμική κλίμακα, με $\sigma_b^2 = 0.05$ και το σ_w^2 να παίρνει τιμές από την ordered περιοχή προς την χρησιμότητα. Καθώς προσεγγίζει την κρίσιμη τιμή, οι καμπύλες αλλάζουν χρώμα από κόκκινο σε μωβ. (c) Η διαφορά $|q^{(l)} - q^*|$ ως συνάρτηση του βάθους σε λογαριθμική κλίμακα για τις ίδιες τιμές παραμέτρων. (d) Η διαφορά $|c_{ab}^{(l)} - c^*|$ ως συνάρτηση του βάθους σε λογαριθμική κλίμακα, με την ίδια λογική χρωμάτων όπως στα (b) και (c). Η γρήγορη σύγκλιση των $\mu^{(l)}$ και $q^{(l)}$, σε σύγκριση με την πιο αργή σύγκλιση του $c_{ab}^{(l)}$, δικαιολογεί την αντικατάσταση του $(\mu^{(l)}, q^{(l)})$ από το (μ^*, q^*) στην ασυμπτωτική ανάλυση της συσχέτισης.

Για να επαληθεύσουμε τις feedforward mean-field αναδρομικές σχέσεις, στο Σχήμα 3 συγκρίνουμε τις προβλεπόμενες τιμές της δεύτερης ροπής και της συσχέτισης δύο εισόδων με πειραματικές μετρήσεις από υλοποιήσεις MRL δικτύων πεπερασμένου πλάτους. Χρησιμοποιούμε τη συνάρτηση ενεργοποίησης $f = \tanh$, την ranking παράμετρο $p = 0.75$, την mixing παράμετρο $\lambda = 0.2$, τη διασπορά ranking $\sigma_a^2 = 1$ και τη διασπορά του bias $\sigma_b^2 = 0.05$. Παίρνουμε βάθος $L = 240$ με κάθε επίπεδο να έχει πλάτος $N = 1000$. Οι αρχικές στατιστικές τίθενται σε $\mu^{(0)} = 0$, $q^{(0)} = 0.8$ και $c_{ab}^{(0)} = 0.6$.

Επιλέγουμε τρεις τιμές του σ_w^2 : μία για $\chi_1 < 1$ (ordered), μία για $\chi_1 = 1$ (critical) και μία για $\chi_1 > 1$ (chaotic). Για κάθε τιμή του σ_w^2 , εφαρμόζουμε επαναληπτικά την απεικόνιση και υπολογίζουμε τις τιμές των $q^{(l)} + (\mu^{(l)})^2$ και $c_{ab}^{(l)}$ που προβλέπει η θεωρία. Η κρίσιμη τιμή $\sigma_{w,\text{crit}}^2$ υπολογίζεται βρίσκοντας πρώτα το σταθερό σημείο (μ^*, q^*) των αναδρομών της μέσης τιμής και της διασποράς και επιλέγοντας έπειτα το σ_w^2 έτσι ώστε να ισχύει $\chi_1 = 1$.



Σχήμα 3: Παρακολούθηση της δεύτερης ροπής και της συσχέτισης για MRL δίκτυα. Οι συνεχείς καμπύλες αναπαριστούν τις τιμές που προκύπτουν από τις αναδρομικές σχέσεις, ενώ οι τελείες τις αντίστοιχες πειραματικές εκτιμήσεις. Οι τελευταίες υπολογίζονται με βάση τον μέσο όρο ανεξάρτητων δικτύων MRL πεπερασμένου πλάτους, με πλάτος $N = 1000$ και βάθος $L = 240$. Οι σκιασμένες ζώνες δείχνουν ± 1 standard error του μέσου όρου. Το σχήμα (a) δείχνει την παρακολούθηση της δεύτερης ροπής $q^{(l)} + (\mu^{(l)})^2$, ενώ το σχήμα (b) δείχνει την παρακολούθηση της συσχέτισης δύο εισόδων $c_{ab}^{(l)}$. Το κόκκινο, το μωβ και το μπλε αντιστοιχούν στα ordered, critical και chaotic καθεστώτα, αντίστοιχα.

Forward depth scales

Για $\sigma_b^2 = 0.05$ και για τιμές του σ_w^2 από 0.5 έως την κρίσιμη τιμή $\sigma_{w,\text{crit}}^2 \approx 2.7141$, εφαρμόζουμε επαναληπτικά τις αναδρομικές σχέσεις (2), (4) και (7) έως ότου να συγκλίνουν. Ξεκινάμε από $\mu_a^{(0)} = \mu_b^{(0)} = 0$, $q_{aa}^{(0)} = q_{bb}^{(0)} = 0.8$ και $c_{ab}^{(0)} = 0.6$. Στο Σχήμα 2(b)–(d), βλέπουμε ότι τα $\mu_a^{(l)}$, $q_{aa}^{(l)}$, $c_{ab}^{(l)}$ προσεγγίζουν τα αντίστοιχα σταθερά τους σημεία μ^* , q^* , c^* με εκθετικά φθίνουσα συμπεριφορά.

Η ανάλυσή μας διαφοροποιείται σε αυτό το σημείο από εκείνη των Schoenholz κ.ά. [4]. Όπως φαίνεται στο Σχήμα 2(c), η σύγκλιση του $q_{aa}^{(l)}$ προς το σταθερό σημείο q^* δεν φαίνεται να επιβραδύνεται καθώς το σ_w^2 πλησιάζει την κρίσιμη τιμή, δηλαδή καθώς $\chi_1 \rightarrow 1$.

Η διαφορά αυτή μπορεί να γίνει κατανοητή παρατηρώντας ότι σε εμάς η διασπορά δεν εξελίσσεται σύμφωνα με μία μονοδιάστατη αναδρομή. Αντίθετα, η μέση τιμή και η διασπορά σχηματίζουν ένα coupled διδιάστατο δυναμικό σύστημα. Επομένως, η ταχύτητα με την οποία το $q_{aa}^{(l)}$ προσεγγίζει το q^* , καθώς και η ταχύτητα με την οποία το $\mu_a^{(l)}$ προσεγγίζει το μ^* , προκύπτει από τη Ιακωβιανή της coupled απεικόνισης μέσης τιμής–διασποράς στην εξίσωση (6).

Ορίζουμε τις διαταραχές (perturbations)

$$\eta^{(l)} = \mu_a^{(l)} - \mu^*, \quad \epsilon^{(l)} = q_{aa}^{(l)} - q^*.$$

Συγκεντρώνοντάς τες σε ένα διάνυσμα, έχουμε:

$$\begin{pmatrix} \eta^{(l+1)} \\ \epsilon^{(l+1)} \end{pmatrix} = \begin{pmatrix} J_{\mu\mu} & J_{\mu q} \\ J_{q\mu} & J_{qq} \end{pmatrix} \begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix} + O\left(\left\| \begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix} \right\|^2\right).$$

Τα στοιχεία της Ιακωβιανής της coupled απεικόνισης μέσης τιμής-διασποράς έχουν υπολογιστεί στην υποενότητα του Παραρτήματος C.5.2. Επομένως, η ταχύτητα σύγκλισης της δυναμικής μέσης τιμής-διασποράς καθορίζεται από τη φασματική ακτίνα $\rho(J)$ και όχι μόνο από το χ_1 .

Έτσι, για αρκετά μεγάλο l , έχουμε:

$$\left\| \begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix} \right\| = \left\| \begin{pmatrix} \mu_a^{(l)} - \mu^* \\ q_{aa}^{(l)} - q^* \end{pmatrix} \right\| \sim e^{-l/\xi_{\mu,q}},$$

όπου

$$\xi_{\mu,q}^{-1} = -\log \rho(J).$$

Το $\xi_{\mu,q}$ συμβολίζει το depth scale που ελέγχει πόσο βαθιά διεισδύει σε ένα τυχαίο MRL νευρωνικό δίκτυο η πληροφορία που προέρχεται από μία μόνο είσοδο.

Όσον αφορά τη σύγκλιση της συσχέτισης $c_{ab}^{(l)}$, παρατηρούμε ότι ακολουθεί ακριβώς το ίδιο μοτίβο με το [4]: επιβραδύνεται αισθητά καθώς το σ_w^2 προσεγγίζει την κρίσιμη τιμή.

Θα αποδείξουμε τώρα ότι, ασυμπτωτικά, $|c_{ab}^{(l)} - c^*| \sim e^{-l/\xi_c}$, όπου το ξ_c είναι το depth scale που ελέγχει πόσο βαθιά μπορεί να διεισδύσει σε ένα τυχαίο νευρωνικό δίκτυο η πληροφορία που προέρχεται από ένα ζευγάρι εισόδων. Αρχικά, αναλύουμε την εξίσωση (5). Αναπτύσσοντας γύρω από το $c_{ab}^{(l)} = c^* + \epsilon^{(l)}$, παίρνουμε:

$$\epsilon^{(l+1)} = \epsilon^{(l)} \left[(1 - \lambda)^2 \sigma_w^2 \iint f'(u_1^*) f'(u_2^*) D z_1 D z_2 \right] + O\left((\epsilon^{(l)})^2\right),$$

όπου $u_1^* = \mu^* + \sqrt{q^*} z_1$ και

$$u_2^* = \mu^* + \sqrt{q^*} \left[c^* z_1 + \sqrt{1 - (c^*)^2} z_2 \right].$$

Καθώς η μετατόπιση της μέσης τιμής μ^* είναι σταθερή ως προς τα $c_{ab}^{(l)}$, z_1 και z_2 , δεν επηρεάζει το ανάπτυγμα Taylor ούτε τις Gaussian ταυτότητες ολοκλήρωσης κατά μέρη που χρησιμοποιούνται στις πράξεις των Schoenholz κ.ά. Ως εκ τούτου, η ασυμπτωτική αναδρομική σχέση έχει την ίδια μορφή με εκείνη στο [4], με μόνη διαφορά ότι τα preactivations σταθερού σημείου u_1^* και u_2^* είναι μετατοπισμένα κατά μ^* .

Επομένως, για αρκετά μεγάλο l , η παραπάνω αναδρομή θα έχει εκθετική λύση, $\epsilon^{(l)} \sim e^{-l/\xi_c}$, με το ξ_c να δίνεται από:

$$\xi_c^{-1} = -\log \left((1 - \lambda)^2 \sigma_w^2 \iint f'(u_1^*) f'(u_2^*) D z_1 D z_2 \right). \quad (8)$$

Στην ordered φάση ισχύει $c^* = 1$ και, συνεπώς, $\xi_c^{-1} = -\log \chi_1$.

Backward depth scale

Οι Schoenholz κ.ά. έδειξαν στο [4] ότι στα fully connected νευρωνικά δίκτυα υπάρχει μία δυϊκότητα μεταξύ της forward διάδοσης των σημάτων και του backpropagation των gradients, δηλαδή, σε εκείνους, η ίδια παράμετρος χ_1 έλεγχε πόσο βαθιά διαδίδεται η πληροφορία μέσα στο δίκτυο τόσο προς τα εμπρός όσο και προς τα πίσω. Αντίθετα, δείχνουμε ότι στην MRL αρχιτεκτονική μας η δυϊκότητα αυτή παύει να ισχύει: το backward depth scale διαφέρει από το feedforward depth scale.

Για να υπολογίσουμε το gradient backpropagation depth scale ή αλλιώς backward depth scale, ακολουθούμε την εργασία στο [4].

Αρχικά, θεωρούμε τις εξισώσεις backpropagation για μία loss function E :

$$\frac{\partial E}{\partial W_{ij}^{(l)}} = \delta_i^{(l)} (1 - \lambda) f(z_j^{(l-1)}), \quad \delta_i^{(l)} = f'(z_i^{(l)}) \sum_j^{N_{l+1}} \delta_j^{(l+1)} \left[\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right],$$

$$\delta_i^{(l)} = \frac{\partial E}{\partial z_i^{(l)}},$$

$$\text{όπου } S_{ji}^{(l+1)} = \mathbb{1} \left\{ (f(\mathbf{z}^{(l)}) + \mathbf{a}_j^{(l+1)})_{r(l+1)} = f(z_i^{(l)}) + A_{ji}^{(l+1)} \right\}.$$

Στο πλαίσιο της mean-field θεωρίας, το scale των fluctuation των gradients των βαρών ενός επιπέδου είναι ανάλογο του $\mathbb{E}[(\delta_i^{(l)})^2]$ (βλ. Παράρτημα C.5.3).

Εάν υποθέσουμε επιπλέον πως τα βάρη που χρησιμοποιούνται κατά τη forward propagation είναι ανεξάρτητα από τα βάρη που χρησιμοποιούνται στο backpropagation, μπορούμε να πάρουμε (βλ. Παράρτημα C.5.3) μία αναδρομική σχέση για τη διασπορά του σφάλματος $\tilde{q}^{(l)} = \mathbb{E}[(\delta_i^{(l)})^2]$:

$$\tilde{q}_{aa}^{(l)} \approx \frac{N_{l+1}}{N_l} \chi_{\nabla} \tilde{q}_{aa}^{(l+1)},$$

όπου

$$\chi_{\nabla} = \chi_1 \left(\frac{\lambda^2}{(1 - \lambda)^2 \sigma_w^2} + 1 \right).$$

Αξίζει να σημειωθεί ότι, για $\lambda = 0$, η παραπάνω αναδρομική σχέση ανάγεται σε εκείνη του [4].

Θεωρώντας MRL δίκτυα σταθερού πλάτους ανά επίπεδο, παίρνουμε:

$$\tilde{q}^{(l)} = \tilde{q}^{(L)} e^{-(L-l)/\xi_{\nabla}},$$


όπου

$$\xi_{\nabla}^{-1} = -\ln(\chi_{\nabla}) = -\ln(\chi_1) - \ln \left(1 + \frac{\lambda^2}{(1 - \lambda)^2 \sigma_w^2} \right).$$

Επομένως, προκύπτουν τρία διακριτά καθεστώτα για το gradient backpropagation.

- Στην ordered φάση, $\chi_{\nabla} < 1$ και, συνεπώς, $\xi_{\nabla} > 0$. Στην περίπτωση αυτή, τα backpropagated gradients φθίνουν εκθετικά με το βάθος, με αποτέλεσμα να εμφανίζεται το φαινόμενο των *vanishing gradients* έπειτα από $|\xi_{\nabla}|$ επίπεδα.
- Στο κρίσιμο σημείο, $\chi_{\nabla} \rightarrow 1$ και, επομένως, $\xi_{\nabla} \rightarrow \infty$. Κατά συνέπεια, το εκθετικό depth scale τείνει στο άπειρο και οι κλίσεις παραμένουν περίπου σταθερές ακόμη και σε αυθαίρετα μεγάλα βάθη.
- Στην chaotic φάση, $\chi_{\nabla} > 1$ και, συνεπώς, $\xi_{\nabla} < 0$. Σε αυτό το καθεστώς, τα backpropagated gradients αυξάνονται εκθετικά με το βάθος, με αποτέλεσμα να εμφανίζεται το φαινόμενο των *exploding gradients* έπειτα από $|\xi_{\nabla}|$ επίπεδα.

Για να δούμε πειραματικά τη συμπεριφορά των gradients κατά τη διάδοσή τους, θεωρούμε τυχαία αρχικοποιημένα MRL δίκτυα βάθους $L = 240$ και πλάτους $N_l = 300$. Θέτουμε $\lambda = 0.2$, $f = \tanh$, $p = 0.75$, καθώς και $\sigma_a^2 = 1$ και $\sigma_b^2 = 0.05$. Δεν εκπαιδεύουμε το δίκτυο. Αντίθετα, για κάθε τυχαίο δίκτυο, υπολογίζουμε το cross-entropy loss σε ένα minibatch δεδομένων MNIST και εκτελούμε ένα μόνο backward pass. Το Σχήμα 4(a) δείχνει το τετράγωνο της Frobenius νόρμας του gradient ως προς τον πίνακα βαρών $W^{(l)}$ κάθε επιπέδου, ως συνάρτηση του επιπέδου l , για διάφορες τιμές του σ_w^2 . Σε όλο το εύρος των επιπέδων, οι νόρμες των gradients παρουσιάζουν σαφή εκθετική συμπεριφορά. Πράγματι, βλέπουμε ότι, για ordered τιμές του σ_w^2 (κόκκινο), τα gradients συρρικνώνονται γρήγορα, για τιμές κοντά στην κρίσιμη γραμμή (μωβ) μένουν περίπου σταθερά ως προς το βάθος και, τέλος, για chaotic τιμές του σ_w^2 (μπλε) αυξάνονται γρήγορα.




Σχήμα 4: Πειραματική επαλήθευση της θεωρίας backward διάδοσης των gradients σε τυχαία αρχικοποιημένα MRL δίκτυα. Το σχήμα (a) δείχνει το ανά επίπεδο τετράγωνο της Frobenius νόρμας $\|\nabla_{W^{(l)}} E\|_F^2$ ως συνάρτηση του επιπέδου l για διαφορετικές τιμές του σ_w^2 , από την ordered περιοχή (κόκκινο) προς την critical (μωβ) και έπειτα προς τη chaotic (μπλε). Το σχήμα (b) συγκρίνει το προκύπτον από πειράματα gradient depth scale $|\xi_\nabla|$ με τη θεωρητική πρόβλεψη. Το σ_w^2 μεταβάλλεται από την ordered περιοχή προς την critical και έπειτα προς τη chaotic, με τον ίδιο τρόπο όπως στο (a).

Στο Σχήμα 4(b), συγκρίνουμε τη θεωρητική τιμή του $|\xi_\nabla|$ με την πειραματική τιμή που μετράται σε τυχαία αρχικοποιημένα MRL δίκτυα για διάφορες τιμές του σ_w^2 . Για κάθε επιλογή του σ_w^2 , υπολογίζουμε την προκύπτουσα από πειράματα δεύτερη ροπή των backpropagated preactivation gradients $\delta_i^{(l)}$ σε κάθε επίπεδο και εκτιμούμε το προκύπτον από πειράματα depth scale κάνοντας fit τη μεταβολή τους ως προς το βάθος σε μία εκθετική. Οι πειραματικές τιμές συμφωνούν με τις θεωρητικές προβλέψεις από τη mean-field θεωρία για όλες τις τιμές του σ_w^2 που πήραμε.

Κεφάλαιο 5

Εκπαίδευση MRL δικτύων: πειράματα


Η ανάλυσή μας στο Κεφάλαιο 4 υποδεικνύει ότι στα βαθιά MRL δίκτυα, η εκπαιδευσιμότητα καθορίζεται από το πόσο καλά διαδίδονται τα σήματα forward (δηλαδή, η συσχέτιση να μη συγκλίνει γρήγορα στο σταθερό της σημείο) και τα gradients backward (δηλαδή, τα gradients να μην παρουσιάζουν ούτε το *vanishing* ούτε το *exploding* φαινόμενο). Αυτό συμβαίνει ακριβώς όταν το βάθος του δικτύου L είναι ίδιας τάξης μεγέθους με τα depth scales ξ_c και ξ_∇ . Ακολουθώντας τους Schoenholz et al. στο [4], ελέγχουμε την υπόθεση αυτή ως εξής: για κάθε ζευγάρι βάθους και αρχικοποίησης, εκπαιδεύουμε πέντε ανεξάρτητα δίκτυα με διαφορετικό seed και στη συνέχεια εκτυπώνουμε το μέσο training accuracy ως συνάρτηση του βάθους και των αντίστοιχων υπερπαραμέτρων.



Σχήμα 5: Μέσο training accuracy στο MNIST των δικτύων MRL ως συνάρτηση του βάθους L και της αρχικής διασποράς βαρών σ_w^2 , με εύρος από υψηλή ακρίβεια (ανοιχτό κόκκινο) έως χαμηλή ακρίβεια (μαύρο). Τα διαγράμματα (a) και (b) δείχνουν την ακρίβεια μετά από 200 βήματα SGD. Στο (a), οι λευκές διακεκομμένες καμπύλες συμβολίζουν τα πολλαπλάσια $n\xi_c$, ενώ στο (b), οι κυανές διακεκομμένες καμπύλες συμβολίζουν τα $n\xi_\nabla$, για $n \in \{1, 3, 6, 9\}$. Τα διαγράμματα (c) και (d) δείχνουν την ακρίβεια μετά από 2.000 και 5.000 βήματα SGD, αντίστοιχα, με τα $9\xi_c$ και $9\xi_\nabla$ από πάνω. Οι συμπαγείς λευκές και κυανές γραμμές σημειώνουν τις κρίσιμες αρχικοποιήσεις $\chi_1 = 1$ και $\chi_\nabla = 1$, αντίστοιχα. Τα αποτελέσματα είναι ο μέσος όρος 5 ανεξάρτητων τυχαίων seeds.

Εκπαιδεύουμε δίκτυα με βάθος δικτύου $10 \leq L \leq 320$, διασπορά αρχικοποίησης βαρών $1.5 \leq \sigma_w^2 \leq 4$, διασπορά αρχικοποίησης του ranking bias $\sigma_a^2 = 1$ και διασπορά αρχικοποίησης του γραμμικού bias $\sigma_b^2 = 0.05$. Επιπλέον, παίρνουμε mixing coefficient $\lambda = 0.2$ και $p = 0.75$, δηλαδή η ranking συνάρτηση επιστρέφει περίπου το $[0.75 \cdot N]$ -οστό μικρότερο στοιχείο. Ως πλάτος των επιπέδων του δικτύου παίρνουμε $N = 64$. Η επιλογή του λ είναι σκόπιμη, είναι τέτοια ώστε να είμαστε στο γραμμικό καθεστώς, στο οποίο έλαβε και χώρα όλη μας η θεωρητική ανάλυση.

Εκπαιδεύουμε τα δίκτυα πάνω στο σύνολο δεδομένων MNIST (υποσύνολο 20.000 δειγμάτων) χρησιμοποιώντας stochastic gradient descent με batch size 64. Παίρνουμε learning rate 0.05 για $L \leq 80$, 0.01 για $80 < L \leq 160$ και τέλος 0.0001 για $160 < L \leq 320$. Χρησιμοποιούμε το cross entropy loss. Το training accuracy υπολογίζεται με batch size 256, πάνω σε ένα υποσύνολο 5.000 δειγμάτων εκπαίδευσης. Αν και η ανάλυσή μας αφορά αυστηρά την εκπαιδευσιμότητα και όχι το generalization, συμπεριλαμβάναμε διαγράμματα των test accuracies στο Σχήμα 6 για λόγους πληρότητας.



Σχήμα 6: Μέσο test accuracy στο MNIST των δικτύων MRL ως συνάρτηση του βάθους L και της αρχικής διασποράς βαρών σ_w^2 , όπου η υψηλή ακρίβεια αναπαρίσταται με ανοιχτό μπλε και χαμηλή ακρίβεια με μαύρο. Τα διαγράμματα δείχνουν το test accuracy μετά από (a) 200, (b) 2.000 και (c) 5.000 βήματα εκπαίδευσης SGD. Τιμές κάτω από τη τιμή τυχαίου accuracy εμφανίζονται με μαύρο.

Ειδικότερα, οι τιμές $\sigma_{w^2, \chi_1} = 2.8742$ και $\sigma_{w^2, \chi_\nabla} = 2.7141$ έχουν ιδιαίτερη σημασία. Η πρώτη είναι το σ_w^2 για το οποίο το forward propagation είναι critical, δηλαδή $\chi_1 = 1$, και η δεύτερη είναι το σ_w^2 για το οποίο το backward propagation είναι critical, δηλαδή $\chi_\nabla = 1$.

Στο Σχήμα 5 εκτυπώνουμε το training accuracy ως συνάρτηση των L και σ_w^2 . Όπως στους Schoenholz et al. [4], ο σκοπός του διαγράμματος είναι η σύγκριση της εκπαιδευσιμής περιοχής των πειραμάτων με τις θεωρητικά depth scales.

Τα προκύπτοντα διαγράμματα του training accuracy δείχνουν πώς η εκπαιδευσιμότητα συγκεντρώνεται στην κρίσιμη ζώνη καθώς το βάθος αυξάνεται. Αυτό ακριβώς συνάδει με τη θεωρητική μας ανάλυση. Τα ρηχά δίκτυα εκπαιδεύονται για ένα σχετικά ευρύ φάσμα τιμών του σ_w^2 . Αντιθέτως, για βαθύτερα δίκτυα, φαίνεται πως η εκπαίδευση τους είναι ευαίσθητη ως προς την αρχικοποίηση, με την εκπαιδευσιμη περιοχή τους να στενεύει στην προβλεπόμενη κρίσιμη περιοχή. Επομένως, μπορούμε να συμπεράνουμε ότι δεν υφίσταται μία μοναδική βέλτιστη τιμή του σ_w^2 , αλλά πως μάλλον έχουμε την ύπαρξη μίας κρίσιμης ζώνης εντός της οποίας τα βαθιά δίκτυα MRL παραμένουν εκπαιδευσιμα.

Κεφάλαιο 6

Συμπεράσματα & Μελλοντικές επεκτάσεις

Συμπεράσματα

Στην εργασία αυτή προσπαθήσαμε να απαντήσουμε στο ερώτημα του αν η θεωρία αρχικοποίησης που ανέπτυξαν οι Poole et al. και οι Schoenholz et al. για τα κλασικά feedforward δίκτυα εξακολουθεί να ισχύει όταν οι νευρώνες δεν είναι αμιγώς γραμμικοί, αλλά ένας (χυρτός) συνδυασμός ενός γραμμικού κόμβου και ενός ranking κόμβου. Είχαμε βάσιμους λόγους να θεωρήσουμε ότι δεν θα ισχύει. Συγκεκριμένα, η ranking συνάρτηση είναι μη διαφορίσιμη, εισάγει εξαρτήσεις στις συντεταγμένες της εισόδου της και, πέρα από το πρώτο επίπεδο, οι συντεταγμένες αυτές δεν είναι πλέον iid.

Όσον αφορά την εκπαίδευση, το υποδιαφορικό Clarke μάς έδωσε ένα καλώς ορισμένο υποκατάστατο του gradient στον ranking κλάδο, εκεί όπου η συνήθης παράγωγος δεν ορίζεται. Έτσι, μπορέσαμε να διατυπώσουμε ένα μαθηματικά αυστηρό μη λείο backpropagation για το δίκτυο MRL.

Όσον αφορά την αρχικοποίηση, δεν μπορέσαμε να εκτιμήσουμε άμεσα τα στατιστικά δεύτερης ροπής του ranking κλάδου, μπορέσαμε όμως να προσδιορίσουμε την τάξη μεγέθους τους, και αυτό αρκούσε για να εντοπίσουμε ένα καθεστώς στο οποίο κυριαρχεί ο γραμμικός κλάδος. Στο καθεστώς αυτό, η κύρια επίδραση του ranking κλάδου στο forward propagation είναι μια ντετερμινιστική μετατόπιση της μέσης τιμής. Λαμβάνοντας υπόψη τη μετατόπιση αυτή, η ανάλυση μας προχωρά όπως στους Schoenholz et al., με ordered και chaotic φάσεις και forward και backward depth scales.

Το πιο ενδιαφέρον αποτέλεσμα αφορά το σημείο στο οποίο το MRL δίκτυο διαφοροποιείται από τα κλασικά δίκτυα. Στα κλασικά feedforward δίκτυα η forward και η backward χρισσιμότητα συμπίπτουν ενώ στα δίκτυα MRL όχι. Η επίδραση του ranking κλάδου στα forward στατιστικά δεύτερης ροπής είναι σχεδόν αμελητέα, επηρεάζει άμεσα όμως την backward διάδοση μέσω του subgradient του, έτσι, οι δύο χρισσιμότητες διαχωρίζονται. Μία καλή αρχικοποίηση για ένα δίκτυο MRL δεν βρίσκεται επομένως κοντά σε ένα μοναδικό κρίσιμο σημείο, αλλά μεταξύ δύο διαφορετικών κρίσιμων σημείων. Τα πειράματά μας στο MNIST συνάδουν με την εικόνα αυτή. Τα ρηχά δίκτυα εκπαιδεύονται σε ένα ευρύ φάσμα τιμών του σ_w^2 , ενώ για βαθύτερα δίκτυα η εκπαιδευσιμη περιοχή στενεύει προς τη ζώνη μεταξύ των δύο κρίσιμων τιμών, εκεί ακριβώς όπου και τα δύο depth scales παραμένουν μεγάλα.

Δεν ισχυριζόμαστε ότι η εικόνα είναι πλήρης. Η ανάλυση λαμβάνει χώρα στο καθεστώς στο οποίο ο γραμμικός κλάδος κυριαρχεί ως προς τα στατιστικά δεύτερης ροπής, και πήραμε τη ranking παράμετρο σταθερή και central. Το επόμενο φυσικό ερώτημα είναι το αν οι κρίσιμες αρχικοποιήσεις που βρήκαμε εδώ εξακολουθούν να ισχύουν όταν η συμβολή του ranking κλάδου στα στατιστικά δεύτερης ροπής είναι συγκρίσιμη με εκείνη του γραμμικού κλάδου ή ακόμη και μεγαλύτερη της. Παρ' όλα αυτά, ακόμα και στο καθεστώς που μελετήσαμε, η συμβολή του ranking κλάδου δεν είναι ανύπαρκτη. Μετατοπίζει τα forward στατιστικά πρώτης ροπής και συνεισφέρει στην backward διάδοση αρκετά ώστε η δυϊκότητα μεταξύ των δύο χρισσιμότητων να πάψει να ισχύει. Ελπίζουμε ότι τα εργαλεία που συγκεντρώθηκαν στην εργασία αυτή καθιστούν την απάντηση του ερωτήματος αυτού προσιτή.

Μελλοντικές επεκτάσεις

Ένας περιορισμός της εργασίας αυτής είναι ότι παίρνουμε την ranking παράμετρο $r_i^{(l)}$ σταθερή, ενώ στην αρχική εργασία των Pessoa και Maragos ήταν εκπαιδύσιμη (μέσω της $\rho_i^{(l)}$). Επιπλέον, υποθέτουμε ότι το rank της βρίσκεται μακριά από τα άκρα, δηλαδή ότι η ranking συνάρτηση είναι ένα central order statistic. Σε μελλοντική εργασία θα μπορούσαμε να πάρουμε ένα $r_i^{(l)}$ τέτοιο ώστε η ranking συνάρτηση να προσεγγίζει την πράξη $\min$ ή $\max$. Στην περίπτωση της δεύτερης, θα είχαμε ένα extreme order statistic, το οποίο ασυμπτωτικά συμπεριφέρεται διαφορετικά από το central order statistic που μελετήσαμε εδώ. Για περισσότερα, βλ. David και Nagaraja [22, Ενότ. 10.5].

Ο κύριος περιορισμός της εργασίας αυτής είναι ότι, καθώς δεν προσδιορίσαμε τα στατιστικά δεύτερης ροπής του ranking κλάδου αλλά μονάχα την τάξη μεγέθους τους, εστιάσαμε στο καθεστώς στο οποίο τα στατιστικά δεύτερης ροπής του γραμμικού κλάδου υπερίσχυαν εκείνων του ranking κλάδου. Επομένως, το φυσικό επόμενο βήμα για το μέλλον θα ήταν ο ακριβής προσδιορισμός των στατιστικών δεύτερης ροπής του ranking κλάδου. Αυτό θα μας επέτρεπε να μην επιβάλλουμε τη συνθήκη του mixing coefficient και του πλάτους του δικτύου και να θεωρήσουμε καθεστώτα στα οποία ο ranking κλάδος να έχει στατιστικά δεύτερης ροπής συγκρίσιμα με, ή ακόμα και που υπερισχύουν, των στατιστικών δεύτερης ροπής του γραμμικού κλάδου. Αυτό παρουσιάζει μεγάλο ενδιαφέρον για εμάς, καθώς θα απαντούσε στο ερώτημα αν οι συνθήκες critical αρχικοποίησης που βρήκαμε στην εργασία αυτή θα εξακολουθήσουν να ισχύουν σε καθεστώτα στα οποία ο γραμμικός κλάδος δεν υπερισχύει.

Τέλος, στην εργασία μας ισχύει ο ίδιος περιορισμός με αυτόν των Schoenholz et al., δηλαδή ότι η θεωρία που αναπτύχθηκε εδώ αφορά φραγμένες συναρτήσεις ενεργοποίησης και δεν εφαρμόζεται σε μη φραγμένες, όπως η κλασική ReLU.

Chapter 1

Introduction

1.1 Introduction and motivation

This thesis studies the morphological/ranking/linear networks, abbreviated MRL, introduced by Pessoa and Maragos [1]. They belong to the class of morphological neural networks. Specifically, each MRL node is a convex combination of a linear node, the same one as in fully connected neural networks, and a ranking node. This ranking node is a generalization of the classical morphological node [2]. It was introduced by Pessoa and Maragos in [3] and it returns the r -th smallest entry of the input vector shifted by a ranking bias.

In general, the ranking function is nondifferentiable, which is why the training of MRL networks was originally performed with heuristic gradient computations. In the first part of this thesis, we leverage the fact that the ranking function is locally Lipschitz continuous, hence admits a Clarke subdifferential, and derive a rigorous nonsmooth backpropagation for the full MRL network.

In the second and main part of this thesis, we analyze how forward and backward signals propagate through neural layers in randomly initialized deep MRL networks, extending the mean field analysis that Schoenholz et al. developed in *Deep Information Propagation* [4] for fully connected networks. The main difficulty lies in the coupling of the input coordinates by the ranking operation, which makes tracking the second moment statistics of the ranking branch difficult. We sidestep this by analyzing MRL networks in a regime in which the linear branch dominates these statistics. Notably, we find that, unlike in standard feedforward networks, the forward and backward criticalities in MRL networks do not coincide, so that a good initialization for a deep MRL network is a balance between two distinct critical points.

In summary, we try to answer the question “*How should we initialize deep MRL networks so that they remain trainable?*”.

1.2 Neural networks

In 1943 McCulloch and Pitts published *A Logical Calculus of the Ideas Immanent in Nervous Activity* [5]. It was in this paper that the first mathematical model of a neural network, the “McCulloch-Pitts neuron”, was introduced. Notably this paper introduced NNs as a computational model. It was only in 1958 when Rosenblatt published *The Perceptron: a Probabilistic Model for Information Storage and Organization in the Brain* [6] that neural networks were introduced as a learning model, albeit they were not trained with the gradient based learning that prevails today. Later on, in 1969, Minsky and Papert, in their book *Perceptrons* [7], proved the limitations of the single layer perceptron model (namely, among others, that it could not compute the XOR operation) and made the point that up to then there was no reliable algorithm available to train the multi layer version. They notably write “*There is no reason to suppose that any of these virtues¹ carry over to the many-layered version*”. This led to growing skepticism toward neural networks and contributed to their research slowing down roughly from 1969 to 1982. Then, there was a renewed interest in neural networks thanks to the popularization of backpropagation with Rumelhart, Hinton et al.’s 1986 work *Learning Representations by Back-Propagating Errors* [8]. A few

¹Here, Minsky and Papert are talking about the virtues of the single layer Perceptron.

years later, LeCun et al.'s [9] empirical success on training multi layer NNs on handwritten zip-recognition with backpropagation helped establish it and gradient based training as the go-to way to train multi layer neural networks.

A major shift took place in 2012, with Krizhevsky et al.'s *ImageNet Classification with Deep Convolutional Neural Networks* [10], in which they trained a deep and large convolutional network on ImageNet and it performed substantially better than the state-of-the-art computer vision methods of the time. This and other empirical successes of deep networks naturally raised the question of why depth is useful. In his *Benefits of depth in neural networks* work, Telgarsky [11] showed that deep neural networks can approximate (certain) functions with exponentially fewer neurons than needed in shallow networks.

As modern neural networks grew ever larger, it became natural to study their large or deep limits, i.e. limits in which we let the width or the depth of a neural network tend to infinity. An early and influential example of this analysis and its promise was Neal's work in *Priors for Infinite Networks* [12], where he showed that under suitable priors for the network's weights, as width tends to infinity, the network's outputs converge to a Gaussian process. This was a concrete example of how very large networks can be described, in the infinite width limit, by simpler mathematical objects.

Neal's work showed that the infinite width limit could be used to study networks at initialization. Later work then showed that taking an infinite width or depth limit can also be used to study the training of a network. Namely, for the first, in *Neural Tangent Kernel: Convergence and Generalization in Neural Networks* [13], Jacot et al. applied the infinite width analysis to study the training dynamics of very large networks. For the second, Jacot in *Implicit Bias of Large Depth Networks: a Notion of Rank for Nonlinear Functions* [14], used the infinite depth limit to study the so-called implicit bias of deep homogeneous² networks, that is, study why in training, deep homogeneous networks are "biased" to favor certain functions when fitting the training data.

It is that same general philosophy, namely of using the infinite width/depth limit to reveal properties that are hard to see in finite networks, that we follow in this thesis to study morphological neural networks, a special class of networks introduced in the next section. Specifically, following closely Schoenholz et al.'s work in [4], we study the propagation of signals and gradients in randomly initialized deep morphological networks and leverage mean-field approximations and an infinite width limit to identify initialization settings that improve trainability.

1.3 Morphological neural networks

Up to now, the neural networks discussed above more or less share the common architecture feature of the linear neural node, i.e. the linear node:

$$z_i = \sum_j W_{ij} y_j + b_i$$

followed by a nonlinear activation f , such as the sigmoid or the rectified linear unit, commonly known as ReLU. Davidson and Hummer [2] in 1993, inspired from the success of mathematical morphology in image processing, proposed replacing the standard linear node with the morphological node, i.e.:

$$z_i = \bigvee_j (y_j + A_{ij}) \quad \text{or} \quad z_i = \bigwedge_j (y_j + A_{ij})$$

where $\bigvee$ denotes the dilation based operator and is the maximum over j , and $\bigwedge$ denotes the erosion based operator and is the minimum over j . Thus, the input combination is no longer a weighted sum, but a maximum/minimum of shifted input coordinates.

Because dilation and erosion are themselves nonlinear operations, it was believed that a nonlinear activation function was not strictly necessary.

Notably in 1998, Ritter et al. in *Morphological Associative Memories* [15] make the case that if the strength of the electric potential is an additive process and the postsynaptic membrane only accepts signals of a certain maximum strength then morphological networks have a strong biological plausibility.

²A neural network is homogeneous if its network (output) function scales as follows as we scale its θ parameters : $f(x; c\theta) = c^L f(x; \theta)$. Here L is the depth of the network.

The dilation and erosion operations are closely related to the ranking operator, also known as the order statistic. Indeed, Maragos and Schafer [16] showed that the ranking operator, i.e. choosing the k -th largest/smallest entry of a vector can be represented as the maximum of erosions or equivalently as the minimum of dilations. Using this connection it becomes natural to pass from pure dilation/erosion neurons to the more general rank neuron. In that spirit, Maragos and Pessoa [3] introduced the ranking neural network, whose ranking nodes were of the following form:

$$z_i = R_r(y + a),$$

here, R_r denotes the ranking operation in which the r -th smallest entry of the shifted-by- a vector y is returned.

The architecture studied in this thesis, is an extension of this network. Specifically, Pessoa and Maragos [1], a few years after the introduction of the ranking networks, introduced the morphological/ranking/linear network, abbreviated MRL, in which each node is a sum of a ranking node and the classical linear node from the Perceptron. Specifically, the MRL node is of the following form:

$$z_i = \lambda R_r(y + a) + (1 - \lambda) \left(\sum_j W_{ij} y_j + b_i \right)$$

It should be noted that for $\lambda = 0$, the MRL node reduces to the linear node, and for $\lambda = 1$ it reduces to the ranking node. Like other morphological neural networks, the MRL network suffers from training issues, namely the nondifferentiability of the max, min and ranking operation when a tie occurs between entries of the $y + a$ vector. In [1], to tackle this, Pessoa and Maragos used a heuristic gradient for the ranking operation. We will revisit the training of the MRL network in hopes of a formalization using subderivatives. For a broader treatment of morphological operators, and classical and modern approaches to training morphological neural networks, see Chapter 4 of Maragos [23].

Morphological networks have also been revisited in the modern deep learning setting. Dimitriadis and Maragos [17] studied dense morphological networks and found that they can be pruned remarkably well with their performance surviving even when a large percentage of the parameters is removed. Fotopoulos and Maragos [18] studied deep morphological architectures and showed that pure dilation/erosion networks without activations are not universal approximators, refuting the long held belief that morphological networks do not need activations. Moreover, they made the case that the nonlinearity of the morphological neurons in general is not enough, deep MNNs need activations, residual connections and hybrid linear-morphological layers to be expressive and trainable.

Chapter 2

The MRL network

2.1 The ranking function

Before we define the architecture of the main scope of this thesis, i.e. the MRL network, we first need to define the ranking function, also more commonly known as the order statistic. We will freely interchange between the two names.

Definition 2.1.1 (Ranking function/Order statistic). *Let $t = (t_1, \dots, t_n) \in \mathbb{R}^n$ and r be an integer in $\{1, \dots, n\}$. Suppose we sort the entries of the vector t in ascending order as $t_{(1)} \leq \dots \leq t_{(n)}$. The ranking function, or the r -th order statistic, is then defined as:*

$$R_r(t) := t_{(r)}.$$

Example 2.1.2. *Let $t = (4, 1, 7, 1) \in \mathbb{R}^4$. Sorting its entries in ascending order gives*

$$t_{(1)} = 1, \quad t_{(2)} = 1, \quad t_{(3)} = 4, \quad t_{(4)} = 7.$$

Then, $R_1(t) = \min(t) = 1$ returns the smallest entry, $R_4(t) = \max(t) = 7$ the largest, and $R_3(t) = 4$. Note that the value 1 is both the first and the second order statistic, so R_r returns a well defined value at a tie.

2.2 Architecture of the MRL network

We consider the morphological/rank/linear (MRL) network introduced by Pessoa and Maragos in [1], a feedforward network with L layers and layer widths $N_0, \dots, N_L$.

Let $f : \mathbb{R} \rightarrow \mathbb{R}$ be a scalar activation function, such as sigmoid, tanh and ReLU. Then, for each layer $l = 1, \dots, L$:

$$\mathbf{y}^{(l)} = \mathbf{F}^{(l)}(\mathbf{z}^{(l)}) = (f(z_1^{(l)}), \dots, f(z_{N_l}^{(l)}))^{\top}, \quad z_i^{(l)} = h(\mathbf{y}^{(l-1)}; \boldsymbol{\theta}_i^{(l)}), \quad i = 1, \dots, N_l,$$

where $\mathbf{y}^{(0)}$ is the network input and $\mathbf{y}^{(L)}$ is the network output.

Each node is a convex combination of a linear and ranking/morphological part

$$z_i^{(l)} = h(\mathbf{y}^{(l-1)}; \boldsymbol{\theta}_i^{(l)}) = \lambda_i^{(l)} \alpha_i^{(l)} + (1 - \lambda_i^{(l)}) \beta_i^{(l)},$$

where

$$\alpha_i^{(l)} = R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}), \quad \beta_i^{(l)} = (\mathbf{w}_i^{(l)})^{\top} \mathbf{y}^{(l-1)} + b_i^{(l)} = \sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)}.$$

$R_{r_i^{(l)}}$ is the ranking function, that is, it returns the $r_i^{(l)}$ -th smallest entry of the $\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}$ vector, denoted as $(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)})_{(r_i^{(l)})}$ according to the notation we introduced earlier.




Figure 2.1: Structure of the l -th layer of the MRL network.

The parameters are:

the rank bias $\mathbf{a}_i^{(l)} \in \mathbb{R}^{N_{l-1}}$, where

$$\mathbf{a}_i^{(l)} := i\text{-th row of } A^{(l)}, \quad A^{(l)} \in \mathbb{R}^{N_l \times N_{l-1}}$$

the linear weights $\mathbf{w}_i^{(l)} \in \mathbb{R}^{N_{l-1}}$, where:

$$\mathbf{w}_i^{(l)} := i\text{-th row of } W^{(l)}, \quad W^{(l)} \in \mathbb{R}^{N_l \times N_{l-1}}$$

the bias $b_i^{(l)} \in \mathbb{R}$, and the mixing coefficient $\lambda_i^{(l)} \in [0, 1]$.

We collect them in

$$\boldsymbol{\theta}_i^{(l)} = (\mathbf{a}_i^{(l)}, \rho_i^{(l)}, \mathbf{w}_i^{(l)}, b_i^{(l)}, \lambda_i^{(l)}),$$

where the ranking parameter $r_i^{(l)} \in \{1, \dots, N_{l-1}\}$ is softly parameterized from $\rho_i^{(l)} \in \mathbb{R}$ as follows:

$$r_i^{(l)} = \left\lfloor N_{l-1} - \frac{N_{l-1} - 1}{1 + \exp(-\rho_i^{(l)})} + \frac{1}{2} \right\rfloor.$$

Unlike Pessoa and Maragos [1], where $r_i^{(l)}$ is trainable, we take it to be fixed.

Chapter 3

Nonsmooth backpropagation for MRL networks

The ranking function will be the main source of nonsmoothness in the MRL architecture. Therefore, before studying the network itself, we first study this function in isolation. In particular, we want to identify its Clarke subdifferential, since this object will later replace the usual derivative of the ranking branch in the backpropagation formulas.

The difficulty is that the ranking function is differentiable only when the selected order statistic is attained by a unique entry. When several entries are tied at the selected rank, the function is no longer differentiable. The Clarke subdifferential is used to handle such nondifferentiable operations. We first express the ranking function as a difference of convex functions to make clear that its Clarke subdifferential exists and is well defined (that is, the ranking function is locally Lipschitz continuous), and then introduce Lewis' formula [19] for its Clarke subdifferential.

3.1 Subdifferential of the ranking function

3.1.1 The ranking function as a difference of convex functions

For each integer $m \in \{0, 1, \dots, n\}$, define the function

$$S_m(t) := \max_{\substack{I \subseteq \{1, \dots, n\} \\ |I|=m}} \sum_{i \in I} t_i,$$

with the convention $S_0(t) := 0$. Notice that by construction,

$$S_m(t) = t_{(n-m+1)} + \dots + t_{(n)}.$$

and therefore the ranking function can be expressed as:

$$R_r(t) = S_{n-r+1}(t) - S_{n-r}(t).$$

Properties of S_m

The function S_m can also be written in a compact form using indicator vectors. Specifically, we have:

$$S_m(t) = \max_{\substack{I \subseteq \{1, \dots, n\} \\ |I|=m}} \langle \mathbf{1}_I, t \rangle, \quad \text{where} \quad (\mathbf{1}_I)_j = \begin{cases} 1, & j \in I, \\ 0, & j \notin I. \end{cases}$$

This representation makes several useful properties clear:

- Each individual function $t \mapsto \langle \mathbf{1}_I, t \rangle$ is affine, and thus convex.
- S_m is the maximum of affine (and thus convex) functions, so it must itself be convex.
- Since S_m is convex, it follows that it is locally Lipschitz everywhere in the interior of the domain of S_m .

3.1.2 Clarke subdifferential of the ranking function

Since we showed that R_r is the difference of two locally Lipschitz functions, it is itself locally Lipschitz as well. As such its Clarke subdifferential exists and is well defined. For the exact Clarke subdifferential, Lewis' formula [19] for order statistics gives

$$\partial_c R_r(t) = \text{co}\{e_j^\top : t_j = t_{(r)}\}.$$

Here, e_j denotes the j -th standard basis vector.

3.2 Clarke's chain rule

Having defined the ranking function, its subdifferential and the architecture of the MRL network, leveraging Clarke's chain rule(s), which we will present shortly, we can derive a nonsmooth analogue of backpropagation update rules for the training of the network.

We now present Clarke's chain rule(s) in [20].

Theorem 3.2.1 (Clarke's Chain Rule I, [20]). *Let X be a Banach space, $h = (h_1, \dots, h_n) : X \rightarrow \mathbb{R}^n$ with each h_i Lipschitz near $x \in X$, and let $g : \mathbb{R}^n \rightarrow \mathbb{R}$ be Lipschitz near $h(x)$. Set $f = g \circ h$. Identifying $(\mathbb{R}^n)^*$ with $\mathbb{R}^n$, view any $\alpha \in \partial g(h(x))$ as $\alpha = (\alpha_1, \dots, \alpha_n)$. Then f is Lipschitz near x , and*

$$\partial_c f(x) \subset \overline{\text{co}}\left\{\sum_{i=1}^n \alpha_i \zeta_i : \zeta_i \in \partial_c h_i(x), \alpha \in \partial_c g(h(x))\right\}.$$

Here, $\overline{\text{co}}$ denotes the closed convex hull.

Since we are in a (Euclidean) finite dimensional-setting, compact implies closed. The Clarke subdifferential of locally Lipschitz functions is compact. Therefore, the set being convexified in the Chain Rule I is compact as the continuous image of finite products of compact sets, hence its convex hull is compact as well, therefore closed due to the Euclidean dimensional finiteness. So we may use co instead of $\overline{\text{co}}$ from now on.

Theorem 3.2.2 (Clarke's Chain Rule II, [20]). *Let F be a map from X to another Banach space Y , and let g be a real-valued function on Y . Suppose that F is strictly differentiable at x and that g is Lipschitz near $F(x)$. Then $f = g \circ F$ is Lipschitz near x , and one has*

$$\partial_c f(x) \subset [D_s F(x)]^* \partial_c g(F(x)).$$

3.3 Nonsmooth backpropagation

For the training, we consider a labeled example $(\mathbf{x}, \mathbf{d})$ with network output $\mathbf{y} = \mathbf{y}^L$, and the squared loss function:

$$E := \|\mathbf{d} - \mathbf{y}\|_2^2 = \|\mathbf{e}\|_2^2 = \sum_{j=1}^{N_L} e_j^2.$$

where $\mathbf{e} := \mathbf{d} - \mathbf{y}$ is the error vector.

3.3.1 Helper mappings

We now define the following helper mappings that will aid us with our analysis:

$$\phi : \mathbb{R}^{N_L} \rightarrow \mathbb{R}, \quad \phi(\mathbf{u}) = \|\mathbf{d} - \mathbf{u}\|^2$$

The preactivation map

$$\mathbf{h}^{(l)} : \mathbb{R}^{N_{l-1}} \rightarrow \mathbb{R}^{N_l}, \quad \mathbf{h}^{(l)}(\mathbf{y}) = (h(\mathbf{y}; \boldsymbol{\theta}_1^{(l)}), \dots, h(\mathbf{y}; \boldsymbol{\theta}_{N_l}^{(l)}))^\top,$$

where all the network parameters $\boldsymbol{\theta}^{(l)}$ are fixed and the variable is the previous layer's activated vector $\mathbf{y}^{(l-1)}$.

The l -th layer's component wise activation map:

$$\mathbf{F}^{(l)} : \mathbb{R}^{N_l} \rightarrow \mathbb{R}^{N_l}, \quad \mathbf{F}^{(l)}(\mathbf{z}) = (f(z_1), \dots, f(z_{N_l}))^\top,$$

We define the downstream propagation map from layer l to the output layer L :

$$\mathbf{T}_l : \mathbb{R}^{N_l} \rightarrow \mathbb{R}^{N_L} \quad \mathbf{T}_l = \mathbf{F}^{(L)} \circ \mathbf{h}^{(L)} \circ \mathbf{F}^{(L-1)} \circ \mathbf{h}^{(L-1)} \circ \dots \circ \mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)}.$$

Then, we define

$$E_l : \mathbb{R}^{N_l} \rightarrow \mathbb{R}, \quad E_l(\mathbf{y}^{(l)}) = \phi(\mathbf{T}_l(\mathbf{y}^{(l)})).$$

The mapping E_l can be viewed as the original output loss E as a function of the l -th layer activation $\mathbf{y}^{(l)}$. For each coordinate i , define the one-dimensional coordinate slice:

$$\psi_i : \mathbb{R} \rightarrow \mathbb{R}, \quad \psi_i(t) := E_l(\mathbf{F}^{(l)}(z_1^{(l)}, \dots, z_{i-1}^{(l)}, t, z_{i+1}^{(l)}, \dots, z_{N_l}^{(l)})).$$

And lastly, for each coordinate i , define the affine coordinate injection

$$\mathbf{J}_i : \mathbb{R} \rightarrow \mathbb{R}^{N_l}, \quad \mathbf{J}_i(t) = \mathbf{z}^{(l)} + (t - z_i^{(l)})\mathbf{e}_i.$$

3.3.2 Error signal $\delta_i^{(l)}$

We now derive a nonsmooth analogue of the backpropagation formulas in [1]. For each parameter $\theta \in \{\mathbf{w}_i^{(l)}, \mathbf{a}_i^{(l)}, b_i^{(l)}, \lambda_i^{(l)}\}$ we derive the nonsmooth equivalent of the derivative chain rule identity:

$$\frac{\partial E}{\partial \theta} = \frac{\partial E}{\partial y_i^{(l)}} \frac{\partial y_i^{(l)}}{\partial z_i^{(l)}} \frac{\partial z_i^{(l)}}{\partial \theta}$$

Notably, in our nonsmooth setting, it will be an upper inclusion instead of an equality.

By the Clarke chain rule, choosing

$$\sigma_i^{(l)} \in \partial_c f(z_i^{(l)}), \quad \mathbf{e}^{(l)} \in -\frac{1}{2} \partial_c E_l(\mathbf{y}^{(l)}),$$

and defining

$$\delta_i^{(l)} := \sigma_i^{(l)} e_i^{(l)},$$

we obtain the nonsmooth equivalent to $\partial E / \partial y_i^{(l)} \cdot \partial y_i^{(l)} / \partial z_i^{(l)}$:

$$\partial_c \psi_i(z_i^{(l)}) \subset \text{co} \left\{ -2\delta_i^{(l)} : \sigma_i^{(l)} \in \partial_c f(z_i^{(l)}), \mathbf{e}^{(l)} \in -\frac{1}{2} \partial_c E_l(\mathbf{y}^{(l)}) \right\}. \quad (3.3.1)$$

See the Appendix B.1 for the details.

3.3.3 Parameter subgradients

Now, having derived the nonsmooth analogue of

$$\frac{\partial E}{\partial y_i^{(l)}} \frac{\partial y_i^{(l)}}{\partial z_i^{(l)}}$$

in the equation (3.3.1) above, we are in position to derive the nonsmooth analogue of

$$\frac{\partial E}{\partial \theta} = \frac{\partial E}{\partial y_i^{(l)}} \frac{\partial y_i^{(l)}}{\partial z_i^{(l)}} \frac{\partial z_i^{(l)}}{\partial \theta}, \quad \theta \in \{\mathbf{w}_i^{(l)}, \mathbf{a}_i^{(l)}, b_i^{(l)}, \lambda_i^{(l)}\}$$

In order to do that, we consider the following four helper mappings:

$$\begin{aligned} h_{\mathbf{w}_i^{(l)}} &:= h(\cdot; \mathbf{y}^{(l-1)}, \boldsymbol{\theta}_i^{(l)} / \{\mathbf{w}_i^{(l)}\}) : \mathbb{R}^{N_{l-1}} \rightarrow \mathbb{R} \\ h_{\mathbf{a}_i^{(l)}} &:= h(\cdot; \mathbf{y}^{(l-1)}, \boldsymbol{\theta}_i^{(l)} / \{\mathbf{a}_i^{(l)}\}) : \mathbb{R}^{N_{l-1}} \rightarrow \mathbb{R} \\ h_{b_i^{(l)}} &:= h(\cdot; \mathbf{y}^{(l-1)}, \boldsymbol{\theta}_i^{(l)} / \{b_i^{(l)}\}) : \mathbb{R} \rightarrow \mathbb{R} \\ h_{\lambda_i^{(l)}} &:= h(\cdot; \mathbf{y}^{(l-1)}, \boldsymbol{\theta}_i^{(l)} / \{\lambda_i^{(l)}\}) : \mathbb{R} \rightarrow \mathbb{R}. \end{aligned}$$

We apply Clarke's Chain Rule I to

$$g = E_l \circ \mathbf{F}^{(l)} \circ \mathbf{J}_i : \mathbb{R} \rightarrow \mathbb{R}$$

and h taken to be each of the four mappings above. The various h helper mappings above are the preactivation of neuron i in layer l viewed as a function of the network's parameter of our choosing (the one we take the "derivative" with respect to) while all the other parameters and the $l-1$ layer's activation vector $\mathbf{y}^{(l-1)}$ are taken to be fixed.

We obtain the inclusions

$$\partial_c(g \circ h_\theta)(\theta) \subset \text{co} \{ \alpha \zeta_\theta : \zeta_\theta \in \partial_c h_\theta(\theta), \alpha \in \partial_c g(h_\theta(\theta)) \}, \quad \theta \in \{ \mathbf{w}_i^{(l)}, \mathbf{a}_i^{(l)}, b_i^{(l)}, \lambda_i^{(l)} \}. \quad (3.3.2)$$

Since $h_\theta(\theta) = z_i^{(l)}$, equation (3.3.1) gives

$$\partial_c g(z_i^{(l)}) \subset \text{co} \{ -2\delta_i^{(l)} \},$$

therefore

$$\partial_c(g \circ h_\theta)(\theta) \subset \text{co} \{ -2\delta_i^{(l)} \zeta_\theta : \zeta_\theta \in \partial_c h_\theta(\theta) \}. \quad (3.3.3)$$

It remains to compute the Clarke subdifferentials $\partial_c h_\theta(\theta)$ of the helper mappings, i.e. the nonsmooth equivalent of the local derivatives¹. We derive them in the Appendix B.2 and obtain:

$$\begin{aligned} \partial_c(g \circ h_{\mathbf{w}_i^{(l)}})(\mathbf{w}_i^{(l)}) &\subset \text{co} \{ -2\delta_i^{(l)}(1 - \lambda_i^{(l)})(\mathbf{y}^{(l-1)})^\top \} \\ \partial_c(g \circ h_{\mathbf{a}_i^{(l)}})(\mathbf{a}_i^{(l)}) &\subset \text{co} \{ -2\delta_i^{(l)}\lambda_i^{(l)}\zeta, \zeta \in \partial_c R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}) \} \\ \partial_c(g \circ h_{b_i^{(l)}})(b_i^{(l)}) &\subset \text{co} \{ -2\delta_i^{(l)}(1 - \lambda_i^{(l)}) \} \\ \partial_c(g \circ h_{\lambda_i^{(l)}})(\lambda_i^{(l)}) &\subset \text{co} \{ -2\delta_i^{(l)}(\alpha_i^{(l)} - \beta_i^{(l)}) \}, \end{aligned}$$

where, from the previous subsection:

$$\partial_c R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}) = \text{co} \{ \mathbf{e}_k^\top : y_k^{(l-1)} + A_{ik}^{(l)} = (\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)})_{(r_i^{(l)})} \}$$

3.3.4 Backward error recursion

It remains to determine a backward error quantity that, ideally, would satisfy

$$\mathbf{e}^{(l)} \in -\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)}).$$

However, since the Clarke chain rules used in our derivation generally yield set inclusions rather than equalities, we cannot in general compute this Clarke subdifferential exactly. Instead, we derive an upper estimate of $-1/2\partial_c E_l(\mathbf{y}^{(l)})$ and use it to define the backward recursion.

From the Appendix B.3, we have:

$$\partial_c E_l(\mathbf{y}^{(l)}) \subset \text{co} \left\{ \sum_{j=1}^{N_{l+1}} -2\delta_j^{(l+1)} \mathbf{v}_j^{(l+1)} : \mathbf{e}^{(l+1)} \in -\frac{1}{2}\partial_c E_{l+1}(\mathbf{y}^{(l+1)}), \mathbf{v}_j^{(l+1)} \in \partial_c h_{\theta_j^{(l+1)}}(\mathbf{y}^{(l)}), \sigma_j^{(l+1)} \in \partial_c f(z_j^{(l+1)}) \right\} \quad (3.3.4)$$

with (see Appendix, section B.4):

$$\partial_c h_{\theta_j^{(l+1)}}(\mathbf{y}^{(l)}) = \lambda_j^{(l+1)} \text{co} \{ \mathbf{e}_j^\top : (\mathbf{y}^{(l)} + \mathbf{a}_j^{(l+1)})_j = (\mathbf{y}^{(l)} + \mathbf{a}_j^{(l+1)})_{(r_j^{(l+1)})} \} + (1 - \lambda_j^{(l+1)})(\mathbf{w}_j^{(l+1)})^\top$$

¹Local derivatives are what is commonly called the derivative of the preactivation wrt to the network's parameters.

We emphasize that the set on the right-hand side of (3.3.4) is an upper estimate of the Clarke sub-differential. Therefore, an arbitrary element selected from this set is not necessarily itself a Clarke subgradient.

Thus, for each $j = 1, \dots, N_{l+1}$, choose

$$\mathbf{c}_j^{(l+1)} \in \partial_c R_{r_j^{(l+1)}} \left(\mathbf{y}^{(l)} + \mathbf{a}_j^{(l+1)} \right).$$

Then

$$\mathbf{v}_j^{(l+1)} = \lambda_j^{(l+1)} \mathbf{c}_j^{(l+1)} + (1 - \lambda_j^{(l+1)}) (\mathbf{w}_j^{(l+1)})^\top \in \partial_c h_{\theta_j^{(l+1)}} (\mathbf{y}^{(l)}).$$

Therefore, for the backward recursion, having now specified $\mathbf{v}_j^{(l+1)}$ we select $\mathbf{e}^{(l)}$ from the upper estimate in (3.3.4):

$$\mathbf{e}^{(l)} \in \text{co} \left\{ \sum_{j=1}^{N_{l+1}} \delta_j^{(l+1)} \left[\lambda_j^{(l+1)} \mathbf{c}_j^{(l+1)} + (1 - \lambda_j^{(l+1)}) (\mathbf{w}_j^{(l+1)})^\top \right] \right\}.$$

Equivalently, componentwise,

$$e_i^{(l)} \in \text{co} \left\{ \sum_{j=1}^{N_{l+1}} \delta_j^{(l+1)} \left[\lambda_j^{(l+1)} c_{ji}^{(l+1)} + (1 - \lambda_j^{(l+1)}) W_{ji}^{(l+1)} \right] \right\}.$$

For the output layer, we have that

$$E_L(\mathbf{y}^{(L)}) = \|\mathbf{d} - \mathbf{y}^{(L)}\|^2,$$

hence

$$\partial_c E_L(\mathbf{y}^{(L)}) = \{-2(\mathbf{d} - \mathbf{y}^{(L)})\}.$$

Thus, starting from

$$\mathbf{e}^{(L)} = \mathbf{d} - \mathbf{y}^{(L)},$$

the hidden-layer quantities $\mathbf{e}^{(l)}$ are obtained by backward recursion from the inclusion above, and the corresponding $\delta_i^{(l)} = \sigma_i^{(l)} e_i^{(l)}$, with $\sigma_i^{(l)} \in \partial_c f(z_i^{(l)})$, are then used in the parameter update directions.

It should be noted that the recursively selected vectors $\mathbf{e}^{(l)}$, and consequently the resulting parameter-update directions, are not generally guaranteed to be elements of the corresponding exact Clarke subdifferentials as noted above.

Chapter 4

Mean field analysis of MRL networks at initialization

After deriving a nonsmooth analogue of backpropagation for the training of the MRL network, we’ve now reached the main contribution of this thesis, namely, the mean field analysis of the MRL network at (random) initialization.

Our goal in this chapter is to understand how signals propagate forward and backward through a deep MRL network at initialization, in order to identify initialization variances of the network parameters, $W_{ij}^{(l)}, A_{ij}^{(l)}, b_i^{(l)}$, for which the network remains trainable at large depths. We follow closely Poole et al.’s [21] and Schoenholz et al.’s [4] work, that is, working in the infinite width limit and leveraging a Gaussian ansatz for the preactivations, we derive deterministic recursive relations for the single input variance and the two input correlation of the preactivations. The rate at which the recursive relations converge to their fixed points defines the *forward depth scales*.

For the backward propagation, the scale of fluctuations of the gradients of the weights in a layer is proportional to the second moment of the derivative of the loss with respect to the preactivations of that layer. The recursive relation for this second moment is linear, and so the gradients either explode or vanish exponentially with depth. The rate of this exponential is exactly the *backward depth scale*. Schoenholz et al. claim in [4] that these two depth scales indicate the order of maximum depth of a network before training collapses. What is notable is that in the standard feedforward network case these two scales diverged to infinity for the same initializations while in the MRL network that is no longer true. We will see that later on, in subsection 4.2.6.

Now, to derive the recursive relations mentioned above, we of course have to also keep track of the statistics of the ranking branch. But, the ranking branch couples its coordinates, and as such, the preactivations of the network beyond the first layer are no longer iid. Since most classical order statistic theorems ask for iidness, we no longer have access to them, and as such, we cannot keep track of the full distribution of the ranking branch’s preactivations through depth. Instead we can find its mean and identify the order of its second moment statistics. The second allows us later on to identify a setting in which the linear branch dominates the second moment statistics in the MRL network and it is in that setting that we work for the rest of the chapter. We call this regime the *linear* regime of the MRL networks.

To get a better understanding of the ranking branch, we first analyze pure ranking networks before turning to hybrid MRL networks. This is done in sections 4.1 and 4.2 respectively, with the latter also containing the fixed point and depth scale analysis described above.

4.1 Pure ranking networks as a preliminary analysis

4.1.1 Model definition and assumptions

As a preliminary, we consider a pure ranking network, the morphological/rank neural network as it was introduced in [3] by Pessoa and Maragos, a feedforward network with L layers and layer widths $N_1, \dots, N_L$.

Let $f : \mathbb{R} \rightarrow \mathbb{R}$ be a scalar activation function, such as ReLU, tanh etc. Then, for each layer $l = 1, \dots, L$:

$$\mathbf{y}^{(l)} = (f(\alpha_1^{(l)}), \dots, f(\alpha_{N_l}^{(l)}))^\top, \quad \alpha_i^{(l)} = R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}), \quad i = 1, \dots, N_l,$$

where $\mathbf{y}^{(l-1)} \in \mathbb{R}^{N_{l-1}}$, $\alpha_i^{(l)} \in \mathbb{R}$ and

$$\mathbf{a}_i^{(l)} := i\text{-th row of } A^{(l)}, \quad A^{(l)} \in \mathbb{R}^{N_l \times N_{l-1}}$$

The rank parameter $r_i^{(l)} \in \{1, \dots, N_{l-1}\}$ is softly parameterized from $\rho_i^{(l)} \in \mathbb{R}$ as follows:

$$r_i^{(l)} = \left\lfloor N_{l-1} - \frac{N_{l-1} - 1}{1 + \exp(-\rho_i^{(l)})} + \frac{1}{2} \right\rfloor$$

Since we will study a randomly initialized neural network we suppose the ranking bias follows:

$$A_{ij}^{(l)} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_a^2), \quad 1 \leq i \leq N_l, \quad 1 \leq j \leq N_{l-1},$$

independently across i, j, l .

Let $\mathbf{X}_i^{(l)} \in \mathbb{R}^{N_{l-1}}$ be defined entrywise by:

$$(X_i^{(l)})_j = y_j^{(l-1)} + A_{ij}^{(l)}, \quad j \in \{1, \dots, N_{l-1}\}$$

Thus, in order statistic notation:

$$R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}) = (X_i^{(l)})_{(r_i^{(l)})}.$$

In the mean-field regime, we have that $N_{l-1} \rightarrow \infty, \forall l \in \{1, \dots, L\}$. For asymptotic analysis, we take the width N_{l-1} as varying but take the rank parameters $\rho_i^{(l)} \in \mathbb{R}$ to be fixed with respect to width.

4.1.2 Mean and variance of the pure-ranking network

First layer: theorem-level approximation

For the first layer, that is $l = 1$:

$$(X_i^{(1)})_j = y_j^{(0)} + A_{ij}^{(1)}, \quad j \in \{1, \dots, N_0\}$$

and

$$\alpha_i^{(1)} = R_{r_i^{(1)}}(\mathbf{y}^{(0)} + \mathbf{a}_i^{(1)}) = (X_i^{(1)})_{(r_i^{(1)})}, \quad \forall i \in \{1, \dots, N_1\}$$

We recall the classical central order asymptotic theorem from [22]:

Theorem 4.1.1 (Asymptotic distribution of central order statistics [22, theorem 10.3]). *Let $X_1, \dots, X_n$ be i.i.d. with distribution function F and density f . Let $0 < p < 1$, and assume that*

$$\frac{r}{n} - p = o(n^{-1/2}),$$

and

$$0 < f(\xi_p) < \infty, \quad \text{where } \xi_p = F^{-1}(p).$$

Then

$$n^{1/2}(X_{(r)} - \xi_p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{f(\xi_p)^2}\right).$$

We make the following assumptions:

- The entries of the input $\mathbf{y}^{(0)}$ are i.i.d., that is the sequence $\{y_i^{(0)}\}_{i=1}^{N_0}$ is i.i.d.
- $y_j^{(0)}$ is independent of $A_{ij}^{(1)}$ across j .

Under these assumptions, the entries $\{(X_i^{(1)})_j\}_{j=1}^{N_0}$ are i.i.d.

The appendix (see C.1.2) shows that the $F_{(X_i^{(1)})_j}$ marginal c.d.f. of $(X_i^{(1)})_j$, that is for a fixed coordinate j , is:

$$F_{(X_i^{(1)})_j}(x) = \mathbb{P}\left((X_i^{(1)})_j \leq x\right) = \mathbb{E}\left[\Phi\left(\frac{x - y_j^{(0)}}{\sigma_a}\right)\right] \quad (4.1.2)$$

Moreover, the dominated convergence theorem conditions hold (see the appendix, C.1.3) and thus the marginal density is:

$$f_{(X_i^{(1)})_j}(x) = \frac{d}{dx} F_{(X_i^{(1)})_j}(x) = \mathbb{E}\left[\frac{1}{\sigma_a} \phi\left(\frac{x - y_j^{(0)}}{\sigma_a}\right)\right]$$

In particular, from the strict positivity and the boundedness of the gaussian density:

$$0 < f_{(X_i^{(1)})_j}(x) \leq \frac{1}{\sigma_a \sqrt{2\pi}}, \quad x \in \mathbb{R}.$$

Since theorem 4.1.1 holds for any $p \in (0, 1)$, to fulfill that condition it suffices if we choose:

$$p_i^{(l)} := 1 - \sigma(\rho_i^{(l)}), \quad \forall l \in \{1, \dots, L\}$$

And it can be proven (see the appendix, C.1.1) that:

$$\frac{r_i^{(1)}}{N_0} - p_i^{(1)} = o(N_0^{-1/2})$$

Therefore all the assumptions of the classical theorem hold, by applying it we get

$$\sqrt{N_0}(\alpha_i^{(1)} - \xi_i^{(1)}) \xrightarrow{d} \mathcal{N}\left(0, \frac{p_i^{(1)}(1 - p_i^{(1)})}{f_{(X_i^{(1)})_j}^2(\xi_i^{(1)})}\right),$$

thus, for large but finite N_0 , we use the theorem-level approximation

$$\alpha_i^{(1)} \approx \mathcal{N}\left(\xi_i^{(1)}, \frac{p_i^{(1)}(1 - p_i^{(1)})}{N_0 f_{(X_i^{(1)})_j}^2(\xi_i^{(1)})}\right), \quad i \in \{1, \dots, N_1\}.$$

where

$$F_{(X_i^{(1)})_j}(\xi_i^{(1)}) = p_i^{(1)}.$$

This gives us an approximation to the mean value and variance of the i -th preactivation (of the first layer):

$$\mathbb{E}[\alpha_i^{(1)}] \approx \xi_i^{(1)} \text{ and } \text{Var}(\alpha_i^{(1)}) \approx \frac{p_i^{(1)}(1 - p_i^{(1)})}{N_0 f_{(X_i^{(1)})_j}^2(\xi_i^{(1)})}.$$

From now on, we will assume a common $\rho^{(l)}$ parameter within each layer in order for the preactivations $\{\alpha_i^{(l)}\}_{i=1}^{N_l}$ to be identically distributed per layer, specifically we take

$$\rho_i^{(l)} = \rho^{(l)}, \quad i \in \{1, \dots, N_l\}, \quad l \in \{1, \dots, L\}.$$

As a consequence of that, all neurons in layer l share the same induced rank $r^{(l)}$ and the same quantile level $p^{(l)}$. Now, let $i, k \in \{1, \dots, N_l\}$ with $i \neq k$. Since the rows $\mathbf{a}_i^{(l)}$ and $\mathbf{a}_k^{(l)}$ are identically distributed from the fact that $A_{ij}^{(l)} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_a^2)$, and both neurons apply the same ranking function $R_{r^{(l)}}$ to the same previous-layer random vector $\mathbf{y}^{(l-1)}$, we have

$$R_{r^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}) \stackrel{d}{=} R_{r^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_k^{(l)}).$$

which means

$$\alpha_i^{(l)} \stackrel{d}{=} \alpha_k^{(l)}.$$

Beyond the first layer: order approximation

For layers $l \geq 2$, we have

$$(X_i^{(l)})_j = y_j^{(l-1)} + A_{ij}^{(l)} = f(\alpha_j^{(l-1)}) + A_{ij}^{(l)}$$

Previously, for $l = 1$, the coordinates $\{(X_i^{(1)})_j\}_{j=1}^{N_0}$ that entered the ranking function were iid under the assumptions on the input vector's entries, and since all the other conditions held, the central order theorem applied directly to the first layer preactivations.

Now, for $l \geq 2$ the situation differs. The coordinates entering the ranking operation $\{(X_i^{(l)})_j\}_{j=1}^{N_{l-1}}$ are in general not iid. Under the common- ρ assumption, they have the same marginal distribution across j , but they are generally dependent. This is because their distribution depends on the previous layer's realized vector $\mathbf{y}^{(l-1)}$. To see this:

For $j \neq k$,

$$(X_i^{(l)})_j = f(\alpha_j^{(l-1)}) + A_{ij}^{(l)}, \quad (X_i^{(l)})_k = f(\alpha_k^{(l-1)}) + A_{ik}^{(l)} \quad (y_j^{(l-1)} = f(\alpha_j^{(l-1)}))$$

$A_{ij}^{(l)}$ and $A_{ik}^{(l)}$ are independent but $\alpha_j^{(l-1)}$ and $\alpha_k^{(l-1)}$ are not since they share the r.v. $\mathbf{y}^{(l-2)}$:

$$\alpha_j^{(l-1)} = R_{r^{(l-1)}}(\mathbf{y}^{(l-2)} + \mathbf{a}_j^{(l-1)}), \quad \alpha_k^{(l-1)} = R_{r^{(l-1)}}(\mathbf{y}^{(l-2)} + \mathbf{a}_k^{(l-1)}).$$

Moreover, for $l \geq 2$, the marginal distribution of a coordinate entering the ranking operator is width-dependent. Indeed,

$$F_N^{(l)}(x) = \mathbb{P}\left((X_i^{(l)})_j \leq x\right) = \mathbb{E}\left[\Phi\left(\frac{x - f(\alpha_j^{(l-1)})}{\sigma_a}\right)\right].$$

Since the law of $\alpha_j^{(l-1)}$ depends on the previous-layer width, the cdf $F_N^{(l)}$ depends on N . So, for $l \geq 2$ there's a point in defining three different cdf's:

$$\text{empirical width dependent cdf: } \hat{F}_N(x) = \frac{1}{N} \sum_{j=1}^N \mathbf{1}\{(X_i^{(l)})_j \leq x\}$$

$$\text{marginal width dependent cdf: } F_N(x) = \mathbb{P}\left((X_i^{(l)})_j \leq x\right)$$

$$\text{limiting marginal cdf: } F(x) := \lim_{N \rightarrow \infty} F_N(x)$$

By C.2.2, making use of Chebyshev's inequality, we have that

$$\hat{F}_N(x) \xrightarrow{P} F_N(x), \quad \forall x \in \mathbb{R}$$

and by C.2.3, assuming that $\alpha_j^{(l-1)} \xrightarrow{P} \xi^{(l-1)}$ we have that

$$F_N(x) \rightarrow F(x), \quad \forall x \in \mathbb{R}$$

where $F(x)$ is proven to be:

$$F(x) = \mathbb{P}(f(\xi^{(l-1)}) + A_{ij}^{(l)} \leq x) = \Phi\left(\frac{x - f(\xi^{(l-1)})}{\sigma_a}\right) \quad (4.1.3)$$

since $A_{ij}^{(l)} \sim \mathcal{N}(0, \sigma_a^2)$. By combining the two convergences, it follows that:

$$\hat{F}_N(x) \xrightarrow{P} F(x).$$

Since F is continuous and strictly increasing at $\xi^{(l)} = F^{-1}(p^{(l)})$, the usual quantile consistency argument applies. Hence, from $\hat{F}_N(x) \xrightarrow{P} F(x)$ and $r^{(l)}/N \rightarrow p^{(l)}$,

$$\alpha_i^{(l)} = (\mathbf{X}_i^{(l)})_{(r^{(l)})} = \hat{F}_N^{-1}(r^{(l)}/N) \xrightarrow{P} F^{-1}(p^{(l)}) = \xi^{(l)}.$$

See van der Vaart [24, Sec. 21.1].

Since $\alpha_i^{(l)} \xrightarrow{P} \xi^{(l)}$, convergence of the mean follows under a mild uniform-integrability condition. In particular, it is enough to assume that for some $\delta > 0$,

$$\sup_N \mathbb{E} \left[|\alpha_i^{(l)}|^{1+\delta} \right] < \infty.$$

Under this assumption,

$$\mathbb{E}[\alpha_i^{(l)}] \rightarrow \xi^{(l)}, \quad \forall l \in \{2, \dots, L\}, i \in \{1, \dots, N_l\}$$

this motivates the following approximation:

$$\mathbb{E}[\alpha_i^{(l)}] \approx \xi^{(l)}, \quad \forall l \in \{2, \dots, L\}, i \in \{1, \dots, N_l\}.$$

Now we will turn to the variance of the i -th preactivation $\alpha_i^{(l)}$ in the l -th layer where $l \in \{2, \dots, L\}$.

It is proven in C.2.4 that if we make the following assumptions:

- the order of the empirical threshold covariance at $x = \xi^{(l)}$ is $O(1/N)$, i.e:

$$\text{Cov} \left(\mathbf{1}\{(X_i^{(l)})_j \leq \xi^{(l)}\}, \mathbf{1}\{(X_i^{(l)})_k \leq \xi^{(l)}\} \right) = O(1/N).$$

- Bahadur's representation holds even though the samples are not iid and are just weakly dependent. That is, there exists an R_N such that:

$$\alpha_i^{(l)} - \xi^{(l)} = -\frac{\hat{F}_N(\xi^{(l)}) - p^{(l)}}{(F^{(l)})'(\xi^{(l)})} + R_N, \quad R_N = o_p(N^{-1/2}),$$

- The sequence $\{NR_N^2\}_{N \geq 1}$ is uniformly integrable.




Figure 4.1: Scaled empirical variance $N\widehat{\text{Var}}(\alpha_i^{(l)})$ for the pure ranking network. The solid curves show the mean over the tested configurations, and the shaded regions show the central 50% of the results. The approximately bounded behavior across widths supports the predicted scaling $\text{Var}(\alpha_i^{(l)}) = O(1/N)$ for $l = 2, 3$.

Then:

$$\text{Var}(\alpha_i^{(l)}) = O(1/N)$$

To empirically check the variance order predicted by our approximations and assumptions, we estimate the sample variance $\widehat{\text{Var}}(\alpha_i^{(l)})$ with the neuron index i and layer l fixed, across independent random initializations of a three-layer pure ranking network for the representative neurons

$$i = 0, \quad i = \lfloor N/2 \rfloor, \quad i = N - 1.$$

We tested a grid of different activation functions, namely ReLU, tanh, and identity, and different rank levels p , namely low = 0.25, medium = 0.5, and high = 0.75. Figure 4.1 plots the scaled empirical variance

$$N\widehat{\text{Var}}(\alpha_i^{(l)})$$

aggregated over the tested activations, rank regimes, and representative neurons. The approximately horizontal curves indicate that $N\widehat{\text{Var}}(\alpha_i^{(l)})$ remains bounded as N increases, supporting our predicted order of variance.

4.1.3 Two-input covariance and correlation of the pure-ranking branch

We will now repeat what we did for the mean and variance and find the covariance between the same neuron preactivations of the same layer for different inputs $\mathbf{y}_a^{(0)}$ and $\mathbf{y}_b^{(0)}$, for $l = 1$ and $l \geq 2$. That is the covariance between:

$$\alpha_{i:a}^{(l)} = R_{r(l)}(\mathbf{y}_a^{(l-1)} + \mathbf{a}_i^{(l)}), \quad \alpha_{i:b}^{(l)} = R_{r(l)}(\mathbf{y}_b^{(l-1)} + \mathbf{a}_i^{(l)})$$

First layer: theorem-level approximation

For $l = 1$ and for a fixed neuron $i \in \{1, \dots, N_1\}$ we have the random variable pair:

$$(X_{i:a}^{(1)})_j = y_{j:a}^{(0)} + A_{ij}^{(1)}, \quad (X_{i:b}^{(1)})_j = y_{j:b}^{(0)} + A_{ij}^{(1)}$$

We now state (in our notation) the classical result on the joint asymptotic distribution of central order statistics.

Theorem 4.1.4 (Joint asymptotic distribution of central order statistics [22]). *Let (X, Y) be a bivariate parent distribution with absolutely continuous joint cdf. Let*

$$(X_1, Y_1), \dots, (X_n, Y_n)$$

be iid observations from this distribution. Denote by $X_{(r)}$ the r th order statistic of $X_1, \dots, X_n$, and by $Y_{(s)}$ the s th order statistic of $Y_1, \dots, Y_n$. For $x, y \in \mathbb{R}$, define

$$\begin{aligned} \theta_1(x, y) &= \mathbb{P}\{X \leq x, Y \leq y\}, & \theta_2(x, y) &= \mathbb{P}\{X \leq x, Y > y\}, \\ \theta_3(x, y) &= \mathbb{P}\{X > x, Y \leq y\}, & \theta_4(x, y) &= \mathbb{P}\{X > x, Y > y\}. \end{aligned}$$

Assume

$$r = \alpha n + o(n^{1/2}), \quad s = \beta n + o(n^{1/2}), \quad 0 < \alpha, \beta < 1.$$

Let ξ_α and η_β denote the associated population quantiles of X and Y , respectively, so that

$$F_X(\xi_\alpha) = \alpha, \quad F_Y(\eta_\beta) = \beta.$$

Suppose the first partial derivatives of $\theta_j(x, y)$, $j = 1, \dots, 4$, are continuous at (ξ_α, η_β) . Assume also that

$$f_X(\xi_\alpha) \neq 0, \quad f_Y(\eta_\beta) \neq 0,$$

where f_X and f_Y are the marginal densities of X and Y . Then the asymptotic joint distribution of

$$n^{1/2}(X_{(r)} - \xi_\alpha), \quad n^{1/2}(Y_{(s)} - \eta_\beta)$$

is bivariate normal with zero means, $\alpha(1 - \alpha)/[f_X(\xi_\alpha)]^2$ and $\beta(1 - \beta)/[f_Y(\eta_\beta)]^2$ as variances, and correlation coefficient

$$\frac{\pi_1 - \alpha\beta}{[\alpha(1 - \alpha)\beta(1 - \beta)]^{1/2}},$$

where

$$\pi_1 = \mathbb{P}(X \leq \xi_\alpha, Y \leq \eta_\beta).$$

In a similar fashion to the mean and variance analysis we make the following assumptions:

- The coordinate pairs $\{(y_{j:a}^{(0)}, y_{j:b}^{(0)})\}_{j=1}^{N_0}$ are iid and moreover, are sampled from a joint absolutely continuous distribution.
- $(y_{j:a}^{(0)}, y_{j:b}^{(0)})$ are independent of $A_{ij}^{(1)}$ across j .
- Finally, we assume the local regularity condition required by the theorem, that is that the first partial derivatives of the corresponding θ_j 's are continuous at the relevant quantiles.

Under these assumptions, the pairs $\{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j\}_{j=1}^{N_0}$ are iid and their joint density is absolutely continuous as well.

From Appendix C.1.2 we proved that the marginal cdf for each $(X_{i:c}^{(1)})_j$ is:

$$F_{(X_{i:c}^{(1)})_j}(x) = \mathbb{E} \left[\Phi \left(\frac{x - y_{j:c}^{(0)}}{\sigma_a} \right) \right], \quad c \in \{a, b\}$$

For the joint marginal cdf, since they share the ranking bias weights we have that (see the Appendix C.3.1):

$$F_{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j}(x_1, x_2) = \mathbb{E} \left[\Phi \left(\frac{\min\{x_1 - y_{j:a}^{(0)}, x_2 - y_{j:b}^{(0)}\}}{\sigma_a} \right) \right]$$

From C.1.3, the marginal densities are:

$$f_{(X_{i:c}^{(1)})_j}(x) = \mathbb{E} \left[\frac{1}{\sigma_a} \phi \left(\frac{x - y_{j:c}^{(0)}}{\sigma_a} \right) \right], \quad c \in \{a, b\}.$$

Since the Gaussian density is strictly positive, we have

$$f_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) > 0, \quad f_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)}) > 0$$

at the relevant quantiles as needed. Where $\xi_a^{(1)}, \xi_b^{(1)}$ are such that satisfy:

$$F_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) = p^{(1)} \text{ and } F_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)}) = p^{(1)}.$$

By Appendix C.1.1,

$$\frac{r^{(1)}}{N_0} - p^{(1)} = O(1/N_0).$$

Equivalently,

$$r^{(1)} = N_0 p^{(1)} + O(1) = N_0 p^{(1)} + o(N_0^{1/2}).$$

Thus the rank condition of the theorem holds with

$$r = s = r^{(1)} \quad \text{and} \quad \alpha = \beta = p^{(1)}.$$

By applying the joint asymptotic distribution theorem 4.1.4 since all the assumptions hold we get:

$$\sqrt{N_0} \begin{pmatrix} \alpha_{i:a}^{(1)} - \xi_a^{(1)} \\ \alpha_{i:b}^{(1)} - \xi_b^{(1)} \end{pmatrix} \xrightarrow{d} \mathcal{N} \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \Sigma^{(1)} \right),$$

where

$$\Sigma^{(1)} = \begin{pmatrix} \frac{p^{(1)}(1-p^{(1)})}{f_{(X_{i:a}^{(1)})_j}^2(\xi_a^{(1)})} & \frac{F_{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j}(\xi_a^{(1)}, \xi_b^{(1)}) - (p^{(1)})^2}{f_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) f_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)})} \\ \frac{F_{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j}(\xi_a^{(1)}, \xi_b^{(1)}) - (p^{(1)})^2}{f_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) f_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)})} & \frac{p^{(1)}(1-p^{(1)})}{f_{(X_{i:b}^{(1)})_j}^2(\xi_b^{(1)})} \end{pmatrix}.$$

Thus, for large but finite N_0 , we use the theorem level approximation:

$$\text{Cov} \left(\alpha_{i:a}^{(1)}, \alpha_{i:b}^{(1)} \right) \approx \frac{F_{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j}(\xi_a^{(1)}, \xi_b^{(1)}) - (p^{(1)})^2}{N_0 f_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) f_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)})}.$$

Beyond the first layer: order approximation

For the first layer, the coordinate pairs

$$\left\{ \left((X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j \right) \right\}_{j=1}^{N_0}$$

are iid under the assumptions on the input coordinate pairs and the ranking biases. This is what allowed us to apply the joint central order-statistic theorem of David and Nagaraja.

For $l \geq 2$, the coordinate pairs entering the two ranking operations are no longer iid across width as we proved previously.

As such, the coordinate pairs

$$\left((X_{i:a}^{(l)})_j, (X_{i:b}^{(l)})_j \right)$$

are not iid across j . Therefore the David–Nagaraja joint order-statistic theorem cannot be applied directly beyond the first layer.

It is proven in C.3.2 that if we make the following assumptions (analogous to the assumptions we made to derive the order of the variance of the preactivations for $l \geq 2$):

- The order of the empirical threshold covariance for different inputs is $O(1/N)$, that is:

$$\text{Cov} \left(\mathbf{1}\{(X_{i:a}^{(l)})_j \leq x_1\}, \mathbf{1}\{(X_{i:b}^{(l)})_k \leq x_2\} \right) = O(1/N), \quad j \neq k$$

- The Bahadur representation holds even though the samples are weakly dependent, that is:

$$\alpha_{i:c}^{(l)} - \xi_c^{(l)} = -\frac{\widehat{F}_{N,c}(\xi_c^{(l)}) - p^{(l)}}{(F_c^{(l)})'(\xi_c^{(l)})} + R_{N,c}, \quad R_{N,c} = o_p(N^{-1/2}), \quad \forall c \in \{a, b\}$$

- The sequence $\{NR_{N,c}^2\}_{N \geq 1}$ is uniformly integrable for each $c \in \{a, b\}$.

Then we get that:

$$\text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) = O(1/N), \quad l \geq 2$$

Analogously to what we did for the variance for $l \geq 2$, to empirically check the covariance order predicted by our approximations and assumptions, we estimate the sample covariance

$$\widehat{\text{Cov}}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)})$$

with the neuron index i , layer l , and input pair $(\mathbf{y}_a^{(0)}, \mathbf{y}_b^{(0)})$ fixed, across independent random initializations of a three-layer pure ranking network for the representative neurons

$$i = 0, \quad i = \lfloor N/2 \rfloor, \quad i = N - 1.$$




Figure 4.2: Scaled empirical covariance $N\widehat{\text{Cov}}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)})$ for the pure ranking network. The solid curves show the mean over the tested configurations, and the shaded regions show the central 50% of the results. The approximately bounded behavior across widths supports the predicted scaling $\text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) = O(1/N)$ for $l = 2, 3$.

Following the variance experiment, we tested a grid of different activation functions, namely ReLU, tanh, and identity, and different rank levels p , namely low = 0.25, medium = 0.5, and high = 0.75. Figure 4.2 plots the scaled empirical covariance

$$N\widehat{\text{Cov}}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)})$$

aggregated over the tested activations, rank regimes, and representative neurons. The approximately horizontal curves across widths are consistent with the predicted scaling

$$\text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) = O(1/N)$$

for $l = 2, 3$.

4.2 Hybrid MRL neural networks

We now turn to the main scope of the thesis, the analysis of the MRL network at initialization.

4.2.1 Model definition

We briefly remind the reader the architecture of the MRL networks. We consider a feed-forward network with L layers and layer widths $N_1, \dots, N_L$. For each layer $l = 1, \dots, L$:

$$\mathbf{y}^{(l)} = (f(z_1^{(l)}), \dots, f(z_{N_l}^{(l)}))^\top, \quad z_i^{(l)} = \lambda_i^{(l)} \alpha_i^{(l)} + (1 - \lambda_i^{(l)}) \beta_i^{(l)}$$

with

$$\alpha_i^{(l)} = R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}), \quad \beta_i^{(l)} = \sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)}$$

where $\mathbf{y}^{(l-1)} \in \mathbb{R}^{N_{l-1}}$, $z_i^{(l)}, b_i^{(l)} \in \mathbb{R}$, $W^{(l)} \in \mathbb{R}^{N_l \times N_{l-1}}$ and

$$\mathbf{a}_i^{(l)} = i\text{-th row of } A^{(l)}, \quad A^{(l)} \in \mathbb{R}^{N_l \times N_{l-1}}.$$

As in the pure ranking nn, $r_i^{(l)} \in \{1, \dots, N_{l-1}\}$ is softly parameterized from $\rho_i^{(l)}$ as follows:

$$r_i^{(l)} = \left\lfloor N_{l-1} - \frac{N_{l-1} - 1}{1 + \exp(-\rho_i^{(l)})} + 1/2 \right\rfloor$$

As in the pure ranking analysis, we take a common ρ per layer, that is

$$\rho_i^{(l)} = \rho^{(l)}, \quad \forall l \in \{1, \dots, L\}, i \in \{1, \dots, N_l\}$$

this also implies $r_i^{(l)} = r^{(l)}, \forall l \in \{1, \dots, L\}, i \in \{1, \dots, N_l\}$.

We are studying a randomly initialized neural network so we take the weights to be sampled as follows:

$$\begin{aligned} A_{ij}^{(l)} &\stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_a^2) \\ W_{ij}^{(l)} &\stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_w^2 / N_{l-1}) \\ b_i^{(l)} &\stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_b^2). \end{aligned}$$

We also assume that $A^{(l)}$, $W^{(l)}$, and $b^{(l)}$ are mutually independent and iid across widths.

We take $\lambda_i^{(l)}$ to be deterministic and common across layers and neurons, that is

$$\lambda_i^{(l)} = \lambda \quad \forall l \in \{1, \dots, L\}, i \in \{1, \dots, N_l\}$$

Moreover, the common ρ per layer leads to a common quantile level $p_i^{(l)} = p^{(l)}, \forall l \in \{1, \dots, L\}$, given that we define $p_i^{(l)}$ to be:

$$p_i^{(l)} := 1 - \sigma(\rho_i^{(l)})$$

so since $\rho_i^{(l)} = \rho^{(l)}$ we get:

$$p_i^{(l)} = p^{(l)} = 1 - \sigma(\rho^{(l)}), \quad \forall l \in \{1, \dots, L\}, i \in \{1, \dots, N_l\}$$

By C.1.1 in the appendix, we have that for this choice of $p^{(l)}$:

$$r^{(l)} / N_{l-1} - p^{(l)} = o(N_{l-1}^{-1/2})$$

as is needed for the ranking branch theorems.

4.2.2 Mean field approximation

We follow Schoenholz et al. in [4], we take the “mean-field” approximation, that is replacing $z_i^{(l)}$ by a Gaussian whose first two moments match those of $z_i^{(l)}$. Specifically, we take:

$$z_i^{(l)} \sim \mathcal{N}(\mu^{(l)}, q^{(l)})$$

For the remainder of this thesis we will take the mean field approximation as given.

4.2.3 Mean and variance

First layer

For the mean of the i -th preactivation in the first layer, from C.4.1, we have that:

$$\mathbb{E}[z_i^{(1)}] = \lambda \mathbb{E}[\alpha_i^{(1)}] = \lambda \mathbb{E}[R_{r^{(1)}}(\mathbf{y}^{(0)} + \mathbf{a}_i^{(1)})]$$

but, using the notation from subsection 4.1.2

$$R_{r^{(1)}}(\mathbf{y}^{(0)} + \mathbf{a}_i^{(1)}) = (X_i^{(1)})_{(r^{(1)})}$$

As in the pure-ranking first-layer analysis, we assume that the entries of $\mathbf{y}^{(0)}$ are i.i.d. and that $y_j^{(0)}$ is independent of $A_{ij}^{(1)}$ across j .

Then the entries $\{(X_i^{(1)})_j\}_{j=1}^{N_0}$ are iid. The exact same conditions hold as in the pure ranking case, meaning theorem 4.1.1 applies, thus we have that:

$$\sqrt{N_0}(\alpha_i^{(1)} - \xi^{(1)}) \xrightarrow{d} \mathcal{N}\left(0, \frac{p^{(1)}(1-p^{(1)})}{f_{(X_i^{(1)})_j}^2(\xi^{(1)})}\right),$$

thus, for large but finite N_0 , we use the theorem level approximation:

$$\alpha_i^{(1)} \approx \mathcal{N}\left(\xi^{(1)}, \frac{p^{(1)}(1-p^{(1)})}{N_0 f_{(X_i^{(1)})_j}^2(\xi^{(1)})}\right), \quad i \in \{1, \dots, N_1\}. \quad (4.2.1)$$

Therefore

$$\mathbb{E}[\alpha_i^{(1)}] \approx \xi^{(1)}.$$

Giving us

$$\mathbb{E}[z_i^{(1)}] \approx \lambda \xi^{(1)},$$

where

$$F_{(X_i^{(1)})_j}(\xi^{(1)}) = p^{(1)}, \text{ with } F_{(X_i^{(1)})_j}(x) = \mathbb{E}\left[\Phi\left(\frac{x - y_j^{(0)}}{\sigma_a}\right)\right].$$

Now for the variance of the i -th preactivation in the first layer, from C.4.2, we have that:

$$\text{Var}(z_i^{(1)}) = \lambda^2 \text{Var}(\alpha_i^{(1)}) + (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[(y_j^{(0)})^2] + \sigma_b^2)$$

and by using the variance in eq. (4.2.1):

$$\text{Var}(z_i^{(1)}) \approx \lambda^2 \frac{p^{(1)}(1-p^{(1)})}{N_0 f_{(X_i^{(1)})_j}^2(\xi^{(1)})} + (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[(y_j^{(0)})^2] + \sigma_b^2).$$

Beyond the first layer

Now, for $l \geq 2$ we have that:

$$z_i^{(l)} = \lambda R_{r^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}) + (1 - \lambda) \left(\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)} \right)$$

As we analyzed in the pure ranking mean and variance for $l \geq 2$, the entries of the vector $\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}$ that enter the ranking function are dependent (on the r.v. $\mathbf{y}^{(l-2)}$). As such, the central order statistic theorem 4.1.1 does not apply.

What we can prove, however, is that the ranking preactivation $\alpha_i^{(l)}$ converges in probability to $\xi^{(l)}$.

Indeed, if we assume that

$$(z_j^{(l-1)}, z_k^{(l-1)}) \xrightarrow{d} (u, v)$$

where u, v are independent copies of distribution

$$\mathcal{N}(\mu^{(l-1)}, q^{(l-1)}),$$

then, since we prove that

$$\text{Cov} \left(\mathbf{1}\{f(z_j^{(l-1)}) + A_{ij}^{(l)} \leq x\}, \mathbf{1}\{f(z_k^{(l-1)}) + A_{ik}^{(l)} \leq x\} \right) \rightarrow 0$$

in C.4.3, by C.2.2 we have that $\hat{F}_N(x) \xrightarrow{P} F_N(x)$, i.e. the empirical (width dependent) cdf converges pointwise in probability to the marginal (width dependent) cdf. By C.4.4 we have that the width marginal cdf F_N converges to the limiting marginal cdf F . Combining the two convergences, in the exact same way we did for the pure ranking nn, we have that:

$$\hat{F}_N(x) \xrightarrow{P} F(x)$$

Then, since the above holds along with the fact that $r^{(l)}/N \rightarrow p^{(l)} \in (0, 1)$, standard weak consistency of empirical quantiles gives

$$\alpha_i^{(l)} = (\mathbf{X}_i^{(l)})_{(r^{(l)})} \xrightarrow{P} F^{-1}(p^{(l)}) = \xi^{(l)}$$

Again, making the mild assumption that $\{\alpha_i^{(l)}\}_{N \geq 1}$ is uniformly integrable, we gain

$$\mathbb{E}[\alpha_i^{(l)}] \rightarrow \xi^{(l)}.$$

Allowing us the following approximation for large but finite N_{l-1} :

$$\mathbb{E}[\alpha_i^{(l)}] \approx \xi^{(l)}, \quad \forall l \geq 2.$$

Thus, giving us,

$$\mathbb{E}[z_i^{(l)}] \approx \lambda \xi^{(l)}, \quad \forall l \geq 2.$$

Now we will turn to the variance of the i -th preactivation $z_i^{(l)}$ in the l -th layer where $l \in \{2, \dots, L\}$.

Exactly like we did for the variance of the preactivation for $l \geq 2$ in the pure ranking network, if we assume that:

- the order of the empirical threshold covariance at $x = \xi^{(l)}$ is $O(1/N)$, i.e:

$$\text{Cov} \left(\mathbf{1}\{(X_i^{(l)})_j \leq \xi^{(l)}\}, \mathbf{1}\{(X_i^{(l)})_k \leq \xi^{(l)}\} \right) = O(1/N).$$

- Bahadur's representation holds even though the samples are not iid and are just weakly dependent. That is, there exists an R_N such that:

$$\alpha_i^{(l)} - \xi^{(l)} = -\frac{\widehat{F}_N(\xi^{(l)}) - p^{(l)}}{(F^{(l)})'(\xi^{(l)})} + R_N, \quad R_N = o_p(N^{-1/2}),$$

- The sequence $\{NR_N^2\}_{N \geq 1}$ is uniformly integrable.

Then:

$$\text{Var}(\alpha_i^{(l)}) = O(1/N), \quad \forall l \geq 2.$$

Now, for the linear variance from section C.4.2 in the appendix we have that

$$\text{Var}(\beta_i^{(l)}) = \sigma_w^2 \mathbb{E}[f(z_j^{(l-1)})^2] + \sigma_b^2,$$

where from the mean field assumption $z_j^{(l-1)} \sim \mathcal{N}(\mu^{(l-1)}, q^{(l-1)})$.

For the activation functions considered here, such as ReLU, tanh, and the identity, the quantity $\mathbb{E}[f^2(z_j^{(l-1)})]$ is finite and width-independent whenever $\mu^{(l-1)}$ and $q^{(l-1)}$ are finite. Hence, the linear variance is of order $O(1)$, that is

$$\text{Var}(\beta_i^{(l)}) = O(1).$$

Since we prove that the covariance between the ranking part and linear part is 0 (see C.4.2), we have that

$$\begin{aligned} \text{Var}(z_i^{(l)}) &= \lambda^2 \text{Var}(\alpha_i^{(l)}) + (1 - \lambda)^2 \text{Var}(\beta_i^{(l)}) \\ &= O(\lambda^2/N) + O((1 - \lambda)^2) \end{aligned}$$

Thus, the linear variance dominates the ranking variance when

$$1 - \lambda \gg \lambda/\sqrt{N} \tag{4.2.2}$$

Therefore for such λ that the above holds, the ranking variance will be dominated and we will be in the *linear regime*. In this regime, that is, for λ such that it satisfies (4.2.2), we can approximate the preactivation variance with:

$$\text{Var}(z_i^{(l)}) \approx (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[f(z_j^{(l-1)})^2] + \sigma_b^2), \quad \forall l \geq 2.$$

4.2.4 Two-input covariance and correlation

We will now derive a formula for the covariance and correlation between the same neuron preactivations $z_{i:a}^{(l)}, z_{i:b}^{(l)}$ given different inputs $\mathbf{y}_a^{(0)}, \mathbf{y}_b^{(0)}$ to the network.

First layer

As in the pure-ranking first layer analysis, we assume that the input coordinate pairs $\{(y_{j:a}^{(0)}, y_{j:b}^{(0)})\}_{j=1}^{N_0}$ are iid and sampled from a joint absolutely continuous distribution. We also assume that these input pairs are independent of the random weights and biases of the network along with that the local regularity condition required by theorem 4.1.4 is satisfied. Then, the exact same conditions hold as in the pure ranking network, therefore the theorem 4.1.4 applies, giving us the theorem-level approximation for finite but large enough width N_0 :

$$\text{Cov}(\alpha_{i:a}^{(1)}, \alpha_{i:b}^{(1)}) \approx \frac{F_{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j}(\xi_a^{(1)}, \xi_b^{(1)}) - (p^{(1)})^2}{N_0 f_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) f_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)})}.$$

Now by subsection C.4.5 in the appendix, we have that the covariance of the two input same neuron preactivation for general layer l is equal to:

$$\text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) = \lambda^2 \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) + (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[y_{j:a}^{(l-1)} y_{j:b}^{(l-1)}] + \sigma_b^2)$$

Using the theorem level approximation for the ranking covariance, for the first layer we have that:

$$\text{Cov}(z_{i:a}^{(1)}, z_{i:b}^{(1)}) = \lambda^2 \frac{F_{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j}(\xi_a^{(1)}, \xi_b^{(1)}) - (p^{(1)})^2}{N_0 f_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) f_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)})} + (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[y_{j:a}^{(0)} y_{j:b}^{(0)}] + \sigma_b^2)$$

where $\xi_a^{(1)}$ and $\xi_b^{(1)}$ are the marginal $p^{(1)}$ -quantiles, i.e.

$$F_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) = p^{(1)}, \quad F_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)}) = p^{(1)},$$

and the corresponding joint cdf is (see Appendix C.3.1):

$$F_{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j}(x_1, x_2) = \mathbb{E} \left[\Phi \left(\frac{\min\{x_1 - y_{j:a}^{(0)}, x_2 - y_{j:b}^{(0)}\}}{\sigma_a} \right) \right].$$

Now, the first-layer two-input correlation, by definition is given by

$$\text{Corr}(z_{i:a}^{(1)}, z_{i:b}^{(1)}) = \frac{\text{Cov}(z_{i:a}^{(1)}, z_{i:b}^{(1)})}{\sqrt{\text{Var}(z_{i:a}^{(1)}) \text{Var}(z_{i:b}^{(1)})}}.$$

Using the covariance approximation above, together with the first-layer variance theorem level approximation, we get the theorem level approximation:

$$\text{Corr}(z_{i:a}^{(1)}, z_{i:b}^{(1)}) \approx \frac{\lambda^2 \frac{F_{(X_{i:a}^{(1)})_j, (X_{i:b}^{(1)})_j}(\xi_a^{(1)}, \xi_b^{(1)}) - (p^{(1)})^2}{N_0 f_{(X_{i:a}^{(1)})_j}(\xi_a^{(1)}) f_{(X_{i:b}^{(1)})_j}(\xi_b^{(1)})} + (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[y_{j:a}^{(0)} y_{j:b}^{(0)}] + \sigma_b^2)}{\sqrt{\text{Var}(z_{i:a}^{(1)}) \text{Var}(z_{i:b}^{(1)})}},$$

where $\text{Var}(z_{i:a}^{(1)})$, $\text{Var}(z_{i:b}^{(1)})$ are known from the previous subsections.

Beyond the first layer

For $l \geq 2$ we have:

$$z_{i:a}^{(l)} = \lambda \alpha_{i:a}^{(l)} + (1 - \lambda) \beta_{i:a}^{(l)}, \quad z_{i:b}^{(l)} = \lambda \alpha_{i:b}^{(l)} + (1 - \lambda) \beta_{i:b}^{(l)}$$

where the ranking branches are equal to

$$\alpha_{i:a}^{(l)} = R_{r^{(l)}}(\mathbf{y}_a^{(l-1)} + \mathbf{a}_i^{(l)}), \quad \alpha_{i:b}^{(l)} = R_{r^{(l)}}(\mathbf{y}_b^{(l-1)} + \mathbf{a}_i^{(l)})$$

As we analyzed previously, the entries of the vector $\mathbf{y}_c^{(l-1)}, c \in \{a, b\}$ are dependent on the vector $\mathbf{y}_c^{(l-2)}, c \in \{a, b\}$. As such the coordinate pairs

$$((X_{i:a}^{(l)})_j, (X_{i:b}^{(l)})_j) = (y_{j:a}^{(l-1)} + A_{ij}^{(l)}, y_{j:b}^{(l-1)} + A_{ij}^{(l)})$$

are not iid across j , meaning we cannot apply 4.1.4 for the covariance $\text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)})$ for $l \geq 2$.

From appendix C.4.5 we have that:

$$\text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) = \lambda^2 \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) + (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[f(z_{j:a}^{(l-1)})f(z_{j:b}^{(l-1)})] + \sigma_b^2)$$

As proven in subsection 4.1.3, if we assume:

- The order of the empirical threshold covariance for different inputs is $O(1/N)$, that is:

$$\text{Cov}(\mathbf{1}\{(X_{i:a}^{(l)})_j \leq x_1\}, \mathbf{1}\{(X_{i:b}^{(l)})_k \leq x_2\}) = O(1/N), \quad j \neq k$$

- The Bahadur representation holds even though the samples are weakly dependent, that is:

$$\alpha_{i:c}^{(l)} - \xi_c^{(l)} = -\frac{\widehat{F}_{N,c}(\xi_c^{(l)}) - p^{(l)}}{(F_c^{(l)})'(\xi_c^{(l)})} + R_{N,c}, \quad R_{N,c} = o_p(N^{-1/2}), \quad \forall c \in \{a, b\}$$

- The sequence $\{NR_{N,c}^2\}_{N \geq 1}$ is uniformly integrable for each $c \in \{a, b\}$.

Then

$$\text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) = O(1/N), \quad l \geq 2$$

For the linear covariance, for the activation functions considered here, ReLU, tanh and the identity, $\mathbb{E}[f(z_{j:a}^{(l-1)})f(z_{j:b}^{(l-1)})]$ is $O(1)$ by Cauchy-Schwarz whenever $\mathbb{E}[f(z_{j:a}^{(l-1)})], \mathbb{E}[f(z_{j:b}^{(l-1)})]$ are finite and $O(1)$ as we assume them to be. Therefore:

$$\text{Cov}(\beta_{i:a}^{(l)}, \beta_{i:b}^{(l)}) = \sigma_w^2 \mathbb{E}[f(z_{j:a}^{(l-1)})f(z_{j:b}^{(l-1)})] + \sigma_b^2 = O(1)$$

Giving us:

$$\begin{aligned} \text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) &= \lambda^2 \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) + (1 - \lambda)^2 \text{Cov}(\beta_{i:a}^{(l)}, \beta_{i:b}^{(l)}) \\ &= O(\lambda^2/N) + O((1 - \lambda)^2). \end{aligned}$$

Exactly just like in the variance case, the linear covariance dominates the ranking covariance when

$$1 - \lambda \gg \lambda/\sqrt{N}$$

Therefore for such λ that the above holds, we will be in the *linear regime* and the ranking covariance will be dominated, so it suffices to approximate it by taking

$$\text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) \approx (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[f(z_{j:a}^{(l-1)})f(z_{j:b}^{(l-1)})] + \sigma_b^2), \quad \forall l \geq 2$$

Using the above approximation, we can derive the correlation

$$\text{Corr}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) = \frac{\text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)})}{\sqrt{\text{Var}(z_{i:a}^{(l)}) \text{Var}(z_{i:b}^{(l)})}} \approx \frac{\sigma_w^2 \mathbb{E}[f(z_{j:a}^{(l-1)})f(z_{j:b}^{(l-1)})] + \sigma_b^2}{\sqrt{\text{Var}(z_{i:a}^{(l)}) \text{Var}(z_{i:b}^{(l)})}},$$

where

$$\text{Var}(z_{i:c}^{(l)}) \approx (1 - \lambda)^2 \left(\sigma_w^2 \mathbb{E}[f^2(z_{j:c}^{(l-1)})] + \sigma_b^2 \right), \quad c \in \{a, b\}.$$

4.2.5 Forward depth scale

We take as a given that λ and N are such that satisfy the condition for the linear variance and covariance to dominate the ranking variance and covariance, namely:

$$1 - \lambda \gg \lambda/\sqrt{N}.$$

That is, we take λ and N to be such that we are in the *linear regime*. From now on, equality means equality under the linear-dominance approximation.

Assumption 4.2.3. *We assume a common ρ in the whole neural network, that is*

$$\rho_i^{(l)} = \rho, \quad i = 1, \dots, N_l, \quad l = 1, \dots, L,$$

This leads to

$$p_i^{(l)} = p, \quad i = 1, \dots, N_l, \quad l = 1, \dots, L.$$

Following Schoenholz et. al in [4], we consider first the evolution of a single input, $x_{i:a}$ as it evolves through the network. The mean (or the first moment) of the i -th preactivation in the l layer is:

$$\mu_a^{(l)} = \mathbb{E}[z_{i:a}^{(l)}] = \lambda \xi_a^{(l)} \quad (4.2.4)$$

where $\xi_a^{(l)}$ satisfies

$$F(\xi_a^{(l)}, \mu_a^{(l-1)}, q_{aa}^{(l-1)}) = p, \quad \text{where } F(\xi, \mu, q) = \int \Phi\left(\frac{\xi - f(\mu + \sqrt{q}z)}{\sigma_a}\right) Dz$$

where $Dz = \frac{dz}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$ is the standard Gaussian measure.

The covariance of the preactivations in the same layer is:

$$\text{Cov}(z_{i:a}^{(l)}, z_{j:a}^{(l)}) = q_{aa}^{(l)} \delta_{ij}$$

Where δ_{ij} is the Kronecker delta. The variable $q_{aa}^{(l)}$ is the variance of the i -th preactivation in the l layer. By leveraging the gaussian ansatz, it is described by the following recursive equation:

$$q_{aa}^{(l)} = \text{Var}(z_{i:a}^{(l)}) = (1 - \lambda)^2 (\sigma_w^2 \int f^2(\sqrt{q_{aa}^{(l-1)}} z + \mu_a^{(l-1)}) Dz + \sigma_b^2), \quad (4.2.5)$$

Now we consider the propagation of a pair of signals $x_{i:a}$ and $x_{i:b}$ through this network. The mean pre-activations trivially follow the same recursive equations as in the single-input case. The covariance between different pre-activations in the same layer is $\text{Cov}(z_{i:a}^{(l)}, z_{j:b}^{(l)}) = \delta_{ij} q_{ab}^{(l)}$.

The covariance $q_{ab}^{(l)}$, again, by leveraging the Gaussian ansatz is given by:

$$q_{ab}^{(l)} = \text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) = (1 - \lambda)^2 (\sigma_w^2 \int f(u_1) f(u_2) Dz_1 Dz_2 + \sigma_b^2), \quad (4.2.6)$$

where $u_1 = \mu_a^{(l-1)} + \sqrt{q_{aa}^{(l-1)}} z_1$, $u_2 = \mu_b^{(l-1)} + \sqrt{q_{bb}^{(l-1)}} (c_{ab}^{(l-1)} z_1 + \sqrt{1 - (c_{ab}^{(l-1)})^2} z_2)$, with $c_{ab}^{(l)} = q_{ab}^{(l)} / \sqrt{q_{aa}^{(l)} q_{bb}^{(l)}}$.

Fixed point analysis

Now, the iterative mean-variance map:

$$\begin{pmatrix} \mu_a^{(l)} \\ q_{aa}^{(l)} \end{pmatrix} = \begin{pmatrix} \lambda \xi_a^{(l)} \\ (1 - \lambda)^2 (\sigma_w^2 \int Dz f^2(\mu_a^{(l-1)} + \sqrt{q_{aa}^{(l-1)}} z) + \sigma_b^2) \end{pmatrix}, \quad \text{where } \xi_a^{(l)} \text{ satisfies } F(\xi_a^{(l)}, \mu_a^{(l-1)}, q_{aa}^{(l-1)}) = p \quad (4.2.7)$$

We assume that it admits a fixed point (μ^*, q^*) for any bounded f , finite $\sigma_w, \sigma_b, \sigma_a > 0$, fixed $p \in (0, 1)$.

Assuming that $\mu^{(l)}, q^{(l)}$ rapidly converge to μ^*, q^* , we can then compute the correlation fixed point c^* by setting $q_{aa}^{(l)} = q_{bb}^{(l)} = q^*$ and $\mu_a^{(l)} = \mu_b^{(l)} = \mu^*$ in eq. (4.2.6) and dividing by q^* to obtain an iterative correlation coefficient map $\mathcal{C}$ for $c_{ab}^{(l)}$:

$$c_{ab}^{(l)} = \mathcal{C}(c_{ab}^{(l-1)}, \mu^*, q^* | \sigma_w, \sigma_b, \sigma_a, \lambda, p) \equiv \frac{(1-\lambda)^2}{q^*} \left(\sigma_w^2 \int f(u_1) f(u_2) D z_1 D z_2 + \sigma_b^2 \right) \quad (4.2.8)$$

where, now, $u_1 = \mu^* + \sqrt{q^*} z_1$, $u_2 = \mu^* + \sqrt{q^*} (c_{ab}^{(l-1)} z_1 + \sqrt{1 - (c_{ab}^{(l-1)})^2} z_2)$.

By examining eq. 4.2.8 one can see that $c^* = 1$ is a fixed point of the recursive equation.

By applying the chain rule and product rule from calculus, as well as utilizing the identity

$$\int D z F(z) z = \int D z F'(z),$$

we have that:

$$\chi_1 \equiv \left. \frac{d c_{ab}^{(l)}}{d c_{ab}^{(l-1)}} \right|_{c_{ab}^{(l-1)}=1} = (1-\lambda)^2 \sigma_w^2 \int [f'(\mu^* + \sqrt{q^*} z)]^2 D z$$

The fixed point $c^* = 1$ is locally stable when $\chi_1 < 1$ and unstable when $\chi_1 > 1$. As such, $\chi_1 = 1$ represents the critical line between an ordered phase (in which all inputs end up asymptotically correlated with $c^* = 1$) and a chaotic phase (in which all inputs end up asymptotically decorrelated with $c^* < 1$).

Compared with the standard mean-field theory in [4], [21], the factor $(1-\lambda)^2$ directly damps the correlation gain, while the parameters p and σ_a enter implicitly through the fixed point (μ^*, q^*) .

Taking f to be tanh, $p = 0.75$, $\lambda = 0.2$ and $\sigma_a = 1$ we obtain the phase diagram in fig 4.3 (a).




Figure 4.3: Mean-field criticality in the MRL network. (a) The mean-field phase diagram showing the boundary between ordered and chaotic phases as a function of σ_w^2 and σ_b^2 , determined by the criticality condition $\chi_1 = 1$. (b) The difference $|\mu^{(l)} - \mu^*|$ as a function of depth on a log scale, with $\sigma_b^2 = 0.05$ and σ_w^2 varying from the ordered region toward criticality, as it approaches the critical value the curves turn from red to purple. (c) The difference $|q^{(l)} - q^*|$ as a function of depth on a log scale for the same parameter values. (d) The difference $|c_{ab}^{(l)} - c^*|$ as a function of depth on a log scale, using the same color scheme as in (b) and (c). The rapid convergence of $\mu^{(l)}$ and $q^{(l)}$ compared with the slower convergence of $c_{ab}^{(l)}$ supports the approximation of replacing $(\mu^{(l)}, q^{(l)})$ with (μ^*, q^*) in the asymptotic correlation analysis.

To validate the feedforward mean-field recurrence relations, in figure 4.4 we compare the predicted values of the second moment and two-input correlation against empirical measurements from realized finite-width MRL networks. We use the activation $f = \tanh$, ranking parameter $p = 0.75$, mixing parameter $\lambda = 0.2$, rank-noise variance $\sigma_a^2 = 1$, and bias variance $\sigma_b^2 = 0.05$. The depth is $L=240$ and each layer has width $N=1000$. The initial statistics are set to $\mu^{(0)} = 0$, $q^{(0)} = 0.8$, and $c_{ab}^{(0)} = 0.6$.

We take three choices of σ_w^2 , one for $\chi_1 < 1$ (ordered), $\chi_1 = 1$ (critical) and $\chi_1 > 1$ (chaotic). For each choice of σ_w^2 , the recursive map is iterated to produce theoretical predictions for $q^{(l)} + (\mu^{(l)})^2$ and $c_{ab}^{(l)}$. The critical value $\sigma_{w,\text{crit}}^2$ is obtained by first finding the fixed point (μ^*, q^*) of the mean and variance recursions and then choosing σ_w^2 such that $\chi_1 = 1$.




Figure 4.4: Second moment and correlation tracking for MRL networks. Solid curves denote the recursive relation predictions, while points denote the empirical measurements averaged over independent finite-width MRL network realizations with width $N = 1000$ and depth $L = 240$. Shaded bands indicate ± 1 standard error of the mean. Panel (a) shows the tracking of the second moment $q^{(l)} + (\mu^{(l)})^2$, and panel (b) shows the tracking of the two-input correlation $c_{ab}^{(l)}$. Red, purple, and blue correspond to the ordered, critical, and chaotic regimes, respectively.

Forward depth scales

We iterate eq's (4.2.4), (4.2.5) and (4.2.8) until convergence for $\sigma_b^2 = 0.05$ and multiple values for σ_w^2 from 0.5 up to the critical $\sigma_{w,\text{crit}}^2 \approx 2.7141$, starting with $\mu_a^{(0)} = \mu_b^{(0)} = 0$, $q_{aa}^{(0)} = q_{bb}^{(0)} = 0.8$ and $c_{ab}^{(0)} = 0.6$. We see in fig. 4.3 (b) - (d) that $\mu_a^{(l)}, q_{aa}^{(l)}, c_{ab}^{(l)}$ all approach their corresponding fixed point μ^*, q^*, c^* in an decaying exponential manner.

Where our analysis diverges from Schoenholz et al. in [4] is that the convergence of $q_{aa}^{(l)}$ to its fixed point q^* in our setting (fig. 4.3(c)) does not seem to slow down as σ_w^2 approaches the critical value, that is, near $\chi_1 = 1$.

This difference can be understood by noting that, in the present setting, the variance does not evolve as a 1D recurrence. Instead, the mean and variance form a coupled two-dimensional dynamical system. Thus the rate at which $q_{aa}^{(l)}$ approaches q^* (and the rate $\mu_a^{(l)}$ approaches μ^*) is controlled by the Jacobian of the coupled mean-variance map in equation (4.2.7).

If we define the perturbations

$$\eta^{(l)} = \mu_a^{(l)} - \mu^*, \quad \epsilon^{(l)} = q_{aa}^{(l)} - q^*,$$

Collecting them into a vector, then:

$$\begin{pmatrix} \eta^{(l+1)} \\ \epsilon^{(l+1)} \end{pmatrix} = \begin{pmatrix} J_{\mu\mu} & J_{\mu q} \\ J_{q\mu} & J_{qq} \end{pmatrix} \begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix} + O\left(\left\| \begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix} \right\|^2\right),$$

the entries of the Jacobian of the coupled mean-variance mapping have been derived in the Appendix subsection C.5.2. The convergence rate of the mean-variance dynamics is therefore determined by the spectral radius $\rho(J)$, rather than by just χ_1 .

This gives us that for large enough l :

$$\left\| \begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix} \right\| = \left\| \begin{pmatrix} \mu_a^{(l)} - \mu^* \\ q_{aa}^{(l)} - q^* \end{pmatrix} \right\| \sim e^{-l/\xi_{\mu,q}}.$$

where

$$\xi_{\mu,q}^{-1} = -\log \rho(J).$$

$\xi_{\mu,q}$ denotes the depth scale that controls how deep information from a sole input penetrates into a random neural network.

As to the convergence of the correlation $c_{ab}^{(l)}$, it should be noted that it follows the exact same pattern as in [4], that is, it noticeably slows down as σ_w^2 approaches the critical value.

We will now prove that asymptotically $|c_{ab}^{(l)} - c^*| \sim e^{-l/\xi_c}$ where ξ_c is the depth scale that controls how deep information from a pair input may penetrate into a random neural network. First, we analyze eq. 4.2.6, if we expand about $c_{ab}^{(l)} = c^* + \epsilon^{(l)}$, we get:

$$\epsilon^{(l+1)} = \epsilon^{(l)} \left[(1-\lambda)^2 \sigma_w^2 \int \int f'(u_1^*) f'(u_2^*) D z_1 D z_2 \right] + O\left((\epsilon^{(l)})^2\right),$$

here, $u_1^* = \mu^* + \sqrt{q^*} z_1$ and $u_2^* = \mu^* + \sqrt{q^*} [c^* z_1 + \sqrt{1 - (c^*)^2} z_2]$.

Since the mean shift μ^* is constant with respect to $c_{ab}^{(l)}$, z_1 , and z_2 it does not affect the Taylor expansion and the Gaussian integration by parts identities used in the Schoenholz derivation. As a consequence, the asymptotic recurrence relation results in the same form as in [4] with the sole modification that the fixed point preactivations u_1^* and u_2^* are shifted by μ^* .

As such, we expect for large enough l , the above recurrence will have an exponential solution, $\epsilon^{(l)} \sim e^{-l/\xi_c}$ with ξ_c given by:

$$\xi_c^{-1} = -\log \left((1-\lambda)^2 \sigma_w^2 \int \int f'(u_1^*) f'(u_2^*) D z_1 D z_2 \right) \quad (4.2.9)$$

Where in the ordered phase $c^* = 1$ and thus $\xi_c^{-1} = -\log \chi_1$.

4.2.6 Backward depth scale

Schoenholz et. al showed in [4] that in fully connected neural networks, there's a duality between the forward propagation of signals and the backpropagation of gradients, i.e. the same parameter χ_1 controlled how deep information propagates through the network both forwards and backwards. In contrast, we show that in our MRL architecture that duality is **broken**, the backward depth scale differs from the feedforward depth scale.

To obtain the gradient backpropagation depth scale we follow the work in [4].

First, consider the backpropagation equations given a loss E :

$$\frac{\partial E}{\partial W_{ij}^{(l)}} = \delta_i^{(l)} (1 - \lambda) f(z_j^{(l-1)}), \quad \delta_i^{(l)} = f'(z_i^{(l)}) \sum_j^{N_{l+1}} \delta_j^{(l+1)} \left[\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right],$$

$$\delta_i^{(l)} = \frac{\partial E}{\partial z_i^{(l)}}$$

where $S_{ji}^{(l+1)} = \mathbb{1} \left\{ (f(\mathbf{z}^{(l)}) + \mathbf{a}_j^{(l+1)})_{r(l+1)} = f(z_i^{(l)}) + A_{ji}^{(l+1)} \right\}$.

Within mean field theory, the scale of fluctuations of the gradients of weights in a layer will be proportional to $\mathbb{E}[(\delta_i^{(l)})^2]$, (see Appendix C.5.3).

By taking the additional approximation that the weights used during the forward propagation are independent with the weights used in backpropagation, we can derive (see Appendix C.5.3) a recursive relation for the variance of the error $\tilde{q}^{(l)} = \mathbb{E}[(\delta_i^{(l)})^2]$:

$$\tilde{q}_{aa}^{(l)} \approx \frac{N_{l+1}}{N_l} \chi_{\nabla} \tilde{q}_{aa}^{(l+1)},$$

where

$$\chi_{\nabla} = \chi_1 \left(\frac{\lambda^2}{(1 - \lambda)^2 \sigma_w^2} + 1 \right).$$

Notably, for $\lambda = 0$ we retrieve the recursive relation in [4].

By considering MRL networks of constant layer width, we derive:

$$\tilde{q}^{(l)} = \tilde{q}^{(L)} e^{-(L-l)/\xi_{\nabla}}$$

where

$$\xi_{\nabla}^{-1} = -\ln(\chi_{\nabla}) = -\ln(\chi_1) - \ln \left(1 + \frac{\lambda^2}{(1 - \lambda)^2 \sigma_w^2} \right).$$

As such, it follows that there are three distinct regimes for the gradient backpropagation.

- In the ordered phase, $\chi_{\nabla} < 1$, and therefore $\xi_{\nabla} > 0$. In this regime, backpropagated gradients decay exponentially with depth, so gradients are expected to vanish over layers of order $|\xi_{\nabla}|$.
- At criticality, $\chi_{\nabla} \rightarrow 1$, which implies $\xi_{\nabla} \rightarrow \infty$. Thus the exponential depth scale diverges, and gradients remain stable across arbitrarily large depths in the mean-field limit.
- In the chaotic phase, $\chi_{\nabla} > 1$, and therefore $\xi_{\nabla} < 0$. In this regime, backpropagated gradients grow exponentially with depth, so gradients are expected to explode over layers of order $|\xi_{\nabla}|$.

To empirically verify the predicted gradient-propagation behavior, we consider randomly initialized MRL networks with depth $L = 240$ and width $N_l = 300$, we take $\lambda = 0.2$, $f = \tanh$, $p = 0.75$ and for the fixed variances $\sigma_a^2 = 1$, $\sigma_b^2 = 0.05$. No training is performed. Instead, for each random network, we compute the cross-entropy loss on a minibatch of MNIST data and apply a single backward pass. Figure 4.5(a) shows the squared Frobenius norm of the gradient with respect to the weight matrix $W^{(l)}$ of each layer plotted against the layer index l for a ranging σ_w^2 . Across the range of layers, the gradient norms display a clear exponential trend. Indeed, we can see that for ordered values of σ_w^2 (red) the gradients shrink rapidly, for values close to the critical line (purple) the gradients are approximately preserved across depth and finally, for chaotic values (blue) of σ_w^2 the gradients increase rapidly.




Figure 4.5: Experimental validation of the backward gradient propagation theory in randomly initialized MRL networks. Fig (a): layerwise squared Frobenius norm $\|\nabla_{W^{(l)}} E\|_F^2$ as a function of layer index l for different values of σ_w^2 , from ordered (red) to critical (purple) and then to chaotic (blue). Fig (b): empirically measured gradient depth scale $|\xi_\nabla|$ compared with the theoretical prediction as σ_w^2 varies from ordered (to critical) to chaotic in the same way as in (a).

In Figure 4.5(b), we further test the quantitative prediction for the gradient depth scale. We compare the theoretical value of $|\xi_\nabla|$ with the empirical value measured from randomly initialized MRL networks across different values of σ_w^2 . For each choice of σ_w^2 , we compute the empirical second moment of the backpropagated preactivation gradients $\delta_i^{(l)}$ at every layer and estimate the empirical depth scale by fitting their change across depth to an exponential curve. The resulting measured values agree closely with the mean-field prediction over the range of σ_w^2 considered.

Chapter 5

Training MRL networks: experiments

Our analysis in Chapter 4 indicates that in deep MRL networks, trainability should be determined by how well signals are propagated forward (i.e. the correlation not collapsing to its fixed point) and gradients are propagated backwards (i.e. the gradients neither exploding or vanishing over depth). This is exactly the case when the network depth L is of the same order as the depth scales ξ_c and ξ_∇ . Following Schoenholz et al. in [4], we test this hypothesis by training, for each combination of depth and initialization, 5 independently seeded networks, and then plot the resulting accuracy as a function of depth and the chosen hyperparameters.




Figure 5.1: Mean MNIST training accuracy of MRL networks as a function of depth L and initial weight variance σ_w^2 , ranging from high accuracy (light red) to low accuracy (black). Panels (a) and (b) show accuracy after 200 SGD steps. In (a), white dashed curves denote multiples $n\xi_c$, while in (b), cyan dashed curves denote $n\xi_\nabla$, for $n \in \{1, 3, 6, 9\}$. Panels (c) and (d) show accuracy after 2,000 and 5,000 SGD steps, respectively, with $9\xi_c$ and $9\xi_\nabla$ overlaid. Solid white and cyan lines mark the critical initializations $\chi_1 = 1$ and $\chi_\nabla = 1$, respectively. Results are averaged across independent random seeds.

We train networks for a varying network depth $10 \leq L \leq 320$ and network weight initialization variance $1.5 \leq \sigma_w^2 \leq 4$, with ranking bias initialization variance $\sigma_a^2 = 1$, and linear initialization variance $\sigma_b^2 = 0.05$. Moreover we take the mixing coefficient to be $\lambda = 0.2$ and the ranking parameter $p = 0.75$, i.e. the ranking function returns about the $\lfloor 0.75 \cdot N \rfloor$ -th smallest entry. We take the network's layers' width to be $N = 64$. The choice of λ is deliberate and **vital**, it is so that we are inside the *linear regime*, i.e.

the linear-branch second moment statistics domination condition holds, in which our whole theoretical analysis took place.

We train the networks on the MNIST dataset (a subset of 20,000 samples) using plain stochastic gradient descent with a batch size 64. We take the learning rate to be 0.05 for $L \leq 80$, 0.01 for $80 < L \leq 160$ and finally 0.0001 for $160 < L \leq 320$. We use cross entropy loss and the training accuracy is evaluated using a batch size of 256 and over a subset of 5,000 training samples. Although our analysis strictly concerns trainability and not generalization, we include plots of the test accuracies in fig 5.2 for completeness.




Figure 5.2: Mean MNIST test accuracy of MRL networks on MNIST as a function of depth L and initial weight variance σ_w^2 , ranging from high accuracy (light blue) to low accuracy (black). Panels show the test accuracy after (a) 200, (b) 2,000, and (c) 5,000 SGD training steps. Values below approximately chance-level performance are shown in black.

In particular, the values $\sigma_{w^2, \chi_\nabla} = 2.7141$, and $\sigma_{w^2, \chi_1} = 2.8742$ are of importance to us. The first is the σ_w^2 for which the backward propagation is critical, i.e. $\chi_\nabla = 1$, and the second is the σ_w^2 for which the forward propagation is critical, i.e. $\chi_1 = 1$.

In figure 5.1 we plot the training accuracy as a function of L and σ_w^2 . As in Schoenholz et al. [4], the purpose of the plot is to compare the empirically trainable region with the theoretical depth scales.

The resulting training accuracy plots show how trainability concentrates near the critical band as depth increases. That supports our theoretical analysis. For shallow networks, a relatively wide range of σ_w^2 values can be trained. In contrast, for deeper networks, successful training becomes sensitive to initialization, and the trainable region narrows toward the predicted critical region. Therefore, we can conclude that it is not a single best value of σ_w^2 , but rather the existence of a critical band in which deep MRL networks remain trainable.

Chapter 6

Conclusions & Future work

6.1 Conclusions

In this thesis we tried to answer the question of whether the initialization theory Poole et al. and Schoenholz et al. developed for standard feedforward networks, still holds when the neurons are not purely linear but rather a (convex) combination of a linear and a ranking node. There were good reasons for us to anticipate that it would not. Namely, the ranking function is nondifferentiable, it couples coordinates of its input, and past the first layer these coordinates are no longer iid.

On the training side, the Clarke subdifferential provided us with what the ordinary derivative could not, that is, a well defined replacement for the gradient of the ranking branch, and along with it a rigorous nonsmooth backpropagation for the full MRL network.

On the initialization side, we could not track the second moment statistics of the ranking branch directly, but we could identify their order, and this was enough to isolate a setting in which the linear branch dominates. Within this setting the ranking branch enters the forward pass mainly as a deterministic mean shift, and once we take into consideration this shift, the analysis proceeds much like in Schoenholz et al., with ordered and chaotic phases and forward and backward depth scales.

The most interesting outcome is where the analogy with standard networks fails. In standard feedforward networks forward and backward criticality coincide, in MRL networks they do not. The ranking branch's contribution is nearly invisible in the forward second moment statistics but contributes directly to the backward pass through its subgradient¹, and so the two criticalities separate. A good initialization for MRL networks is therefore not near a single critical point but a balance between two distinct ones. Our experiments on MNIST are consistent with this picture. Shallow networks train over a wide range of σ_w^2 , while for deeper networks the trainable region narrows toward the band between the two critical values, exactly where both depth scales remain large.

We do not claim the picture is complete. The analysis takes place in the setting in which the linear branch dominates the second moment statistics and the ranking parameter was kept fixed and central. Whether the critical initializations found here still hold when the ranking branch contributes comparable, or even dominant, second moment statistics is, in our view, the natural next question. Still, even in the regime we studied, the ranking branch's contribution is not nonexistent. It shifts the forward first moment statistics and contributes to the backward pass enough to break the duality between the two criticalities. We hope that the tools assembled in this thesis make answering this question an approachable task.

¹To the close reader, a more accurate description would be gradient, since in the random initialization setting, the addition of the Gaussian ranking bias $\mathbf{a}_i^{(l)}$ to the vector $\mathbf{y}^{(l-1)}$ causes the entries to tie with a chance of zero, meaning the ranking function is almost surely differentiable at initialization.

6.2 Future work

A limitation of this thesis is that we take the ranking parameter $r_i^{(l)}$ to be fixed, while in the original Pessoa and Maragos paper it was trainable (through $\rho_i^{(l)}$). Moreover, we assume that its ranking is away from the extremes, i.e. the ranking function is a central order statistic. Future work could take an $r_i^{(l)}$ such that the ranking function would approach the min or max operation. In the case of the second, we would deal with an extreme order statistic which asymptotically behaves qualitatively differently from the central one we studied here. For more, see David and Nagaraja [22, Sec. 10.5].

The main limitation of this thesis is that since we did not track explicitly the second moment statistics of the ranking branch and rather identified only their order, we focused in the setting in which the second moment statistics of the linear branch dominated those of the ranking branch. A natural next step for future work would be to identify and track the ranking branch's second moment statistics. That would allow us not to impose the mixing coefficient and network width condition and consider settings in which the ranking branch contributes second moment statistics comparable to, or even dominating, the linear branch's second moment statistics. That is of great interest to us since it would answer the question whether the critical initialization conditions derived in this thesis will still hold for settings in which the linear branch does not dominate.

Finally, in our work, the same limitation as in Schoenholz et al.'s holds, namely that the theory developed here is for bounded activation functions and does not apply to unbounded ones, such as the standard ReLU.

Appendix A

Preliminary Theory

A.1 Elements of convex analysis

In this section we will introduce the necessary theory and tools used in the derivation of nonsmooth backpropagation for MRL networks in chapter 3. The main purpose is to explain how the usual gradient is extended first to convex subgradients and then to Clarke subdifferentials, which apply to locally Lipschitz but not necessarily convex functions.

Throughout this chapter $\text{dom } f$ will denote the ordinary domain of f and not the effective one as a reader familiar with convex analysis might expect.

A.1.1 Convex sets and convex hulls

We begin with some basic notions from convex analysis. Throughout this section, we work in $\mathbb{R}^d$, where $d < \infty$.

Definition A.1.1 (Convex Set). *We will call a set $C \subseteq \mathbb{R}^d$ convex, if for every pair $x, y \in C$ then*

$$(1 - \lambda)x + \lambda y \in C, \text{ where } \lambda \in [0, 1].$$

Another notion we will need is that of the *convex hull* of a set S . Intuitively, it returns the smallest convex set that contains all the points of a set S .

Definition A.1.2 (Convex hull). *The convex hull of a set of points $S \subset \mathbb{R}^d$, denoted $\text{co}(S)$, is defined as:*

$$\text{co}(S) = \left\{ \lambda_1 x_1 + \cdots + \lambda_k x_k \mid x_i \in S, \lambda_i \geq 0, i = 1, \dots, k, \sum_{i=1}^k \lambda_i = 1 \right\}$$

A.1.2 Convex functions

Having defined convex sets, we now can define what it means for a *function* to be convex.

Definition A.1.3 (Convex function). *A function $f : \text{dom } f \rightarrow \mathbb{R}$ is convex if $\text{dom } f$ is a convex set and if for all $x, y \in \text{dom } f$ and λ with $0 \leq \lambda \leq 1$, we have:*

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

We also present the first order condition for a function f to be convex, assuming of course that it's differentiable.

Definition A.1.4 (Convex function, first order condition). *Suppose f is differentiable, i.e., its gradient ∇f exists at each point in $\text{dom } f$. Then f is convex if and only if $\text{dom } f$ is convex and*

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

holds for all $x, y \in \text{dom } f$.

We will also use the following elementary facts about convex functions. Specifically, we will have to deal with affine functions often. As it turns out they are convex. In that spirit, we define what an affine function is and state the fact that it's convex.

Definition A.1.5 (Affine function). *A function $f : \mathbb{R}^d \rightarrow \mathbb{R}$ is called affine if there exist $a \in \mathbb{R}^d$ and $b \in \mathbb{R}$ such that*

$$f(x) = a^T x + b.$$

where $a^T x$ denotes the inner product between d -dimensional points a and x . We use $a^T x$ (equivalently $x^T a$) instead of $\langle a, x \rangle$ since it's closer to standard deep learning notation.

Proposition A.1.6. *Every affine function is convex.*

Proof. The proof follows directly from the definition of convex function. □

Next, another thing that we will need is the pointwise maximum of convex functions. As it turns out, that is convex as well. We omit the proof.

Proposition A.1.7. *Let $f_1, \dots, f_m$ be convex functions on a convex set $C \subseteq \mathbb{R}^d$. Then the pointwise maximum*

$$f(x) = \max_{1 \leq i \leq m} f_i(x)$$

is convex.

A.1.3 Convex subgradients and subdifferentials

The case may be that f is convex but not differentiable, in that case we may speak of (convex) subgradients and (convex) subdifferentials.

Definition A.1.8 (Convex subgradient). *Let f be convex, a vector $g \in \mathbb{R}^d$ is called a convex subgradient of f at $x \in \text{dom } f$ if*

$$f(y) \geq f(x) + g^T(y - x) \quad \text{for all } y \in \text{dom } f.$$

Definition A.1.9 (Convex subdifferential). *Let $f : \text{dom } f \rightarrow \mathbb{R}$ be a convex function, where $\text{dom } f \subseteq \mathbb{R}^d$. The convex subdifferential of f at $x \in \text{dom } f$, denoted by $\partial f(x)$, is the set of all convex subgradients of f at x . Equivalently,*

$$\partial f(x) = \{g \in \mathbb{R}^d : f(y) \geq f(x) + g^T(y - x) \text{ for all } y \in \text{dom } f\}.$$

Proposition A.1.10. *If f is convex and differentiable at x , then $\partial f(x) = \{\nabla f(x)\}$.*

Thus, the convex subdifferential reduces to the usual gradient in the smooth case.

A.1.4 Lipschitz and locally Lipschitz functions

Before we define the Clarke subdifferential, we need to introduce the notion of Lipschitz continuity.

Definition A.1.11 (Lipschitz continuous function). *Let $f : \text{dom } f \rightarrow \mathbb{R}$, where $\text{dom } f \subseteq \mathbb{R}^d$. We say that f is Lipschitz continuous on $\text{dom } f$ if there exists a constant $K \geq 0$ such that*

$$|f(x) - f(y)| \leq K\|x - y\| \quad \text{for all } x, y \in \text{dom } f.$$

The constant K is called a Lipschitz constant for f .

Definition A.1.12 (Lipschitz near a point). *Let $f : \text{dom } f \rightarrow \mathbb{R}$, where $\text{dom } f \subseteq \mathbb{R}^d$. We say that f is Lipschitz near $x \in \text{dom } f$ if there exist constants $K \geq 0$ and $\epsilon > 0$ such that*

$$|f(y) - f(y')| \leq K\|y - y'\| \quad \text{for all } y, y' \in \text{dom } f \cap B(x, \epsilon),$$

where

$$B(x, \epsilon) = \{z \in \mathbb{R}^d : \|z - x\| < \epsilon\}.$$

Definition A.1.13 (Locally Lipschitz continuous function). *Let $f : \text{dom } f \rightarrow \mathbb{R}$, where $\text{dom } f \subseteq \mathbb{R}^d$. We say that f is locally Lipschitz continuous on $\text{dom } f$ if f is Lipschitz near every point $x \in \text{dom } f$.*

Note that every Lipschitz continuous function is locally Lipschitz continuous. The converse is not true in general.

A.1.5 Clarke subdifferential

Having defined locally Lipschitz functions, we can now introduce the Clarke subdifferential. Although Clarke originally defined it in the setting of Banach spaces, we will present it here only in finite-dimensional Euclidean spaces. Its construction relies on the fact that locally Lipschitz functions are differentiable almost everywhere, a result known as Rademacher's theorem, which we briefly recall below.

Theorem A.1.14 (Rademacher's theorem). *Let $U \subseteq \mathbb{R}^d$ be open, and let $f : U \rightarrow \mathbb{R}$ be locally Lipschitz. Then f is differentiable almost everywhere¹ in U .*

Therefore, even if a locally Lipschitz f is not differentiable at a point x , it is differentiable at almost every point near x . The Clarke subdifferential is then intuitively defined by collecting all the gradients at nearby differentiable points and then taking their convex hull.

Definition A.1.15 (Clarke subdifferential). *Let $U \subseteq \mathbb{R}^d$ be open, and let $f : U \rightarrow \mathbb{R}$ be locally Lipschitz. Let $D_f \subseteq U$ denote the set of points at which f is differentiable. For $x \in U$, the Clarke subdifferential of f at x , denoted by $\partial_c f(x)$, is defined by*

$$\partial_c f(x) = \text{co} \left\{ \lim_{k \rightarrow \infty} \nabla f(x_k) \mid x_k \rightarrow x, x_k \in D_f \right\}.$$

Proposition A.1.16. *If f is continuously differentiable² in a neighborhood of x , then*

$$\partial_c f(x) = \{\nabla f(x)\}.$$

Proposition A.1.17. *If f is convex and locally Lipschitz near x , then the Clarke subdifferential is equal to the convex subdifferential:*

$$\partial_c f(x) = \partial f(x).$$

Thus, the Clarke subdifferential extends both the usual gradient and the convex subdifferential. The usual gradient applies to smooth functions, the convex subdifferential applies to convex functions that may be nonsmooth, and the Clarke subdifferential applies to locally Lipschitz functions that may be nonsmooth and nonconvex.

A.2 Elements of asymptotic statistics

In this section we will introduce many of the tools and underlying theory we used for Chapter 4 and its derivations in the Appendix, chapter C.

A.2.1 Convergence in probability and convergence in distribution

Definition A.2.1 (Convergence in probability). *A sequence of random vectors $X_1, X_2, X_3, \dots$ converges in probability to a random vector X , denoted by $X_n \xrightarrow{P} X$, if*

$$\lim_{n \rightarrow \infty} \mathbb{P}(\|X_n - X\| \geq \epsilon) = 0, \text{ for all } \epsilon > 0.$$

Definition A.2.2 (Convergence in distribution). *Let $X_1, X_2, \dots$ be a sequence of random vectors in $\mathbb{R}^d$, and let X be a random vector in $\mathbb{R}^d$. Denote their joint cumulative distribution functions by F_{X_n} and F_X , respectively. We say that X_n converges in distribution to X , denoted by $X_n \xrightarrow{d} X$, if*

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$$

for every $x \in \mathbb{R}^d$ at which F_X is continuous.

¹Meaning that the set of non-differentiable points in the domain of f has a zero Lebesgue measure.

²For an $f : \mathbb{R}^d \rightarrow \mathbb{R}$ continuously differentiable means $\nabla f(x)$ exists and the map $x \mapsto \nabla f(x)$ is continuous.

A.2.2 o_p and O_p notation

Having defined convergence in probability we may define the Big- O_p and little- o_p notation which we use to describe the rate of convergence (in probability) of a random variable. This notation is the direct probabilistic analogue of the deterministic O and o notation.

Definition A.2.3 (o_p notation). *Let $X_1, X_2, \dots$ be a sequence of random variables or random vectors, and let $\{h_n\}_{n \geq 1}$ be a deterministic sequence of positive real numbers. We write*

$$X_n = o_p(h_n)$$

if

$$\frac{\|X_n\|}{h_n} \xrightarrow{P} 0.$$

Definition A.2.4 (O_p notation). *Let $X_1, X_2, \dots$ be a sequence of random variables or random vectors, and let $\{h_n\}_{n \geq 1}$ be a deterministic sequence of positive real numbers. We write*

$$X_n = O_p(h_n)$$

if the sequence $\|X_n\|/h_n$ is bounded in probability. That is, for every $\epsilon > 0$, there exist $M > 0$ and $N \in \mathbb{N}$ such that

$$\mathbb{P}\left(\frac{\|X_n\|}{h_n} > M\right) < \epsilon, \quad \text{for all } n \geq N.$$

Many of the familiar algebraic rules of the deterministic O and o carry over. For example, if a_n and b_n are deterministic positive sequences and $c \neq 0$ is a fixed constant, then

$$\begin{aligned} X_n = o_p(a_n) &\implies X_n = O_p(a_n), \\ c O_p(a_n) &= O_p(a_n), \quad c o_p(a_n) = o_p(a_n), \\ O_p(a_n) + O_p(b_n) &= O_p(\max\{a_n, b_n\}), \quad o_p(a_n) + o_p(b_n) = o_p(\max\{a_n, b_n\}), \\ O_p(a_n) O_p(b_n) &= O_p(a_n b_n), \quad o_p(a_n) O_p(b_n) = o_p(a_n b_n). \end{aligned}$$

A.2.3 Useful convergence results

We now state some standard convergence results that will be used throughout the asymptotic analysis.

Theorem A.2.5 (Continuous mapping theorem). *Let $\{X_n\}_{n \geq 1}$ be a sequence of random vectors in $\mathbb{R}^d$, and let X be a random vector in $\mathbb{R}^d$. Let $g : \mathbb{R}^d \rightarrow \mathbb{R}^m$ be continuous. Then*

$$\begin{aligned} X_n \xrightarrow{d} X &\implies g(X_n) \xrightarrow{d} g(X) \\ X_n \xrightarrow{P} X &\implies g(X_n) \xrightarrow{P} g(X). \end{aligned}$$

Theorem A.2.6 (Slutsky's theorem). *Let $\{X_n\}_{n \geq 1}$ and $\{Y_n\}_{n \geq 1}$ be sequences of random variables. If*

$$X_n \xrightarrow{d} X \quad \text{and} \quad Y_n \xrightarrow{P} c,$$

where $c \in \mathbb{R}$ is constant, then

$$\begin{aligned} X_n + Y_n &\xrightarrow{d} X + c, \\ X_n Y_n &\xrightarrow{d} cX, \\ \frac{X_n}{Y_n} &\xrightarrow{d} \frac{X}{c}, \quad \text{when } c \neq 0. \end{aligned}$$

Theorem A.2.7 (Portmanteau theorem). *Let X_n and X be random variables such that*

$$X_n \xrightarrow{d} X.$$

If $B \subset \mathbb{R}$ is a Borel set satisfying

$$\mathbb{P}(X \in \partial B) = 0,$$

then

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n \in B) = \mathbb{P}(X \in B).$$

Here, ∂B means the boundary of the set B .

Albeit not a convergence result, the following theorem will aid us later on.

Theorem A.2.8 (Chebyshev's inequality). *Let X be a random variable with finite mean and variance. Then, for every $\epsilon > 0$,*

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \epsilon) \leq \frac{\text{Var}(X)}{\epsilon^2}.$$

Theorem A.2.9 (Weak law of large numbers). *Let $X_1, X_2, \dots$ be independent and identically distributed random variables with mean $\mu < \infty$. Then*

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu.$$

Theorem A.2.10 (Central limit theorem). *Let $X_1, X_2, \dots$ be independent and identically distributed random variables with mean μ and variance $0 < \sigma^2 < \infty$. Then*

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1).$$

One thing we will commonly use to go from convergence in probability to the convergence of the expected value of the r.v. is uniform integrability. We provide the definition.

Definition A.2.11 (Uniform integrability). *A sequence of integrable random variables $\{X_n\}_{n \geq 1}$ is uniformly integrable if*

$$\lim_{K \rightarrow \infty} \sup_{n \geq 1} \mathbb{E}[|X_n| \cdot \mathbb{1}\{|X_n| > K\}] = 0.$$

Proposition A.2.12. *Suppose that $X_n \xrightarrow{P} X$ and that $\{X_n\}_{n \geq 1}$ is uniformly integrable. Then*

$$X_n \xrightarrow{L^1} X.$$

Consequently,

$$\mathbb{E}[X_n] \rightarrow \mathbb{E}[X]$$

We state this standard result without proof, as its proof falls outside the scope of this thesis.

A.2.4 Empirical distribution function, order statistics and quantiles

We first begin by defining the empirical distribution function of a sequence of random variables with a common cumulative distribution function.

Definition A.2.13 (Empirical distribution function). *Let $X_1, \dots, X_n$ be real random variables with a common cumulative distribution function F . The empirical distribution function is defined as*

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}\{X_i \leq x\}$$

Notably, for a fixed x , $\hat{F}_n(x)$ denotes the proportion of observations that are less than or equal to x . This view connects the empirical distribution function directly to order statistics, which we will formally define now.

Definition A.2.14 (Order statistics). *Let $X_1, \dots, X_n$ be real random variables. The order statistics of $X_1, \dots, X_n$ are the ordered sample values*

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}.$$

The random variable $X_{(r)}$ is called the r -th order statistic.

The empirical distribution function is directly related to order statistics. Indeed, if there are no ties among $X_1, \dots, X_n$, then exactly r observations are less than or equal to $X_{(r)}$ (since $X_{(r)}$ is by definition the r -th smallest observation). Therefore,

$$\hat{F}_n(X_{(r)}) = \frac{r}{n}.$$

Meaning, the r -th order statistic can be thought of as the point where the empirical cdf has reached r/n .

This motivates the notion of the quantile. While the distribution function evaluates the probability corresponding to a point x , a quantile does the reverse, i.e., it gives the point corresponding to a probability $p \in (0, 1)$. But, since the distribution function may not have an inverse³, we make use of the generalized inverse for nondecreasing functions.

Definition A.2.15 (Quantile). *Let F be a cumulative distribution function. For $p \in (0, 1)$, the p -quantile of F is defined by*

$$F^{-1}(p) = \inf\{x \in \mathbb{R} : F(x) \geq p\}.$$

The same generalized inverse construction can be applied to the empirical distribution function. This gives the empirical quantile function.

Definition A.2.16 (Empirical quantile). *Let $X_1, \dots, X_n$ be real random variables and let $\hat{F}_n$ be their empirical distribution function. For $p \in (0, 1)$, the empirical p -quantile is defined by*

$$\hat{F}_n^{-1}(p) = \inf\{x \in \mathbb{R} : \hat{F}_n(x) \geq p\}.$$

Of course if the distribution function is in fact continuous and strictly increasing then we have the ordinary inverse.

A.2.5 Bahadur representation

We now state a classical asymptotic representation for sample quantiles.

Theorem A.2.17 (Bahadur representation). *Let $X_1, \dots, X_n$ be independent and identically distributed real random variables with cumulative distribution function F , and let $\hat{F}_n$ denote the empirical distribution function. For $p \in (0, 1)$, define the population p -quantile by*

$$\xi_p = F^{-1}(p) = \inf\{x \in \mathbb{R} : F(x) \geq p\},$$

and define the corresponding empirical p -quantile by

$$\hat{\xi}_p = \hat{F}_n^{-1}(p).$$

Assume that F is differentiable at ξ_p , with $F'(\xi_p) > 0$. Then

$$\sqrt{n}(\hat{\xi}_p - \xi_p) = \frac{\sqrt{n}(p - \hat{F}_n(\xi_p))}{F'(\xi_p)} + o_p(1).$$

Equivalently,

$$\hat{\xi}_p - \xi_p = \frac{p - \hat{F}_n(\xi_p)}{F'(\xi_p)} + o_p(n^{-1/2}).$$

This representation shows that, up to a smaller-order error term, the fluctuation of the empirical quantile around the population quantile is determined by the fluctuation of the empirical distribution function evaluated at the population quantile.

³Notably, a cdf is always right continuous and nondecreasing but it may have flat parts (which break one-to-one) and it may have jumps (which break onto), making it non-invertible.

Appendix B

Auxiliary proofs and derivations for Chapter 3

B.1 Derivation of the error signal $\delta_i^{(l)}$

We derive the subdifferential set of $(E_l \circ \mathbf{F}^{(l)})(\mathbf{z}^{(l)})$ using Clarke's chain rule I:

- $h = \mathbf{F}^{(l)} : \mathbb{R}^{N_l} \rightarrow \mathbb{R}^{N_l}$. We assume that the scalar activation $f : \mathbb{R} \rightarrow \mathbb{R}$ is locally Lipschitz. Since $\mathbf{F}^{(j)}$ acts componentwise via f , each $\mathbf{F}^{(j)}$ is locally Lipschitz.
- $g = E_l : \mathbb{R}^{N_l} \rightarrow \mathbb{R}$ is Lipschitz near $\mathbf{y}^{(l)} = \mathbf{F}^{(l)}(\mathbf{z}^{(l)})$ because ϕ is C^1 , and each factor in $\mathbf{T}_l = \mathbf{F}^{(L)} \circ \mathbf{h}^{(L)} \circ \dots \circ \mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)}$ is locally Lipschitz: $\mathbf{F}^{(j)}$ is induced by a locally Lipschitz scalar function as written above, and $\mathbf{h}^{(j)}(\cdot; \boldsymbol{\theta}_i^{(j)})$ is, with parameters fixed, an affine combination of an affine map and an order-statistic map (both globally Lipschitz), hence locally Lipschitz. Therefore $E_l = \phi \circ \mathbf{T}_l$ is Lipschitz near $\mathbf{y}^{(l)}$.

Using Clarke's chain rule we get:

$$\begin{aligned} \partial_c(E_l \circ \mathbf{F}^{(l)})(\mathbf{z}^{(l)}) &\subset \text{co} \left\{ \sum_{j=1}^{N_l} \alpha_j \boldsymbol{\zeta}_j : \boldsymbol{\zeta}_j \in \partial_c F_j^{(l)}(\mathbf{z}^{(l)}), \boldsymbol{\alpha} \in \partial_c E_l(\mathbf{F}^{(l)}(\mathbf{z}^{(l)})) \right\} \\ &\subset \text{co} \left\{ \sum_{j=1}^{N_l} \alpha_j \boldsymbol{\zeta}_j : \boldsymbol{\zeta}_j \in \partial_c F_j^{(l)}(\mathbf{z}^{(l)}), \boldsymbol{\alpha} \in \partial_c E_l(\mathbf{y}^{(l)}) \right\} \end{aligned}$$

Notice that,

$$F_j^{(l)}(\mathbf{z}^{(l)}) = f(\mathbf{e}_j^\top \mathbf{z}^{(l)}) = (f \circ \mathbf{A})(\mathbf{z}^{(l)}), \quad \mathbf{A}(\mathbf{x}) = \mathbf{e}_j^\top \mathbf{x}$$

Therefore, applying Clarke's Chain Rule II we get

$$\partial_c F_j^{(l)}(\mathbf{z}^{(l)}) = \partial_c f(z_j^{(l)}) \mathbf{e}_j^\top$$

i.e., any $\boldsymbol{\zeta}_j \in \partial_c F_j^{(l)}(\mathbf{z}^{(l)})$ can be chosen of the form

$$\boldsymbol{\zeta}_j = \sigma_j^{(l)} \mathbf{e}_j^\top \quad \text{for some } \sigma_j^{(l)} \in \partial_c f(z_j^{(l)}).$$

(Note that, σ_i is the nonsmooth equivalent of $\partial y_i^{(l)} / \partial z_i^{(l)}$.)

Thus

$$\begin{aligned}
\partial_c(E_l \circ \mathbf{F}^{(l)})(\mathbf{z}^{(l)}) &\subset \text{co} \left\{ \sum_{j=1}^{N_l} \alpha_j \sigma_j^{(l)} \mathbf{e}_j^\top : \sigma_j^{(l)} \in \partial_c f(z_j^{(l)}), \alpha \in \partial_c E_l(\mathbf{y}^{(l)}) \right\} \\
&\subset \text{co} \left\{ \alpha \text{Diag}(\boldsymbol{\sigma}^{(l)}) : \sigma_j^{(l)} \in \partial_c f(z_j^{(l)}), \alpha \in \partial_c E_l(\mathbf{y}^{(l)}) \right\} \quad (\boldsymbol{\sigma}^{(l)} = [\sigma_1^{(l)}, \dots, \sigma_{N_l}^{(l)}]) \\
&\subset \text{co} \left\{ -2\mathbf{e}^{(l)} \text{Diag}(\boldsymbol{\sigma}^{(l)}) : \sigma_j^{(l)} \in \partial_c f(z_j^{(l)}), \mathbf{e}^{(l)} \in -\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)}) \right\} \quad (\mathbf{e}^{(l)} := -\frac{1}{2}\alpha) \\
&\subset \text{co} \left\{ -2\boldsymbol{\sigma}^{(l)} \odot \mathbf{e}^{(l)} : \sigma_j^{(l)} \in \partial_c f(z_j^{(l)}), \mathbf{e}^{(l)} \in -\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)}) \right\} \\
&\subset \text{co} \left\{ -2\boldsymbol{\delta}^{(l)} : \sigma_j^{(l)} \in \partial_c f(z_j^{(l)}), \mathbf{e}^{(l)} \in -\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)}) \right\} \quad (\boldsymbol{\delta}^{(l)} := \boldsymbol{\sigma}^{(l)} \odot \mathbf{e}^{(l)})
\end{aligned}$$

Now, for us to derive the entry-wise subdifferential, we define

$$\psi_i : \mathbb{R} \rightarrow \mathbb{R}, \quad \psi_i(t) := E_l(\mathbf{F}^{(l)}(z_1^{(l)}, \dots, z_{i-1}^{(l)}, t, z_{i+1}^{(l)}, \dots, z_{N_l}^{(l)})).$$

$$\mathbf{J}_i : \mathbb{R} \rightarrow \mathbb{R}^{N_l}, \quad \mathbf{J}_i(t) = \mathbf{z}^{(l)} + (t - z_i^{(l)})\mathbf{e}_i,$$

so that $\psi_i = E_l \circ \mathbf{F}^{(l)} \circ \mathbf{J}_i$ and, in particular,

$$\psi_i(z_i^{(l)}) = E_l(\mathbf{F}^{(l)}(\mathbf{z}^{(l)}))$$

We apply Clarke's chain rule II, for $F = \mathbf{J}_i$, where $\mathbf{J}_i$ (as an affine mapping) is strictly differentiable at $z_i^{(l)}$ with derivative $D\mathbf{J}_i(z_i^{(l)}) = \mathbf{e}_i$ and for $g = E_l \circ \mathbf{F}^{(l)}$ where $E_l \circ \mathbf{F}^{(l)}$ is Lipschitz near $\mathbf{z}^{(l)}$ as the composition of two locally Lipschitz mappings.

$$\partial_c(E_l \circ \mathbf{F}^{(l)} \circ \mathbf{J}_i)(z_i^{(l)}) \subset \partial_c(E_l \circ \mathbf{F}^{(l)})(\mathbf{J}_i(z_i^{(l)}))\mathbf{e}_i = \partial_c(E_l \circ \mathbf{F}^{(l)})(\mathbf{z}^{(l)})\mathbf{e}_i$$

And plugging in $\partial_c(E_l \circ \mathbf{F}^{(l)})(\mathbf{z}^{(l)})$ from the above calculations:

$$\begin{aligned}
\partial_c(E_l \circ \mathbf{F}^{(l)} \circ \mathbf{J}_i)(z_i^{(l)}) &\subset \text{co} \left\{ -2\boldsymbol{\sigma}^{(l)} \odot \mathbf{e}^{(l)} : \sigma_j^{(l)} \in \partial_c f(z_j^{(l)}), \mathbf{e}^{(l)} \in -\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)}) \right\} \mathbf{e}_i \\
&\subset \text{co} \left\{ -2\sigma_i \mathbf{e}_i^{(l)} : \sigma_i \in \partial_c f(z_i^{(l)}), \mathbf{e}^{(l)} \in -\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)}) \right\} \\
&\subset \text{co} \left\{ -2\delta_i^{(l)} : \sigma_i \in \partial_c f(z_i^{(l)}), \mathbf{e}^{(l)} \in -\frac{1}{2}\partial_c E_l(\mathbf{y}^{(l)}) \right\}. \tag{B.1.1}
\end{aligned}$$

The second line holds since linear maps preserve convex combinations,

$$L(\text{co } \mathcal{S}) = \text{co}(L\mathcal{S}).$$

B.2 Derivation of parameter subgradients

First, for the weight vector $\mathbf{w}_i^{(l)}$, define

$$h_{\mathbf{w}_i^{(l)}}(\mathbf{w}) = \lambda_i^{(l)} \alpha_i^{(l)} + (1 - \lambda_i^{(l)}) [\mathbf{w}^\top \mathbf{y}^{(l-1)} + b_i^{(l)}].$$

This map is affine in $\mathbf{w}$, hence

$$\partial_c h_{\mathbf{w}_i^{(l)}}(\mathbf{w}_i^{(l)}) = \left\{ (1 - \lambda_i^{(l)}) (\mathbf{y}^{(l-1)})^\top \right\}.$$

Therefore, we have the nonsmooth equivalent of $\partial E / \partial \mathbf{w}_i^{(l)}$:

$$\partial_c(g \circ h_{\mathbf{w}_i^{(l)}})(\mathbf{w}_i^{(l)}) \subset \text{co} \left\{ -2\delta_i^{(l)} (1 - \lambda_i^{(l)}) (\mathbf{y}^{(l-1)})^\top \right\}.$$

Next, for $\mathbf{a}_i^{(l)}$, define

$$h_{\mathbf{a}_i^{(l)}}(\mathbf{a}) = \lambda_i^{(l)} R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}) + (1 - \lambda_i^{(l)}) \beta_i^{(l)}.$$

We have that:

$$\partial_c h_{\mathbf{a}_i^{(l)}}(\mathbf{a}_i^{(l)}) = \lambda_i^{(l)} \partial_c R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)})$$

Therefore, we gain the nonsmooth analogue of $\partial E / \partial \mathbf{a}_i^{(l)}$:

$$\partial_c (g \circ h_{\mathbf{a}_i^{(l)}})(\mathbf{a}_i^{(l)}) \subset \text{co}\{-2\delta_i^{(l)} \lambda_i^{(l)} \boldsymbol{\zeta}, \boldsymbol{\zeta} \in \partial_c R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)})\}$$

where, we know that:

$$\partial_c R_{r_i^{(l)}}(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)}) = \text{co}\{\mathbf{e}_k^\top : y_k^{(l-1)} + A_{ik}^{(l)} = (\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)})_{(r_i^{(l)})}\}$$

Then, for $b_i^{(l)}$, we define:

$$h_{b_i^{(l)}}(b) = \lambda_i^{(l)} \alpha_i^{(l)} + (1 - \lambda_i^{(l)}) \left(\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b \right)$$

This map is affine in b , hence:

$$\partial_c h_{b_i^{(l)}}(b_i^{(l)}) = \{1 - \lambda_i^{(l)}\}$$

Therefore, we have the nonsmooth equivalent of $\partial E / \partial b_i^{(l)}$:

$$\partial_c (g \circ h_{b_i^{(l)}})(b_i^{(l)}) \subset \text{co}\{-2\delta_i^{(l)} (1 - \lambda_i^{(l)})\}.$$

Finally, for $\lambda_i^{(l)}$, define:

$$h_{\lambda_i^{(l)}}(\lambda) = \lambda \alpha_i^{(l)} + (1 - \lambda) \beta_i^{(l)}$$

The map is affine in λ , hence:

$$\partial_c h_{\lambda_i^{(l)}}(\lambda_i^{(l)}) = \{\alpha_i^{(l)} - \beta_i^{(l)}\}$$

Giving us the nonsmooth analogue of $\partial E / \partial \lambda_i^{(l)}$:

$$\partial_c (g \circ h_{\lambda_i^{(l)}})(\lambda_i^{(l)}) \subset \text{co}\{-2\delta_i^{(l)} (\alpha_i^{(l)} - \beta_i^{(l)})\}.$$

B.3 Upper estimate of $\partial_c E_l(\mathbf{y}^{(l)})$

Using the fact that $\mathbf{T}_l = \mathbf{T}_{l+1} \circ \mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)}$, $E_l(\mathbf{y}^{(l)})$ can be rewritten as:

$$\begin{aligned} E_l(\mathbf{y}^{(l)}) &= \phi(\mathbf{T}_{l+1} \circ \mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)})(\mathbf{y}^{(l)}) \\ &= (\phi \circ \mathbf{T}_{l+1})(\mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)})(\mathbf{y}^{(l)}) \\ &= (E_{l+1} \circ \mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)})(\mathbf{y}^{(l)}) \end{aligned}$$

From our previous derivations it's clear that each mapping on the RHS is locally Lipschitz and as such we can use Clarke's chain rule I, where $g = E_{l+1}$ and $h = \mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)}$. We get

$$\partial_c E_l(\mathbf{y}^{(l)}) \subset \text{co}\left\{ \sum_{j=1}^{N_{l+1}} \alpha_j \boldsymbol{\zeta}_j : \boldsymbol{\zeta}_j \in \partial_c (\mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)})_j(\mathbf{y}^{(l)}), \boldsymbol{\alpha} \in \partial_c E_{l+1}(\mathbf{y}^{(l+1)}) \right\}$$

Note:

$$(\mathbf{F}^{(l+1)} \circ \mathbf{h}^{(l+1)})_j(\mathbf{y}^{(l)}) = (f \circ h_{\boldsymbol{\theta}_j^{(l+1)}})(\mathbf{y}^{(l)}) \quad (h_{\boldsymbol{\theta}_j^{(l+1)}} = h(\cdot; \boldsymbol{\theta}_j^{(l+1)}))$$

Then, applying Clarke's chain rule I for $\partial_c(f \circ h_{\boldsymbol{\theta}_j^{(l+1)}})(\mathbf{y}^{(l)})$:

$$\partial_c(f \circ h_{\boldsymbol{\theta}_j^{(l+1)}})(\mathbf{y}^{(l)}) \subset \text{co} \left\{ \sigma_j^{(l+1)} \boldsymbol{\eta}_j : \boldsymbol{\eta}_j \in \partial_c h_{\boldsymbol{\theta}_j^{(l+1)}}(\mathbf{y}^{(l)}), \sigma_j^{(l+1)} \in \partial_c f(z_j^{(l+1)}) \right\}.$$

Finally, we obtain:

$$\begin{aligned} \partial_c E_l(\mathbf{y}^{(l)}) &\subset \text{co} \left\{ \sum_{j=1}^{N_{l+1}} -2 \underbrace{e_j^{(l+1)} \sigma_j^{(l+1)}}_{=\delta_j^{(l+1)}} \boldsymbol{\eta}_j : \mathbf{e}^{(l+1)} \in -\frac{1}{2} \partial_c E_{l+1}(\mathbf{y}^{(l+1)}), \boldsymbol{\eta}_j \in \partial_c h_{\boldsymbol{\theta}_j^{(l+1)}}(\mathbf{y}^{(l)}), \sigma_j^{(l+1)} \in \partial_c f(z_j^{(l+1)}) \right\} \\ &\subset \text{co} \left\{ \sum_{j=1}^{N_{l+1}} -2 \delta_j^{(l+1)} \boldsymbol{\eta}_j : \mathbf{e}^{(l+1)} \in -\frac{1}{2} \partial_c E_{l+1}(\mathbf{y}^{(l+1)}), \boldsymbol{\eta}_j \in \partial_c h_{\boldsymbol{\theta}_j^{(l+1)}}(\mathbf{y}^{(l)}), \sigma_j^{(l+1)} \in \partial_c f(z_j^{(l+1)}) \right\} \\ &\subset \text{co} \left\{ \sum_{j=1}^{N_{l+1}} -2 \delta_j^{(l+1)} \mathbf{v}_j^{(l+1)} : \mathbf{e}^{(l+1)} \in -\frac{1}{2} \partial_c E_{l+1}(\mathbf{y}^{(l+1)}), \mathbf{v}_j^{(l+1)} \in \partial_c h_{\boldsymbol{\theta}_j^{(l+1)}}(\mathbf{y}^{(l)}), \sigma_j^{(l+1)} \in \partial_c f(z_j^{(l+1)}) \right\}. \end{aligned}$$

$(\mathbf{v}_j^{(l+1)} := \boldsymbol{\eta}_j)$

B.4 Derivation of $\partial_c h_{\boldsymbol{\theta}_i^{(l+1)}}(\mathbf{y}^{(l)})$

We have that

$$\begin{aligned} h_{\boldsymbol{\theta}_i^{(l+1)}}(\mathbf{y}^{(l)}) &= h(\mathbf{y}^{(l)}; \boldsymbol{\theta}_i^{(l+1)}) = \lambda_i^{(l+1)} \alpha_i^{(l+1)} + (1 - \lambda_i^{(l+1)}) \beta_i^{(l+1)} \\ &= \lambda_i^{(l+1)} R_{r_i^{(l+1)}}(\mathbf{y}^{(l)} + \mathbf{a}_i^{(l+1)}) + (1 - \lambda_i^{(l+1)}) \left[(\mathbf{w}_i^{(l+1)})^\top \mathbf{y}^{(l)} + b_i^{(l+1)} \right] \end{aligned}$$

Now, $(\mathbf{w}_i^{(l+1)})^\top \mathbf{y}^{(l)} + b_i^{(l+1)}$ is an affine function of $\mathbf{y}^{(l)}$ and therefore strictly differentiable at $\mathbf{y}^{(l)}$. So Clarke's sum rule for subdifferentials holds as an equality, that is:

$$\begin{aligned} \partial_c h_{\boldsymbol{\theta}_i^{(l+1)}}(\mathbf{y}^{(l)}) &= \lambda_i^{(l+1)} \partial_c (R_{r_i^{(l+1)}} \circ \mathbf{D})(\mathbf{y}^{(l)}) + (1 - \lambda_i^{(l+1)}) (\mathbf{w}_i^{(l+1)})^\top \quad (\mathbf{D}(\mathbf{x}) = \mathbf{x} + \mathbf{a}_i^{(l+1)}) \\ &= \lambda_i^{(l+1)} \partial_c R_{r_i^{(l+1)}}(\mathbf{y}^{(l)} + \mathbf{a}_i^{(l+1)}) + (1 - \lambda_i^{(l+1)}) (\mathbf{w}_i^{(l+1)})^\top \\ &= \lambda_i^{(l+1)} \text{co} \left\{ \mathbf{e}_j^\top : (\mathbf{y}^{(l)} + \mathbf{a}_i^{(l+1)})_j = (\mathbf{y}^{(l)} + \mathbf{a}_i^{(l+1)})_{(r_i^{(l+1)})} \right\} + (1 - \lambda_i^{(l+1)}) (\mathbf{w}_i^{(l+1)})^\top \end{aligned}$$

The second line holds because applying Clarke's chain rule II:

$$\partial_c (R_{r_i^{(l+1)}} \circ \mathbf{D})(\mathbf{y}^{(l)}) = \partial_c R_{r_i^{(l+1)}}(\mathbf{y}^{(l)} + \mathbf{a}_i^{(l+1)}) \mathbf{I}_{N_l}$$

Notice that $\mathbf{I}_{N_l}$ (the unit matrix of $N_l \times N_l$ dimension) as a mapping is onto, therefore the usual inclusion holds as an equality.

Appendix C

Auxiliary proofs and derivations for Chapter 4

C.1 Rank parametrization and ranking-input distributions

C.1.1 Order of $r_i^{(l)}/N_{l-1}$ convergence

For every layer $l \in \{1, \dots, L\}$ and every neuron $i \in \{1, \dots, N_l\}$, let

$$p_i^{(l)} = 1 - \sigma(\rho_i^{(l)}).$$

We will prove that then:

$$\frac{r_i^{(l)}}{N_{l-1}} - p_i^{(l)} = O(1/N_{l-1}),$$

and in particular

$$\frac{r_i^{(l)}}{N_{l-1}} - p_i^{(l)} = o(N_{l-1}^{-1/2})$$

Recall that the ranking order is given by:

$$r_i^{(l)} = \lfloor N_{l-1} - (N_{l-1} - 1)\sigma(\rho_i^{(l)}) + 0.5 \rfloor = \lfloor N_{l-1}(1 - \sigma(\rho_i^{(l)})) + \sigma(\rho_i^{(l)}) + 0.5 \rfloor.$$

Since for any $x \in \mathbb{R}$ it holds that $x - 1 \leq \lfloor x \rfloor \leq x$, we have

$$\begin{aligned} N_{l-1}(1 - \sigma(\rho_i^{(l)})) + \sigma(\rho_i^{(l)}) - 0.5 &\leq r_i^{(l)} \leq N_{l-1}(1 - \sigma(\rho_i^{(l)})) + \sigma(\rho_i^{(l)}) + 0.5 \\ (1 - \sigma(\rho_i^{(l)})) + \frac{\sigma(\rho_i^{(l)}) - 0.5}{N_{l-1}} &\leq \frac{r_i^{(l)}}{N_{l-1}} \leq (1 - \sigma(\rho_i^{(l)})) + \frac{\sigma(\rho_i^{(l)}) + 0.5}{N_{l-1}} \\ \frac{\sigma(\rho_i^{(l)}) - 0.5}{N_{l-1}} &\leq \frac{r_i^{(l)}}{N_{l-1}} - p_i^{(l)} \leq \frac{\sigma(\rho_i^{(l)}) + 0.5}{N_{l-1}} \quad (\text{by subtracting } p_i^{(l)} = 1 - \sigma(\rho_i^{(l)})) \end{aligned}$$

Therefore,

$$\begin{aligned} \left| \frac{r_i^{(l)}}{N_{l-1}} - p_i^{(l)} \right| &\leq \max \left(\left| \frac{\sigma(\rho_i^{(l)}) - 0.5}{N_{l-1}} \right|, \left| \frac{\sigma(\rho_i^{(l)}) + 0.5}{N_{l-1}} \right| \right) = \frac{\sigma(\rho_i^{(l)}) + 0.5}{N_{l-1}} \\ &< \frac{3}{2N_{l-1}} \quad (\sigma(x) < 1, x \in \mathbb{R}) \end{aligned}$$

That gives us,

$$\frac{r_i^{(l)}}{N_{l-1}} - p_i^{(l)} = O(1/N_{l-1}).$$

This immediately implies

$$\frac{r_i^{(l)}}{N_{l-1}} - p_i^{(l)} = o(N_{l-1}^{-1/2}).$$

C.1.2 Marginal distribution of the ranking input $y_j^{(l-1)} + A_{ij}^{(l)}$

To derive the marginal c.d.f. of a typical coordinate j in layer l , we only use that $A_{ij}^{(l)} \sim \mathcal{N}(0, \sigma_a^2)$ and that $A_{ij}^{(l)}$ is independent of $y_j^{(l-1)}$. Under the common- ρ assumption, the coordinates $y_j^{(l-1)}$ have a common marginal distribution for $l \geq 2$ (for $l = 1$ it is assumed), so the same marginal c.d.f. applies to every coordinate j .

For a fixed coordinate j ,

$$(X_i^{(l)})_j = y_j^{(l-1)} + A_{ij}^{(l)},$$

then

$$\begin{aligned} F_{(X_i^{(l)})_j}(x) &= \mathbb{P}((X_i^{(l)})_j \leq x) = \mathbb{E}[\mathbb{1}\{(X_i^{(l)})_j \leq x\}] \\ &= \mathbb{E} \left[\mathbb{E} \left[\mathbb{1}\{(X_i^{(l)})_j \leq x\} \mid y_j^{(l-1)} \right] \right] && (\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Z]]) \\ &= \mathbb{E} \left[\mathbb{P}((X_i^{(l)})_j \leq x \mid y_j^{(l-1)}) \right] \\ &= \mathbb{E} \left[\mathbb{P} \left(y_j^{(l-1)} + A_{ij}^{(l)} \leq x \mid y_j^{(l-1)} \right) \right] \\ &= \mathbb{E} \left[\mathbb{P} \left(A_{ij}^{(l)} \leq x - y_j^{(l-1)} \mid y_j^{(l-1)} \right) \right] \\ &= \mathbb{E} \left[F_{A_{ij}^{(l)} | y_j^{(l-1)}}(x - y_j^{(l-1)}) \right] \\ &= \mathbb{E} \left[F_{A_{ij}^{(l)}}(x - y_j^{(l-1)}) \right] && (A_{ij}^{(l)} \perp y_j^{(l-1)}) \\ &= \mathbb{E} \left[\Phi \left(\frac{x - y_j^{(l-1)}}{\sigma_a} \right) \right]. && (F_{A_{ij}^{(l)}}(t) = \Phi(t/\sigma_a)) \end{aligned}$$

C.1.3 Density of the ranking input $y_j^{(l-1)} + A_{ij}^{(l)}$

We now apply the dominated convergence theorem to differentiate the c.d.f. and obtain the density. For fixed $x \in \mathbb{R}$, consider the sequence of measurable functions

$$g_n(u) := \frac{\Phi\left(\frac{(x+1/n)-u}{\sigma_a}\right) - \Phi\left(\frac{x-u}{\sigma_a}\right)}{1/n}, \quad u \in \mathbb{R}.$$

Since Φ is differentiable, for every fixed $u \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} g_n(u) = \frac{1}{\sigma_a} \phi\left(\frac{x-u}{\sigma_a}\right).$$

Moreover, by the mean value theorem, for each n and u , there exists $c_n(u) \in (x, x+1/n)$ such that

$$g_n(u) = \frac{1}{\sigma_a} \phi\left(\frac{c_n(u)-u}{\sigma_a}\right).$$

Hence,

$$|g_n(u)| \leq \frac{1}{\sigma_a \sqrt{2\pi}} \quad \text{for all } n \text{ and } u,$$

since $\phi(t) \leq 1/\sqrt{2\pi}$ for all $t \in \mathbb{R}$. The constant function

$$u \mapsto \frac{1}{\sigma_a \sqrt{2\pi}}$$

is integrable with respect to the probability law of $y_j^{(l-1)}$. Therefore, by the dominated convergence theorem, we may interchange differentiation with expectation:

$$\begin{aligned} f_{(X_i^{(l)})_j}(x) &= \frac{d}{dx} F_{(X_i^{(l)})_j}(x) \\ &= \frac{d}{dx} \mathbb{E} \left[\Phi \left(\frac{x - y_j^{(l-1)}}{\sigma_a} \right) \right] \\ &= \mathbb{E} \left[\frac{d}{dx} \Phi \left(\frac{x - y_j^{(l-1)}}{\sigma_a} \right) \right] \\ &= \mathbb{E} \left[\frac{1}{\sigma_a} \phi \left(\frac{x - y_j^{(l-1)}}{\sigma_a} \right) \right]. \end{aligned}$$

C.2 Pure ranking asymptotics beyond the first layer

C.2.1 Vanishing threshold covariance

To prove that for $l \geq 2$, the empirical width dependent cdf $\hat{F}_N$ converges to the marginal width dependent F_N we first have to prove that the ranking input's empirical cdf's covariance is vanishing.

Fix $l \geq 2$, $j \neq k$, and $x \in \mathbb{R}$. Suppose

$$\alpha_j^{(l-1)} \rightarrow_P \xi^{(l-1)}, \quad \alpha_k^{(l-1)} \rightarrow_P \xi^{(l-1)}.$$

If f is continuous, then

$$\text{Cov} \left(\mathbb{1}\{f(\alpha_j^{(l-1)}) + A_{ij}^{(l)} \leq x\}, \mathbb{1}\{f(\alpha_k^{(l-1)}) + A_{ik}^{(l)} \leq x\} \right) \rightarrow 0.$$

Indeed, since $\alpha_j^{(l-1)}, \alpha_k^{(l-1)} \rightarrow_P \xi^{(l-1)}$, by the continuous mapping theorem since f is continuous

$$f(\alpha_j^{(l-1)}) \rightarrow_P f(\xi^{(l-1)}), \quad f(\alpha_k^{(l-1)}) \rightarrow_P f(\xi^{(l-1)})$$

thus, by the vector form of Slutsky's theorem

$$\left(f(\alpha_j^{(l-1)}) + A_{ij}^{(l)}, f(\alpha_k^{(l-1)}) + A_{ik}^{(l)} \right) \xrightarrow{d} \left(f(\xi^{(l-1)}) + A_{ij}^{(l)}, f(\xi^{(l-1)}) + A_{ik}^{(l)} \right).$$

Since the limiting variables have continuous Gaussian distributions, the joint threshold map $(u, v) \mapsto (\mathbb{1}\{u \leq x\}, \mathbb{1}\{v \leq x\})$ is continuous almost surely¹. Therefore, by the continuous mapping theorem the corresponding indicators converge jointly in distribution. They are bounded, so the expectations and product expectation converge. Thus the covariance converges to the covariance of the limiting indicators, that is:

$$\text{Cov} \left(\mathbb{1}\{f(\alpha_j^{(l-1)}) + A_{ij}^{(l)} \leq x\}, \mathbb{1}\{f(\alpha_k^{(l-1)}) + A_{ik}^{(l)} \leq x\} \right) \rightarrow \text{Cov} \left(\mathbb{1}\{f(\xi^{(l-1)}) + A_{ij}^{(l)} \leq x\}, \mathbb{1}\{f(\xi^{(l-1)}) + A_{ik}^{(l)} \leq x\} \right)$$

The limiting indicators are independent because $A_{ij}^{(l)}$ and $A_{ik}^{(l)}$ are independent and $f(\xi^{(l-1)})$ is just a constant. As such, the limiting covariance is 0.

C.2.2 Convergence of the empirical cdf $\hat{F}_N$ to the marginal cdf F_N

That is, we will show that the empirical (width dependent) cdf $\hat{F}_N$ of the samples $\{(X_i^{(l)})_j\}_{j=1}^N$ converges pointwise in probability to the marginal (width dependent) cdf F_N . We will make use of Chebyshev's inequality:

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \epsilon) \leq \frac{\text{Var}(X)}{\epsilon^2}$$

The empirical cdf by definition is:

$$\hat{F}_N(x) = \frac{1}{N} \sum_{j=1}^N \mathbb{1}\{(X_i^{(l)})_j \leq x\}$$

¹That is, the probabilities at the discontinuous points $\mathbb{P}(f(\xi^{(l-1)}) + A_{ij}^{(l)} = x)$ and $\mathbb{P}(f(\xi^{(l-1)}) + A_{ik}^{(l)} = x)$ are zero.

We first prove that the expected value of the empirical cdf is in fact the marginal cdf:

$$\begin{aligned}
\mathbb{E}[\widehat{F}_N(x)] &= \frac{1}{N} \mathbb{E} \left[\sum_{j=1}^N \mathbb{1}\{(X_i^{(l)})_j \leq x\} \right] \\
&= \frac{1}{N} \sum_{j=1}^N \mathbb{E} \left[\mathbb{1}\{(X_i^{(l)})_j \leq x\} \right] \\
&= \frac{1}{N} \sum_{j=1}^N \mathbb{P} \left((X_i^{(l)})_j \leq x \right) \\
&= \mathbb{P} \left((X_i^{(l)})_j \leq x \right) = F_N(x)
\end{aligned}$$

where the last line holds because $\{(X_i^{(l)})_j\}_{j=1}^N$ are identically marginally distributed under common $\rho^{(l)}$ per layer.

Now for the variance, we have:

$$\begin{aligned}
\text{Var}(\widehat{F}_N(x)) &= \frac{1}{N^2} \text{Var} \left(\sum_{j=1}^N \mathbb{1}\{(X_i^{(l)})_j \leq x\} \right) \\
&= \frac{1}{N^2} \left[\sum_{j=1}^N \text{Var}(\mathbb{1}\{(X_i^{(l)})_j \leq x\}) + 2 \sum_{1 \leq j < k \leq N} \text{Cov} \left(\mathbb{1}\{(X_i^{(l)})_j \leq x\}, \mathbb{1}\{(X_i^{(l)})_k \leq x\} \right) \right] \\
&= \frac{N}{N^2} F_N(x)(1 - F_N(x)) + \frac{2}{N^2} \frac{N(N-1)}{2} \text{Cov} \left(\mathbb{1}\{(X_i^{(l)})_j \leq x\}, \mathbb{1}\{(X_i^{(l)})_k \leq x\} \right) \\
&= \frac{1}{N} F_N(x)(1 - F_N(x)) + \frac{N-1}{N} \text{Cov} \left(\mathbb{1}\{(X_i^{(l)})_j \leq x\}, \mathbb{1}\{(X_i^{(l)})_k \leq x\} \right)
\end{aligned}$$

The second line holds due to the covariance expansion. The third line follows from the fact that the variance of a Bernoulli r.v with success probability p is $p(1-p)$ and the fact that the $\{(X_i^{(l)})_j\}_{j=1}^N$ are identically marginally distributed. More specifically, we assume that the coordinate array $\{(X_i^{(l)})_j\}_{j=1}^N$ is exchangeable, as such, all off-diagonal threshold covariances are equal.

For any c.d.f. F we have that for any $x \in \mathbb{R}$, $F(x) \in [0, 1]$. Therefore that gives us

$$0 \leq F_N(x)(1 - F_N(x)) \leq \frac{1}{4}$$

By a multiplication of the above inequality with $1/N$ and the squeeze theorem consequently, we get

$$\lim_{N \rightarrow \infty} \frac{1}{N} F_N(x)(1 - F_N(x)) = 0 \quad (\text{C.2.1})$$

For the second term, from subsection C.2.1 in the appendix (since $(X_i^{(l)})_j = f(\alpha_j^{(l-1)}) + A_{ij}$), we have that:

$$\lim_{N \rightarrow \infty} \text{Cov} \left(\mathbb{1}\{(X_i^{(l)})_j \leq x\}, \mathbb{1}\{(X_i^{(l)})_k \leq x\} \right) = 0 \quad (\text{C.2.2})$$

From equations (C.2.1), (C.2.2) and since $(N-1)/N = O(1)$ we get:

$$\lim_{N \rightarrow \infty} \text{Var}(\widehat{F}_N(x)) = 0$$

so, by applying the Chebyshev inequality for the random variable $\widehat{F}_N(x)$ and then taking the limit:

$$\lim_{N \rightarrow \infty} \mathbb{P}(|\widehat{F}_N(x) - F_N(x)| \geq \epsilon) \leq \lim_{N \rightarrow \infty} \frac{\text{Var}(\widehat{F}_N(x))}{\epsilon^2} = 0$$

so by the definition of convergence in probability:

$$\widehat{F}_N(x) \xrightarrow{P} F_N(x).$$

C.2.3 Convergence of the marginal cdf F_N to the limiting marginal cdf F

That is, we will prove that the marginal width dependent cdf $F_N(x)$ converges to the limiting marginal cdf $F(x)$. Assume that

$$\alpha_j^{(l-1)} \xrightarrow{P} \xi^{(l-1)}$$

Let

$$F(x) := \mathbb{P}(f(\xi^{(l-1)}) + A_{ij}^{(l)} \leq x)$$

We will prove that

$$\lim_{N \rightarrow \infty} F_N(x) = F(x), \quad \forall x \in \mathbb{R}$$

Proof. Since $\alpha_j^{(l-1)} \xrightarrow{P} \xi^{(l-1)}$, by the continuous mapping theorem:

$$f(\alpha_j^{(l-1)}) \xrightarrow{P} f(\xi^{(l-1)})$$

Then, from Slutsky's theorem we have that:

$$f(\alpha_j^{(l-1)}) + A_{ij}^{(l)} \xrightarrow{d} f(\xi^{(l-1)}) + A_{ij}^{(l)}$$

Then, from the Portmanteau theorem, since the following hold:

$$\begin{cases} f(\alpha_j^{(l-1)}) + A_{ij}^{(l)} \xrightarrow{d} f(\xi^{(l-1)}) + A_{ij}^{(l)} \\ \partial(-\infty, x] = \{x\} \\ \mathbb{P}(f(\xi^{(l-1)}) + A_{ij}^{(l)} = x) = 0 \end{cases}$$

(The third equation holds from the fact that the distribution of $f(\xi^{(l-1)}) + A_{ij}^{(l)}$ r.v. is a shifted Gaussian.)

We have that:

$$\lim_{N \rightarrow \infty} \underbrace{\mathbb{P}(f(\alpha_j^{(l-1)}) + A_{ij}^{(l)} \leq x)}_{=: F_N(x)} = \underbrace{\mathbb{P}(f(\xi^{(l-1)}) + A_{ij}^{(l)} \leq x)}_{=: F(x)}$$

□

C.2.4 Order of the ranking preactivation variance $\text{Var}(\alpha_i^{(l)})$

Assume that the order of the empirical threshold covariance at $x = \xi^{(l)}$ is $O(1/N)$, that is:

$$\text{Cov}\left(\mathbb{1}\{(X_i^{(l)})_j \leq \xi^{(l)}\}, \mathbb{1}\{(X_i^{(l)})_k \leq \xi^{(l)}\}\right) = O(1/N)$$

and assume that Bahadur's representation holds even though the samples are not iid but rather weakly dependent in the vanishing covariance sense. That is, there exists an R_N such that:

$$\alpha_i^{(l)} - \xi^{(l)} = -\frac{\widehat{F}_N(\xi^{(l)}) - p^{(l)}}{F'(\xi^{(l)})} + R_N, \quad R_N = o_p(N^{-1/2})$$

and finally, assume that the sequence $\{NR_N^2\}_{N \geq 1}$ is uniformly integrable. Then we will show that

$$\text{Var}(\alpha_i^{(l)}) = O(1/N)$$

Proof. In C.2.2, we show that, for any point $x \in \mathbb{R}$:

$$\text{Var}(\widehat{F}_N(x)) = \frac{1}{N} F_N(x)(1 - F_N(x)) + \frac{N-1}{N} \text{Cov}\left(\mathbb{1}\{(X_i^{(l)})_j \leq x\}, \mathbb{1}\{(X_i^{(l)})_k \leq x\}\right)$$

By taking $x = \xi^{(l)}$ this gives us

$$\text{Var}(\widehat{F}_N(x)) = \frac{1}{N} F_N(\xi^{(l)})(1 - F_N(\xi^{(l)})) + \frac{N-1}{N} \text{Cov}\left(\mathbb{1}\{(X_i^{(l)})_j \leq \xi^{(l)}\}, \mathbb{1}\{(X_i^{(l)})_k \leq \xi^{(l)}\}\right)$$

Again, by the appendix in C.2.2, since it was proven for all $x \in \mathbb{R}$:

$$\frac{1}{N} F_N(\xi^{(l)})(1 - F_N(\xi^{(l)})) = O(1/N)$$

Along with the first assumption that the empirical threshold covariance's order is $O(1/N)$, this gives us:

$$\text{Var}(\widehat{F}_N(x)) = O(1/N)$$

By the second assumption, we have

$$\alpha_i^{(l)} - \xi^{(l)} = -\frac{\widehat{F}_N(\xi^{(l)}) - p^{(l)}}{F'(\xi^{(l)})} + R_N$$

Taking the variance gives us:

$$\begin{aligned} \text{Var}(\alpha_i^{(l)}) &= \text{Var}(\alpha_i^{(l)} - \xi^{(l)}) = \text{Var}\left(\frac{\widehat{F}_N(\xi^{(l)}) - p^{(l)}}{F'(\xi^{(l)})}\right) + \text{Var}(R_N) \\ &= \frac{\text{Var}(\widehat{F}_N(\xi^{(l)}))}{(F'(\xi^{(l)}))^2} + o(1/N) && (\text{Var}(R_N) \leq \mathbb{E}[(R_N)^2] = o(1/N)) \\ &= O(1/N) + o(1/N) && (\text{Var}(\widehat{F}_N(\xi^{(l)})) = O(1/N)) \\ &= O(1/N) \end{aligned}$$

where the covariance between the linear term and R_N , by Cauchy-Schwarz is of order $o(1/N)$ and thus was ignored. The fact that $\mathbb{E}[(R_N)^2] = o(1/N)$ is obtained from $R_N = o_p(N^{-1/2})$ in combination with the fact that the series $\{NR_N^2\}_{N \geq 1}$ is assumed to be uniformly integrable. $\square$

C.3 Two-input ranking Covariance $\text{Cov}(\alpha_{i;a}^{(l)}, \alpha_{i;b}^{(l)})$

C.3.1 Distribution of the joint ranking input $(y_{j;a}^{(l-1)} + A_{ij}^{(l)}, y_{j;b}^{(l-1)} + A_{ij}^{(l)})$

To derive the joint c.d.f. of a typical coordinate j for two different inputs' entries $y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)}$, we use that the same ranking bias coordinate $A_{ij}^{(l)}$ appears in both entries:

$$(X_{i;a}^{(l)})_j = y_{j;a}^{(l-1)} + A_{ij}^{(l)}, \quad (X_{i;b}^{(l)})_j = y_{j;b}^{(l-1)} + A_{ij}^{(l)}.$$

We also use that $A_{ij}^{(l)} \sim \mathcal{N}(0, \sigma_a^2)$ and that

$$A_{ij}^{(l)} \perp (y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)}).$$

For fixed j , define

$$F_{(X_{i;a}^{(l)})_j, (X_{i;b}^{(l)})_j}(x_1, x_2) = \mathbb{P}\left((X_{i;a}^{(l)})_j \leq x_1, (X_{i;b}^{(l)})_j \leq x_2\right).$$

Then

$$\begin{aligned}
& F_{(X_{i;a}^{(l)})_j, (X_{i;b}^{(l)})_j}(x_1, x_2) \\
&= \mathbb{P}\left((X_{i;a}^{(l)})_j \leq x_1, (X_{i;b}^{(l)})_j \leq x_2\right) \\
&= \mathbb{E}\left[\mathbb{1}\left\{(X_{i;a}^{(l)})_j \leq x_1, (X_{i;b}^{(l)})_j \leq x_2\right\}\right] \\
&= \mathbb{E}\left[\mathbb{E}\left[\mathbb{1}\left\{(X_{i;a}^{(l)})_j \leq x_1, (X_{i;b}^{(l)})_j \leq x_2\right\} \mid y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)}\right]\right] \quad (\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X \mid Z]]) \\
&= \mathbb{E}\left[\mathbb{P}\left((X_{i;a}^{(l)})_j \leq x_1, (X_{i;b}^{(l)})_j \leq x_2 \mid y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)}\right)\right] \\
&= \mathbb{E}\left[\mathbb{P}\left(y_{j;a}^{(l-1)} + A_{ij}^{(l)} \leq x_1, y_{j;b}^{(l-1)} + A_{ij}^{(l)} \leq x_2 \mid y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)}\right)\right] \\
&= \mathbb{E}\left[\mathbb{P}\left(A_{ij}^{(l)} \leq x_1 - y_{j;a}^{(l-1)}, A_{ij}^{(l)} \leq x_2 - y_{j;b}^{(l-1)} \mid y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)}\right)\right] \\
&= \mathbb{E}\left[\mathbb{P}\left(A_{ij}^{(l)} \leq \min\left\{x_1 - y_{j;a}^{(l-1)}, x_2 - y_{j;b}^{(l-1)}\right\} \mid y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)}\right)\right] \\
&= \mathbb{E}\left[F_{A_{ij}^{(l)} \mid y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)}}\left(\min\left\{x_1 - y_{j;a}^{(l-1)}, x_2 - y_{j;b}^{(l-1)}\right\}\right)\right] \\
&= \mathbb{E}\left[F_{A_{ij}^{(l)}}\left(\min\left\{x_1 - y_{j;a}^{(l-1)}, x_2 - y_{j;b}^{(l-1)}\right\}\right)\right] \quad (A_{ij}^{(l)} \perp (y_{j;a}^{(l-1)}, y_{j;b}^{(l-1)})) \\
&= \mathbb{E}\left[\Phi\left(\frac{\min\left\{x_1 - y_{j;a}^{(l-1)}, x_2 - y_{j;b}^{(l-1)}\right\}}{\sigma_a}\right)\right] \quad (F_{A_{ij}^{(l)}}(t) = \Phi(t/\sigma_a))
\end{aligned}$$

C.3.2 Order of the two-input ranking covariance $\text{Cov}(\alpha_{i;a}^{(l)}, \alpha_{i;b}^{(l)})$

Similarly to the variance order derivation, assume that

$$\text{Cov}\left(\mathbb{1}\{(X_{i;a}^{(l)})_j \leq x_1\}, \mathbb{1}\{(X_{i;b}^{(l)})_k \leq x_2\}\right) = O(1/N), \quad j \neq k \quad (\text{C.3.1})$$

and assume that although with the samples not being iid, the Bahadur representation holds:

$$\alpha_{i;c}^{(l)} - \xi_c^{(l)} = -\frac{\widehat{F}_{N,c}(\xi_c^{(l)}) - p^{(l)}}{(F_c^{(l)})'(\xi_c^{(l)})} + R_{N,c}, \quad R_{N,c} = o_p(N^{-1/2}), \quad \forall c \in \{a, b\} \quad (\text{C.3.2})$$

Moreover assume that the sequence $\{NR_{N,c}^2\}_{N \geq 1}$ is uniformly integrable for each $c \in \{a, b\}$. That gives us

$$\mathbb{E}[R_{N,c}^2] = o(1/N), \quad \forall c \in \{a, b\}. \quad (\text{C.3.3})$$

We have that $\text{Cov}(\widehat{F}_{N,a}(x_1), \widehat{F}_{N,b}(x_2))$ is equal to:

$$\begin{aligned}
&= \text{Cov}\left(\frac{1}{N} \sum_{j=1}^N \mathbb{1}\{(X_{i;a}^{(l)})_j \leq x_1\}, \frac{1}{N} \sum_{k=1}^N \mathbb{1}\{(X_{i;b}^{(l)})_k \leq x_2\}\right) \\
&= \frac{1}{N^2} \text{Cov}\left(\sum_{j=1}^N \mathbb{1}\{(X_{i;a}^{(l)})_j \leq x_1\}, \sum_{k=1}^N \mathbb{1}\{(X_{i;b}^{(l)})_k \leq x_2\}\right) \quad (\text{Cov}(aX, aY) = a^2 \text{Cov}(X, Y)) \\
&= \frac{1}{N^2} \sum_{j=1}^N \sum_{k=1}^N \text{Cov}\left(\mathbb{1}\{(X_{i;a}^{(l)})_j \leq x_1\}, \mathbb{1}\{(X_{i;b}^{(l)})_k \leq x_2\}\right) \\
&\quad (\text{Cov}(\sum_j X_j, \sum_k Y_k) = \sum_j^{N_{l+1}} \sum_k^{N_{l+1}} \text{Cov}(X_j, Y_k)) \\
&= \frac{1}{N^2} \left[\sum_{j=1}^N \text{Cov}\left(\mathbb{1}\{(X_{i;a}^{(l)})_j \leq x_1\}, \mathbb{1}\{(X_{i;b}^{(l)})_j \leq x_2\}\right) + \sum_{j=1}^N \sum_{\substack{k=1 \\ k \neq j}}^N \text{Cov}\left(\mathbb{1}\{(X_{i;a}^{(l)})_j \leq x_1\}, \mathbb{1}\{(X_{i;b}^{(l)})_k \leq x_2\}\right) \right]
\end{aligned}$$

where in the last line we split the sum to the diagonal and off diagonal terms.

Now, for any $x_1, x_2 \in \mathbb{R}$, for the covariance of the diagonal terms, by the definition of the covariance we have that

$$\begin{aligned} \text{Cov}\left(\mathbb{1}\{(X_{i:a}^{(l)})_j \leq x_1\}, \mathbb{1}\{(X_{i:b}^{(l)})_j \leq x_2\}\right) &= \mathbb{P}\left((X_{i:a}^{(l)})_j \leq x_1, (X_{i:b}^{(l)})_j \leq x_2\right) - \mathbb{P}\left((X_{i:a}^{(l)})_j \leq x_1\right) \mathbb{P}\left((X_{i:b}^{(l)})_j \leq x_2\right) \\ &= O(1), \end{aligned}$$

since as a difference of probabilities it is bounded by some constant. Combining this, with the assumption (C.3.1) we have that:

$$\begin{aligned} \text{Cov}(\widehat{F}_{N,a}(x_1), \widehat{F}_{N,b}(x_2)) &= \frac{1}{N^2} [N \cdot O(1) + N(N-1) \cdot O(1/N)] \\ &= O(1/N) \end{aligned}$$

Now,

$$\begin{aligned} \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) &= \text{Cov}(\alpha_{i:a}^{(l)} - \xi_a^{(l)}, \alpha_{i:b}^{(l)} - \xi_b^{(l)}) \\ &= \text{Cov}\left(-\frac{\widehat{F}_{N,a}(\xi_a^{(l)}) - p^{(l)}}{(F_a^{(l)})'(\xi_a^{(l)})} + R_{N,a}, -\frac{\widehat{F}_{N,b}(\xi_b^{(l)}) - p^{(l)}}{(F_b^{(l)})'(\xi_b^{(l)})} + R_{N,b}\right) \quad (\text{By eq. C.3.2}) \\ &= \text{Cov}\left(-\frac{\widehat{F}_{N,a}(\xi_a^{(l)}) - p^{(l)}}{(F_a^{(l)})'(\xi_a^{(l)})}, -\frac{\widehat{F}_{N,b}(\xi_b^{(l)}) - p^{(l)}}{(F_b^{(l)})'(\xi_b^{(l)})}\right) + o(1/N) \\ &= \frac{\text{Cov}\left(\widehat{F}_{N,a}(\xi_a^{(l)}) - p^{(l)}, \widehat{F}_{N,b}(\xi_b^{(l)}) - p^{(l)}\right)}{(F_a^{(l)})'(\xi_a^{(l)})(F_b^{(l)})'(\xi_b^{(l)})} + o(1/N) \\ &= \frac{\text{Cov}\left(\widehat{F}_{N,a}(\xi_a^{(l)}), \widehat{F}_{N,b}(\xi_b^{(l)})\right)}{(F_a^{(l)})'(\xi_a^{(l)})(F_b^{(l)})'(\xi_b^{(l)})} + o(1/N) \\ &= O(1/N) + o(1/N) = O(1/N) \end{aligned}$$

The remainder terms are $o(1/N)$ because by Cauchy-Schwarz and eq. C.3.3:

$$|\text{Cov}(R_{N,a}, R_{N,b})| \leq \sqrt{\text{Var}(R_{N,a}) \text{Var}(R_{N,b})} \leq \sqrt{\mathbb{E}[R_{N,a}^2] \mathbb{E}[R_{N,b}^2]} = o(1/N)$$

and for $\text{Cov}(\widehat{F}_{N,a}(\xi_a^{(l)}) - p^{(l)}, R_{N,b})$ (same argument goes for $\text{Cov}(\widehat{F}_{N,b}(\xi_b^{(l)}) - p^{(l)}, R_{N,a})$) we have that:

$$\begin{aligned} \left| \text{Cov}(\widehat{F}_{N,a}(\xi_a^{(l)}) - p^{(l)}, R_{N,b}) \right| &= \left| \text{Cov}(\widehat{F}_{N,a}(\xi_a^{(l)}), R_{N,b}) \right| \\ &\leq \sqrt{\text{Var}(\widehat{F}_{N,a}(\xi_a^{(l)})) \text{Var}(R_{N,b})} \quad (\text{Cauchy-Schwarz}) \\ &\leq \sqrt{\text{Var}(\widehat{F}_{N,a}(\xi_a^{(l)})) \mathbb{E}[R_{N,b}^2]} \quad (\text{Var}(X) \leq \mathbb{E}[X^2]) \\ &= \sqrt{O(1/N) o(1/N)} = \sqrt{o(1/N^2)} = o(1/N). \end{aligned}$$

where we know $\text{Var}(\widehat{F}_{N,a}(x)) = O(1/N)$, $\forall x \in \mathbb{R}$ from section C.2.4.

C.4 Hybrid MRL derivations

C.4.1 MRL preactivation mean $\mathbb{E}[z_i^{(l)}]$ derivation

We have that

$$\begin{aligned}
\mathbb{E}[z_i^{(l)}] &= \mathbb{E}[\lambda \alpha_i^{(l)}] + \mathbb{E}[(1 - \lambda) \beta_i^{(l)}] \\
&= \lambda \mathbb{E}[\alpha_i^{(l)}] + (1 - \lambda) \mathbb{E} \left[\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)} \right] \\
&= \lambda \mathbb{E}[\alpha_i^{(l)}] + (1 - \lambda) \left(\sum_{j=1}^{N_{l-1}} \mathbb{E}[W_{ij}^{(l)} y_j^{(l-1)}] + \mathbb{E}[b_i^{(l)}] \right) && (\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]) \\
&= \lambda \mathbb{E}[\alpha_i^{(l)}] + (1 - \lambda) \left(\sum_{j=1}^{N_{l-1}} \mathbb{E}[W_{ij}^{(l)}] \mathbb{E}[y_j^{(l-1)}] + \mathbb{E}[b_i^{(l)}] \right) && (W_{ij}^{(l)} \perp y_j^{(l-1)}) \\
&= \lambda \mathbb{E}[\alpha_i^{(l)}] && (\mathbb{E}[W_{ij}^{(l)}] = \mathbb{E}[b_i^{(l)}] = 0)
\end{aligned}$$

C.4.2 MRL preactivation variance $\text{Var}(z_i^{(l)})$ derivation

Since λ is deterministic,

$$\begin{aligned}
\text{Var}(z_i^{(l)}) &= \text{Var} \left(\lambda \alpha_i^{(l)} + (1 - \lambda) \beta_i^{(l)} \right) \\
&= \lambda^2 \text{Var}(\alpha_i^{(l)}) + (1 - \lambda)^2 \text{Var}(\beta_i^{(l)}) + 2\lambda(1 - \lambda) \text{Cov}(\alpha_i^{(l)}, \beta_i^{(l)}).
\end{aligned}$$

We will now compute the linear variance term and show that the cross covariance vanishes.

$$\begin{aligned}
\text{Var}(\beta_i^{(l)}) &= \mathbb{E} \left[\left(\beta_i^{(l)} \right)^2 \right] - \left(\mathbb{E}[\beta_i^{(l)}] \right)^2 \\
&= \mathbb{E}[(\beta_i^{(l)})^2] \\
&= \mathbb{E} \left[\left(\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)} \right)^2 \right] \\
&= \mathbb{E} \left[\sum_{j=1}^{N_{l-1}} \sum_{k=1}^{N_{l-1}} W_{ij}^{(l)} W_{ik}^{(l)} y_j^{(l-1)} y_k^{(l-1)} \right] + 2 \mathbb{E} \left[\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} b_i^{(l)} \right] + \mathbb{E}[(b_i^{(l)})^2] \\
&= \sum_{j=1}^{N_{l-1}} \sum_{k=1}^{N_{l-1}} \mathbb{E}[W_{ij}^{(l)} W_{ik}^{(l)}] \mathbb{E}[y_j^{(l-1)} y_k^{(l-1)}] + 0 + \sigma_b^2 \\
&\hspace{15em} (W_{ij}^{(l)} \perp y_j^{(l-1)}, b_i^{(l)} \perp (W_{ij}^{(l)}, y_j^{(l-1)}), \mathbb{E}[b_i^{(l)}] = 0) \\
&= \sum_{j=1}^{N_{l-1}} \mathbb{E}[(W_{ij}^{(l)})^2] \mathbb{E}[(y_j^{(l-1)})^2] + \sigma_b^2 && (\{W_{ij}^{(l)}\} \text{ iid}, \mathbb{E}[W_{ij}^{(l)}] = 0) \\
&= \frac{\sigma_w^2}{N_{l-1}} \sum_{j=1}^{N_{l-1}} \mathbb{E}[(y_j^{(l-1)})^2] + \sigma_b^2 && (\mathbb{E}[(W_{ij}^{(l)})^2] = \sigma_w^2 / N_{l-1}) \\
&= \sigma_w^2 \mathbb{E}[(y_j^{(l-1)})^2] + \sigma_b^2 && (\{y_j^{(l-1)}\}_{j=1}^{N_{l-1}} \text{ identically distr over } j)
\end{aligned}$$

For the cross covariance we have that:

$$\begin{aligned}
\text{Cov}(\alpha_i^{(l)}, \beta_i^{(l)}) &= \mathbb{E}[\alpha_i^{(l)} \beta_i^{(l)}] && (\mathbb{E}[\alpha_i^{(l)}] \mathbb{E}[\beta_i^{(l)}] = 0) \\
&= \mathbb{E} \left[R_{r^{(l)}} \left(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)} \right) \left(\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)} \right) \right] \\
&= \mathbb{E} \left[\mathbb{E} \left[R_{r^{(l)}} \left(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)} \right) \left(\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)} \right) \middle| \mathbf{y}^{(l-1)} \right] \right] && (\text{tower property}) \\
&= \mathbb{E} \left[\mathbb{E} \left[R_{r^{(l)}} \left(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)} \right) \middle| \mathbf{y}^{(l-1)} \right] \mathbb{E} \left[\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_j^{(l-1)} + b_i^{(l)} \middle| \mathbf{y}^{(l-1)} \right] \right] \\
&&& (\mathbf{a}_i^{(l)} \perp (W^{(l)}, \mathbf{b}^{(l)})) \\
&= \mathbb{E} \left[\mathbb{E} \left[R_{r^{(l)}} \left(\mathbf{y}^{(l-1)} + \mathbf{a}_i^{(l)} \right) \middle| \mathbf{y}^{(l-1)} \right] \cdot 0 \right] && (\mathbb{E}[W_{ij}^{(l)}] = \mathbb{E}[b_i^{(l)}] = 0) \\
&= 0.
\end{aligned}$$

Putting it all together, we get

$$\text{Var}(z_i^{(l)}) = \lambda^2 \text{Var}(\alpha_i^{(l)}) + (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[(y_j^{(l-1)})^2] + \sigma_b^2)$$

C.4.3 Vanishing threshold covariance for MRL layers

We remind the fact that $z_j^{(l-1)}, z_k^{(l-1)}$ are width dependent although the current notation does not include N . Assume that

$$(z_j^{(l-1)}, z_k^{(l-1)}) \xrightarrow{d} (u, v)$$

where u, v are independent copies of

$$\mathcal{N}(\mu^{(l-1)}, q^{(l-1)}).$$

Then, we will show that the threshold covariance is vanishing.

Since f is continuous, by the continuous mapping theorem we have that

$$(f(z_j^{(l-1)}), f(z_k^{(l-1)})) \xrightarrow{d} (f(u), f(v)).$$

Now, since $A_{ij}^{(l)}, A_{ik}^{(l)}$ are iid and independent of $z_j^{(l-1)}, z_k^{(l-1)}$ we have that:

$$(f(z_j^{(l-1)}) + A_{ij}^{(l)}, f(z_k^{(l-1)}) + A_{ik}^{(l)}) \xrightarrow{d} (f(u) + A_{ij}^{(l)}, f(v) + A_{ik}^{(l)}).$$

Next, the continuous mapping theorem can be applied for the joint threshold map

$$(s, t) \mapsto (\mathbb{1}\{s \leq x\}, \mathbb{1}\{t \leq x\})$$

since

$$\mathbb{P}(f(u) + A_{ij}^{(l)} = x) = 0, \quad \mathbb{P}(f(v) + A_{ik}^{(l)} = x) = 0.$$

That gives us:

$$\begin{aligned}
& \left(\mathbb{1}\{f(z_j^{(l-1)}) + A_{ij}^{(l)} \leq x\}, \mathbb{1}\{f(z_k^{(l-1)}) + A_{ik}^{(l)} \leq x\} \right) \\
& \xrightarrow{d} \left(\mathbb{1}\{f(u) + A_{ij}^{(l)} \leq x\}, \mathbb{1}\{f(v) + A_{ik}^{(l)} \leq x\} \right).
\end{aligned}$$

Now, since the indicators are bounded, the expectations and the product expectation converge. As such, the covariance converges to the covariance of the limiting indicators, i.e.:

$$\text{Cov} \left(\mathbb{1}\{f(z_j^{(l-1)}) + A_{ij}^{(l)} \leq x\}, \mathbb{1}\{f(z_k^{(l-1)}) + A_{ik}^{(l)} \leq x\} \right) \rightarrow \text{Cov} \left(\mathbb{1}\{f(u) + A_{ij}^{(l)} \leq x\}, \mathbb{1}\{f(v) + A_{ik}^{(l)} \leq x\} \right).$$

But $A_{ij}^{(l)}, A_{ik}^{(l)}$ are independent, and the same holds for u, v from our assumption. Therefore

$$\text{Cov} \left(\mathbb{1}\{f(u) + A_{ij}^{(l)} \leq x\}, \mathbb{1}\{f(v) + A_{ik}^{(l)} \leq x\} \right) = 0.$$

C.4.4 Convergence of the marginal cdf F_N to the limiting marginal cdf F (MRL)

We remind the reader that $z_j^{(l-1)}$ is width dependent, although the dependence on N is suppressed in our notation. We assume that

$$z_j^{(l-1)} \xrightarrow{d} u, \quad u \sim \mathcal{N}(\mu^{(l-1)}, q^{(l-1)}).$$

The width dependent marginal cdf is defined as:

$$F_N(x) = \mathbb{P}((X_i^{(l)})_j \leq x) = \mathbb{P}(f(z_j^{(l-1)}) + A_{ij}^{(l)} \leq x).$$

Since f is continuous, from the continuous mapping theorem we first have that:

$$f(z_j^{(l-1)}) \xrightarrow{d} f(u).$$

Then, since $A_{ij}^{(l)}$ is independent of $z_j^{(l-1)}$ we have that

$$f(z_j^{(l-1)}) + A_{ij}^{(l)} \xrightarrow{d} f(u) + A_{ij}^{(l)}.$$

Then, from the Portmanteau theorem, since the following hold:

$$\begin{cases} f(z_j^{(l-1)}) + A_{ij}^{(l)} \xrightarrow{d} f(u) + A_{ij}^{(l)} \\ \partial(-\infty, x] = \{x\} \\ \mathbb{P}(f(u) + A_{ij}^{(l)} = x) = 0 \end{cases}$$

(The third equation holds from the fact that the distribution of the $f(u) + A_{ij}^{(l)}$ r.v. is a continuous distribution due to the addition of independent Gaussian noise.)

Therefore we have that:

$$\lim_{N \rightarrow \infty} F_N(x) = \lim_{N \rightarrow \infty} \mathbb{P}(f(z_j^{(l-1)}) + A_{ij}^{(l)} \leq x) = \mathbb{P}(f(u) + A_{ij}^{(l)} \leq x) = F(x).$$

where F denotes the limiting marginal cdf.

Since $A_{ij}^{(l)}$ is Gaussian, we have that

$$F(x) = \mathbb{E} \left[\Phi \left(\frac{x - f(u)}{\sigma_a} \right) \right], \quad u \sim \mathcal{N}(\mu^{(l-1)}, q^{(l-1)}).$$

C.4.5 MRL preactivation two-input covariance $\text{Cov}(z_{i;a}^{(l)}, z_{i;b}^{(l)})$ derivation

We have that:

$$\begin{aligned} \text{Cov}(z_{i;a}^{(l)}, z_{i;b}^{(l)}) &= \text{Cov}(\lambda \alpha_{i;a}^{(l)} + (1 - \lambda) \beta_{i;a}^{(l)}, \lambda \alpha_{i;b}^{(l)} + (1 - \lambda) \beta_{i;b}^{(l)}) \\ &= \text{Cov}(\lambda \alpha_{i;a}^{(l)}, \lambda \alpha_{i;b}^{(l)}) + \text{Cov}(\lambda \alpha_{i;a}^{(l)}, (1 - \lambda) \beta_{i;b}^{(l)}) + \text{Cov}((1 - \lambda) \beta_{i;a}^{(l)}, \lambda \alpha_{i;b}^{(l)}) + \text{Cov}((1 - \lambda) \beta_{i;a}^{(l)}, (1 - \lambda) \beta_{i;b}^{(l)}) \\ &= \lambda^2 \text{Cov}(\alpha_{i;a}^{(l)}, \alpha_{i;b}^{(l)}) + (1 - \lambda)^2 \text{Cov}(\beta_{i;a}^{(l)}, \beta_{i;b}^{(l)}) + \lambda(1 - \lambda) (\text{Cov}(\alpha_{i;a}^{(l)}, \beta_{i;b}^{(l)}) + \text{Cov}(\beta_{i;a}^{(l)}, \alpha_{i;b}^{(l)})) \end{aligned}$$

Now we will prove that both $\text{Cov}(\alpha_{i:a}^{(l)}, \beta_{i:b}^{(l)})$, $\text{Cov}(\beta_{i:a}^{(l)}, \alpha_{i:b}^{(l)})$ are equal to zero.

$$\begin{aligned}
\text{Cov}(\alpha_{i:a}^{(l)}, \beta_{i:b}^{(l)}) &= \mathbb{E}[\alpha_{i:a}^{(l)} \beta_{i:b}^{(l)}] - \mathbb{E}[\alpha_{i:a}^{(l)}] \mathbb{E}[\beta_{i:b}^{(l)}] \\
&= \mathbb{E}[\alpha_{i:a}^{(l)} \beta_{i:b}^{(l)}] \quad (\mathbb{E}[\beta_{i:b}^{(l)}] = 0) \\
&= \mathbb{E} \left[R_{r^{(l)}}(\mathbf{y}_a^{(l-1)} + \mathbf{a}_i^{(l)}) \left(\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_{j:b}^{(l-1)} + b_i^{(l)} \right) \right] \\
&= \mathbb{E} \left[\mathbb{E} \left[R_{r^{(l)}}(\mathbf{y}_a^{(l-1)} + \mathbf{a}_i^{(l)}) \left(\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_{j:b}^{(l-1)} + b_i^{(l)} \right) \middle| \mathbf{y}_a^{(l-1)}, \mathbf{y}_b^{(l-1)}, \mathbf{a}_i^{(l)} \right] \right] \\
&\quad \text{(tower property)} \\
&= \mathbb{E} \left[R_{r^{(l)}}(\mathbf{y}_a^{(l-1)} + \mathbf{a}_i^{(l)}) \mathbb{E} \left[\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_{j:b}^{(l-1)} + b_i^{(l)} \middle| \mathbf{y}_a^{(l-1)}, \mathbf{y}_b^{(l-1)}, \mathbf{a}_i^{(l)} \right] \right] \\
&= \mathbb{E} \left[R_{r^{(l)}}(\mathbf{y}_a^{(l-1)} + \mathbf{a}_i^{(l)}) \left(\sum_{j=1}^{N_{l-1}} \mathbb{E}[W_{ij}^{(l)}] y_{j:b}^{(l-1)} + \mathbb{E}[b_i^{(l)}] \right) \right] \\
&\quad ((W^{(l)}, b^{(l)}) \perp (\mathbf{y}_a^{(l-1)}, \mathbf{y}_b^{(l-1)}, \mathbf{a}_i^{(l)})) \\
&= \mathbb{E} \left[R_{r^{(l)}}(\mathbf{y}_a^{(l-1)} + \mathbf{a}_i^{(l)}) \cdot 0 \right] \quad (\mathbb{E}[W_{ij}^{(l)}] = \mathbb{E}[b_i^{(l)}] = 0) \\
&= 0.
\end{aligned}$$

The same argument shows that $\text{Cov}(\beta_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) = 0$ as well.

Now we will derive the covariance of the linear branches $\text{Cov}(\beta_{i:a}^{(l)}, \beta_{i:b}^{(l)})$.

$$\begin{aligned}
\text{Cov}(\beta_{i:a}^{(l)}, \beta_{i:b}^{(l)}) &= \mathbb{E}[\beta_{i:a}^{(l)} \beta_{i:b}^{(l)}] - \mathbb{E}[\beta_{i:a}^{(l)}] \mathbb{E}[\beta_{i:b}^{(l)}] \\
&= \mathbb{E}[\beta_{i:a}^{(l)} \beta_{i:b}^{(l)}] \quad (\mathbb{E}[\beta_{i:a}^{(l)}] = \mathbb{E}[\beta_{i:b}^{(l)}] = 0) \\
&= \mathbb{E} \left[\left(\sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_{j:a}^{(l-1)} + b_i^{(l)} \right) \left(\sum_{k=1}^{N_{l-1}} W_{ik}^{(l)} y_{k:b}^{(l-1)} + b_i^{(l)} \right) \right] \\
&= \mathbb{E} \left[\sum_{j=1}^{N_{l-1}} \sum_{k=1}^{N_{l-1}} W_{ij}^{(l)} W_{ik}^{(l)} y_{j:a}^{(l-1)} y_{k:b}^{(l-1)} \right] + \mathbb{E} \left[b_i^{(l)} \sum_{j=1}^{N_{l-1}} W_{ij}^{(l)} y_{j:a}^{(l-1)} \right] \\
&\quad + \mathbb{E} \left[b_i^{(l)} \sum_{k=1}^{N_{l-1}} W_{ik}^{(l)} y_{k:b}^{(l-1)} \right] + \mathbb{E}[(b_i^{(l)})^2] \\
&= \sum_{j=1}^{N_{l-1}} \sum_{k=1}^{N_{l-1}} \mathbb{E}[W_{ij}^{(l)} W_{ik}^{(l)}] \mathbb{E}[y_{j:a}^{(l-1)} y_{k:b}^{(l-1)}] + 0 + 0 + \sigma_b^2 \\
&\quad (W_{ij}^{(l)} \perp (y_{j:a}^{(l-1)}, y_{k:b}^{(l-1)}), b_i^{(l)} \perp (W^{(l)}, \mathbf{y}_a^{(l-1)}, \mathbf{y}_b^{(l-1)}), \mathbb{E}[b_i^{(l)}] = 0) \\
&= \sum_{j=1}^{N_{l-1}} \mathbb{E}[(W_{ij}^{(l)})^2] \mathbb{E}[y_{j:a}^{(l-1)} y_{j:b}^{(l-1)}] + \sigma_b^2 \quad (\{W_{ij}^{(l)}\} \text{ iid}, \mathbb{E}[W_{ij}^{(l)}] = 0) \\
&= \frac{\sigma_w^2}{N_{l-1}} \sum_{j=1}^{N_{l-1}} \mathbb{E}[y_{j:a}^{(l-1)} y_{j:b}^{(l-1)}] + \sigma_b^2 \quad (\mathbb{E}[(W_{ij}^{(l)})^2] = \sigma_w^2 / N_{l-1}) \\
&= \sigma_w^2 \mathbb{E}[y_{j:a}^{(l-1)} y_{j:b}^{(l-1)}] + \sigma_b^2 \quad (\{y_{j:a}^{(l-1)}, y_{j:b}^{(l-1)}\}_{j=1}^{N_{l-1}} \text{ identically distributed over } j)
\end{aligned}$$

Therefore giving us:

$$\begin{aligned}
\text{Cov}(z_{i:a}^{(l)}, z_{i:b}^{(l)}) &= \lambda^2 \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) + (1 - \lambda)^2 \text{Cov}(\beta_{i:a}^{(l)}, \beta_{i:b}^{(l)}) \\
&= \lambda^2 \text{Cov}(\alpha_{i:a}^{(l)}, \alpha_{i:b}^{(l)}) + (1 - \lambda)^2 (\sigma_w^2 \mathbb{E}[y_{j:a}^{(l-1)} y_{j:b}^{(l-1)}] + \sigma_b^2)
\end{aligned}$$

C.5 Signal propagation derivations

C.5.1 Gaussian ansatz versions of the cdf's and densities

For the second order moment of the activated preactivation $f(z_j^{(l-1)})$ since from the Gaussian ansatz $z_j^{(l-1)} \sim \mathcal{N}(\mu^{(l-1)}, q^{(l-1)})$, it follows that:

$$\begin{aligned}\mathbb{E}[f^2(z_j^{(l-1)})] &= \int_{-\infty}^{\infty} f^2(u) \frac{1}{\sqrt{2\pi q^{(l-1)}}} \exp\left(-\frac{(u - \mu^{(l-1)})^2}{2q^{(l-1)}}\right) du \\ &= \int_{-\infty}^{\infty} f^2(\sqrt{q^{(l-1)}}z + \mu^{(l-1)}) Dz \quad (\text{set } u = \sqrt{q^{(l-1)}}z + \mu^{(l-1)})\end{aligned}$$

where $\int Dz = \frac{1}{\sqrt{2\pi}} \int e^{-z^2/2} dz$. In C.4.4 we proved that the limiting marginal cdf of the entries that enter the ranking function is:

$$F_{(X_i^{(l)})_j}(x) = \mathbb{E}\left[\Phi\left(\frac{x - f(z_j^{(l-1)})}{\sigma_a}\right)\right]$$

now, using the fact that $z_j^{(l-1)} \sim \mathcal{N}(\mu^{(l-1)}, q^{(l-1)})$ we get:

$$\begin{aligned}F_{(X_i^{(l)})_j}(x) &= \mathbb{E}\left[\Phi\left(\frac{x - f(z_j^{(l-1)})}{\sigma_a}\right)\right] \\ &= \int_{-\infty}^{\infty} \Phi\left(\frac{x - f(u)}{\sigma_a}\right) \frac{1}{\sqrt{2\pi q^{(l-1)}}} \exp\left(-\frac{(u - \mu^{(l-1)})^2}{2q^{(l-1)}}\right) du \\ &= \int_{-\infty}^{\infty} \Phi\left(\frac{x - f(\mu^{(l-1)} + \sqrt{q^{(l-1)}}z)}{\sigma_a}\right) Dz \quad (\text{set } u = \sqrt{q^{(l-1)}}z + \mu^{(l-1)})\end{aligned}$$

For two inputs $\mathbf{y}_a^{(0)}, \mathbf{y}_b^{(0)}$, as an extension of the Gaussian ansatz we assume:

$$\begin{pmatrix} z_{j;a}^{(l-1)} \\ z_{j;b}^{(l-1)} \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_a^{(l-1)} \\ \mu_b^{(l-1)} \end{pmatrix}, \begin{pmatrix} q_{aa}^{(l-1)} & q_{ab}^{(l-1)} \\ q_{ab}^{(l-1)} & q_{bb}^{(l-1)} \end{pmatrix}\right)$$

For the second order moment of the activated preactivations $(f(z_{j;a}^{(l-1)}), f(z_{j;b}^{(l-1)}))$, we have that:

$$\mathbb{E}\left[f(z_{j;a}^{(l-1)})f(z_{j;b}^{(l-1)})\right] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(u_1)f(u_2)\varphi_{ab}^{(l-1)}(u_1, u_2) du_1 du_2$$

Where $\varphi_{ab}^{(l-1)}(u_1, u_2)$ is the joint Gaussian density of $(z_{j;a}^{(l-1)}, z_{j;b}^{(l-1)})$. Specifically

$$\begin{aligned}\varphi_{ab}^{(l-1)}(u_1, u_2) &= \frac{1}{2\pi\sqrt{q_{aa}^{(l-1)}q_{bb}^{(l-1)}}\sqrt{1 - (c_{ab}^{(l-1)})^2}} \\ &\cdot \exp\left(-\frac{1}{2(1 - (c_{ab}^{(l-1)})^2)}\left[\frac{(u_1 - \mu_a^{(l-1)})^2}{q_{aa}^{(l-1)}} - 2c_{ab}^{(l-1)}\frac{(u_1 - \mu_a^{(l-1)})(u_2 - \mu_b^{(l-1)})}{\sqrt{q_{aa}^{(l-1)}q_{bb}^{(l-1)}}} + \frac{(u_2 - \mu_b^{(l-1)})^2}{q_{bb}^{(l-1)}}\right]\right),\end{aligned}$$

Now if we set

$$\begin{aligned}u_1 &= \mu_a^{(l-1)} + \sqrt{q_{aa}^{(l-1)}}z_1, \\ u_2 &= \mu_b^{(l-1)} + \sqrt{q_{bb}^{(l-1)}}\left(c_{ab}^{(l-1)}z_1 + \sqrt{1 - (c_{ab}^{(l-1)})^2}z_2\right),\end{aligned}$$

where z_1, z_2 two independent standard Gaussian variables, then we get:

$$\mathbb{E}\left[f(z_{j;a}^{(l-1)})f(z_{j;b}^{(l-1)})\right] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(u_1)f(u_2) Dz_1 Dz_2$$

By section C.3.1, the joint marginal cdf of the entries that enter the ranking functions is equal to:

$$F_{(X_{i;a}^{(l)})_j, (X_{i;b}^{(l)})_j}(x_1, x_2) = \mathbb{E} \left[\Phi \left(\frac{\min \{x_1 - f(z_{j;a}^{(l-1)}), x_2 - f(z_{j;b}^{(l-1)})\}}{\sigma_a} \right) \right]$$

Now using the Gaussian ansatz for the joint density we get:

$$\begin{aligned} F_{(X_{i;a}^{(l)})_j, (X_{i;b}^{(l)})_j}(x_1, x_2) &= \mathbb{E} \left[\Phi \left(\frac{\min \{x_1 - f(z_{j;a}^{(l-1)}), x_2 - f(z_{j;b}^{(l-1)})\}}{\sigma_a} \right) \right] \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \Phi \left(\frac{\min \{x_1 - f(u_1), x_2 - f(u_2)\}}{\sigma_a} \right) \varphi_{ab}^{(l-1)}(u_1, u_2) du_1 du_2, \end{aligned}$$

Using the same substitution we used above we get:

$$F_{(X_{i;a}^{(l)})_j, (X_{i;b}^{(l)})_j}(x_1, x_2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \Phi \left(\frac{\min \{x_1 - f(u_1), x_2 - f(u_2)\}}{\sigma_a} \right) Dz_1 Dz_2.$$

C.5.2 Forward recurrence relations derivations

Preactivation variance recurrence relation

Let

$$T_q(\mu, q) = (1 - \lambda)^2 \left[\sigma_w^2 \int f^2(\mu + \sqrt{q}z) Dz + \sigma_b^2 \right]$$

then

$$q_{aa}^{(l+1)} = T_q(\mu_a^{(l)}, q_{aa}^{(l)}).$$

Expanding $q_{aa}^{(l)}, q_{aa}^{(l+1)}$ and $\mu_a^{(l)}$ about their fixed point we get:

$$q^* + \epsilon^{(l+1)} = T_q(\mu^* + \eta^{(l)}, q^* + \epsilon^{(l)})$$

by taking then the Taylor expansion of T_q at (μ^*, q^*) :

$$q^* + \epsilon^{(l+1)} = T_q(\mu^*, q^*) + \left. \frac{\partial T_q}{\partial \mu_a^{(l)}} \right|_{(\mu^*, q^*)} \eta^{(l)} + \left. \frac{\partial T_q}{\partial q_{aa}^{(l)}} \right|_{(\mu^*, q^*)} \epsilon^{(l)} + O \left(\left\| (\eta^{(l)}, \epsilon^{(l)})^\top \right\|^2 \right)$$

We will now derive $\left. \partial T_q / \partial q_{aa}^{(l)} \right|_{(\mu^*, q^*)}$, we have

$$\begin{aligned} \left. \frac{\partial T_q}{\partial q_{aa}^{(l)}} \right|_{(\mu^*, q^*)} &= \left. \frac{\partial}{\partial q_{aa}^{(l)}} \right|_{(\mu^*, q^*)} (1 - \lambda)^2 \left[\sigma_w^2 \int Dz f^2 \left(\mu_a^{(l)} + \sqrt{q_{aa}^{(l)}} z \right) + \sigma_b^2 \right] \\ &= (1 - \lambda)^2 \sigma_w^2 \int Dz 2f(\mu^* + \sqrt{q^*}z) f'(\mu^* + \sqrt{q^*}z) \frac{z}{2\sqrt{q^*}} \\ &= \frac{(1 - \lambda)^2 \sigma_w^2}{\sqrt{q^*}} \int Dz z f(\mu^* + \sqrt{q^*}z) f'(\mu^* + \sqrt{q^*}z). \end{aligned}$$

Using the identity, $\int Dz z g(z) = \int Dz g'(z)$, we can rewrite this as

$$\begin{aligned} \left. \frac{\partial T_q}{\partial q_{aa}^{(l)}} \right|_{(\mu^*, q^*)} &= (1 - \lambda)^2 \sigma_w^2 \int Dz \left[(f'(\mu^* + \sqrt{q^*}z))^2 + f''(\mu^* + \sqrt{q^*}z) f(\mu^* + \sqrt{q^*}z) \right] \\ &= \chi_1 + (1 - \lambda)^2 \sigma_w^2 \int Dz f''(\mu^* + \sqrt{q^*}z) f(\mu^* + \sqrt{q^*}z). \end{aligned}$$

For the other partial derivative with respect to $\mu_a^{(l)}$ we have:

$$\begin{aligned} \left. \frac{\partial T_q}{\partial \mu_a^{(l)}} \right|_{(\mu^*, q^*)} &= \left. \frac{\partial}{\partial \mu_a^{(l)}} \right|_{(\mu^*, q^*)} (1 - \lambda)^2 \left[\sigma_w^2 \int Dz f^2 \left(\mu_a^{(l)} + \sqrt{q_{aa}^{(l)}} z \right) + \sigma_b^2 \right] \\ &= (1 - \lambda)^2 \left[\sigma_w^2 \int Dz 2f(\mu^* + \sqrt{q^*} z) f'(\mu^* + \sqrt{q^*} z) \right] \end{aligned}$$

Finally giving us:

$$\begin{aligned} \epsilon^{(l+1)} &= 2(1 - \lambda)^2 \sigma_w^2 \left[\int Dz f(\mu^* + \sqrt{q^*} z) f'(\mu^* + \sqrt{q^*} z) \right] \eta^{(l)} \\ &\quad + \left[\chi_1 + (1 - \lambda)^2 \sigma_w^2 \int Dz f''(\mu^* + \sqrt{q^*} z) f(\mu^* + \sqrt{q^*} z) \right] \epsilon^{(l)} \\ &\quad + O \left(\left\| (\eta^{(l)}, \epsilon^{(l)})^\top \right\|^2 \right). \end{aligned}$$

Preactivation mean recurrence relation

We know that:

$$\mu_a^{(l+1)} = \lambda \xi_a^{(l)}$$

where $\xi_a^{(l)}$ satisfies

$$F(\xi_a^{(l)}, \mu_a^{(l)}, q_{aa}^{(l)}) = p, \text{ where } F(\xi, \mu, q) = \int \Phi \left(\frac{\xi - f(\mu + \sqrt{q} z)}{\sigma_a} \right) Dz$$

At the fixed point point of $\mu_a^{(l+1)}$ and $\xi_a^{(l)}$ we have that:

$$\mu^* = \lambda \xi^* \implies \xi^* = \mu^* / \lambda$$

Now we have that:

$$F(\xi_a^{(l)}, \mu_a^{(l-1)}, q_{aa}^{(l-1)}) = p$$

By expanding $\xi_a^{(l)}, \mu_a^{(l)}, q_{aa}^{(l)}$ around their fixed point we get:

$$\begin{aligned} F(\xi^* + \delta^{(l)}, \mu^* + \eta^{(l)}, q^* + \epsilon^{(l)}) &= p \\ F \left(\frac{\mu^* + \eta^{(l+1)}}{\lambda}, \mu^* + \eta^{(l)}, q^* + \epsilon^{(l)} \right) &= p \end{aligned} \quad (\delta^{(l)} = \eta^{(l+1)} / \lambda, \xi^* = \mu^* / \lambda)$$

Now by taking the Taylor expansion of F at $(\mu^* / \lambda, \mu^*, q^*)$ we get:

$$\underbrace{F(\mu^* / \lambda, \mu^*, q^*)}_{=p} + \frac{\partial F}{\partial \xi} \Big|_{(\mu^* / \lambda, \mu^*, q^*)} \eta^{(l+1)} / \lambda + \frac{\partial F}{\partial \mu} \Big|_{(\mu^* / \lambda, \mu^*, q^*)} \eta^{(l)} + \frac{\partial F}{\partial q} \Big|_{(\mu^* / \lambda, \mu^*, q^*)} \epsilon^{(l)} + O \left(\left\| (\eta^{(l+1)} / \lambda, \eta^{(l)}, \epsilon^{(l)}) \right\|^2 \right) = p$$

Solving for $\eta^{(l+1)}$ and using the shorthand $F_x^* = \partial F / \partial x|_{(\mu^* / \lambda, \mu^*, q^*)}$ we have:

$$\eta^{(l+1)} = -\lambda \frac{F_\mu^*}{F_\xi^*} \eta^{(l)} - \lambda \frac{F_q^*}{F_\xi^*} \epsilon^{(l)} + O(\|(\eta^{(l)}, \epsilon^{(l)})\|^2)$$

Then:

$$\begin{aligned} F_\xi^* &= \frac{1}{\sigma_a} \int \phi \left(\frac{\mu^* / \lambda - f(\mu^* + \sqrt{q^*} z)}{\sigma_a} \right) Dz \\ F_\mu^* &= -\frac{1}{\sigma_a} \int \phi \left(\frac{\mu^* / \lambda - f(\mu^* + \sqrt{q^*} z)}{\sigma_a} \right) f'(\mu^* + \sqrt{q^*} z) Dz \end{aligned}$$

and finally for F_q^* by making use of the identity $\int Dz z g(z) = \int Dz g'(z)$:

$$F_q^* = -\frac{1}{2\sigma_a} \int Dz \phi \left(\frac{\mu^* / \lambda - f(\mu^* + \sqrt{q^*} z)}{\sigma_a} \right) \left[f''(\mu^* + \sqrt{q^*} z) + \frac{\left(\frac{\mu^*}{\lambda} - f(\mu^* + \sqrt{q^*} z) \right) [f'(\mu^* + \sqrt{q^*} z)]^2}{\sigma_a^2} \right]$$

Joint mean-variance recurrence relation

Combining the mean and variance perturbation recurrences in a vector

$$\begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix} = \begin{pmatrix} \mu_a^{(l)} - \mu^* \\ q_{aa}^{(l)} - q^* \end{pmatrix}.$$

Then taking the Taylor expansion of the coupled $\mu_a^{(l)}, q_{aa}^{(l)}$ mapping around μ^*, q^*

$$\begin{pmatrix} \eta^{(l+1)} \\ \epsilon^{(l+1)} \end{pmatrix} = J \begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix} + O\left(\left\|\begin{pmatrix} \eta^{(l)} \\ \epsilon^{(l)} \end{pmatrix}\right\|^2\right),$$

where

$$J = \begin{pmatrix} J_{\mu\mu} & J_{\mu q} \\ J_{q\mu} & J_{qq} \end{pmatrix}.$$

We have derived all the entries of the Jacobian of the coupled mean-variance mapping, namely:

$$J_{\mu\mu} = \lambda \frac{\int Dz \phi\left(\frac{\mu^*/\lambda - f(\mu^* + \sqrt{q^*}z)}{\sigma_a}\right) f'(\mu^* + \sqrt{q^*}z)}{\int Dz \phi\left(\frac{\mu^*/\lambda - f(\mu^* + \sqrt{q^*}z)}{\sigma_a}\right)}.$$

$$J_{\mu q} = \frac{\lambda}{2} \frac{\int Dz \phi\left(\frac{\mu^*/\lambda - f(\mu^* + \sqrt{q^*}z)}{\sigma_a}\right) \left[f''(\mu^* + \sqrt{q^*}z) + \frac{\left(\frac{\mu^*}{\lambda} - f(\mu^* + \sqrt{q^*}z)\right) [f'(\mu^* + \sqrt{q^*}z)]^2}{\sigma_a^2} \right]}{\int Dz \phi\left(\frac{\mu^*/\lambda - f(\mu^* + \sqrt{q^*}z)}{\sigma_a}\right)}.$$

$$J_{q\mu} = 2(1 - \lambda)^2 \sigma_w^2 \int Dz f(\mu^* + \sqrt{q^*}z) f'(\mu^* + \sqrt{q^*}z).$$

$$J_{qq} = \chi_1 + (1 - \lambda)^2 \sigma_w^2 \int Dz f''(\mu^* + \sqrt{q^*}z) f(\mu^* + \sqrt{q^*}z).$$

C.5.3 Backward recurrence relations derivations

Following [4], we will derive the backward signal recurrence relations for the MRL network.

By the chain rule:

$$\frac{\partial E}{\partial W_{ij}^{(l)}} = \underbrace{\frac{\partial E}{\partial z_i^{(l)}}}_{\delta_i^{(l)}} \frac{\partial z_i^{(l)}}{\partial W_{ij}^{(l)}} = \delta_i^{(l)} (1 - \lambda) f(z_j^{(l-1)})$$

Then for the $\delta_i^{(l)}$ we have that:

$$\delta_i^{(l)} = \frac{\partial E}{\partial z_i^{(l)}} = \sum_j^{N_{l+1}} \frac{\partial E}{\partial z_j^{(l+1)}} \frac{\partial z_j^{(l+1)}}{\partial z_i^{(l)}} = \sum_j^{N_{l+1}} \delta_j^{(l+1)} \frac{\partial z_j^{(l+1)}}{\partial z_i^{(l)}}$$

For the derivative of j -th preactivation of $l+1$ layer w.r.t. to the i -th preactivation of the l layer we have that:

$$\begin{aligned} \frac{\partial z_j^{(l+1)}}{\partial z_i^{(l)}} &= \frac{\partial}{\partial z_i^{(l)}} \left[\lambda R_{r(l+1)}(\mathbf{y}^{(l)} + \mathbf{a}_j^{(l+1)}) + (1 - \lambda) \left(\sum_{k=1}^{N_l} W_{jk}^{(l+1)} y_k^{(l)} + b_j^{(l+1)} \right) \right] \\ &= \lambda \frac{\partial R_{r(l+1)}(\mathbf{y}^{(l)} + \mathbf{a}_j^{(l+1)})}{\partial z_i^{(l)}} + (1 - \lambda) W_{ji}^{(l+1)} f'(z_i^{(l)}) \\ &= \lambda \mathbb{1} \left\{ (f(\mathbf{z}^{(l)}) + \mathbf{a}_j^{(l+1)})_{r(l+1)} = f(z_i^{(l)}) + A_{ji}^{(l+1)} \right\} f'(z_i^{(l)}) + (1 - \lambda) W_{ji}^{(l+1)} f'(z_i^{(l)}) \\ &= f'(z_i^{(l)}) \left[\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right], \end{aligned}$$

where $S_{ji}^{(l+1)} = \mathbb{1} \left\{ (f(\mathbf{z}^{(l)}) + \mathbf{a}_j^{(l+1)})_{r^{(l+1)}} = f(z_i^{(l)}) + A_{ji}^{(l+1)} \right\}$.

Now, note that since we add the iid Gaussian noise vector $\mathbf{a}_j^{(l+1)}$ to the vector $\mathbf{y}^{(l)}$, ranking ties of $(\mathbf{y}^{(l)} + \mathbf{a}_j^{(l+1)})$ entries occur with probability zero, as such the ranking function is differentiable almost surely.

Thus,

$$\delta_i^{(l)} = f'(z_i^{(l)}) \sum_j^{N_{l+1}} \delta_j^{(l+1)} \left[\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right]$$

We now briefly show that the scale of fluctuations of the gradient of weights in a layer will be proportional to $\mathbb{E}[(\delta_i^{(l)})^2]$.

$$\begin{aligned} \|\nabla_{W^{(l)}} E\|_F^2 &= \sum_i^{N_l} \sum_{j=1}^{N_{l-1}} \left(\frac{\partial E}{\partial W_{ij}^{(l)}} \right)^2 \approx N_l N_{l-1} \mathbb{E} \left[\left(\frac{\partial E}{\partial W_{ij}^{(l)}} \right)^2 \right] \\ &= N_l N_{l-1} (1 - \lambda)^2 \mathbb{E}[(\delta_i^{(l)})^2 f^2(z_j^{(l-1)})] \\ &= N_l N_{l-1} (1 - \lambda)^2 \mathbb{E}[(\delta_i^{(l)})^2] \mathbb{E}[f^2(z_j^{(l-1)})] \end{aligned}$$

where the last line follows from the mean field decorrelation approximation. Hence

$$\|\nabla_{W^{(l)}} E\|_F^2 \propto \mathbb{E}[(\delta_i^{(l)})^2]$$

Now we will derive the recursive relation for $\mathbb{E}[(\delta_i^{(l)})^2]$, first:

$$\mathbb{E}[(\delta_i^{(l)})^2] = \mathbb{E} \left[(f'(z_i^{(l)}))^2 \sum_{j=1}^{N_{l+1}} \sum_k^{N_{l+1}} \left(\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right) \left(\lambda S_{ki}^{(l+1)} + (1 - \lambda) W_{ki}^{(l+1)} \right) \delta_j^{(l+1)} \delta_k^{(l+1)} \right]$$

we split the double summation into diagonal terms and off diagonal terms, i.e.:

$$\sum_j^{N_{l+1}} \left(\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right)^2 (\delta_j^{(l+1)})^2 + \sum_{j \neq k} \left(\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right) \left(\lambda S_{ki}^{(l+1)} + (1 - \lambda) W_{ki}^{(l+1)} \right) \delta_j^{(l+1)} \delta_k^{(l+1)}$$

For the diagonal:

$$\mathbb{E} \left[(f'(z_i^{(l)}))^2 \sum_j^{N_{l+1}} \left(\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right)^2 (\delta_j^{(l+1)})^2 \right] \approx \mathbb{E}[(f'(z_i^{(l)}))^2] \sum_{j=1}^{N_{l+1}} \mathbb{E} \left[\left(\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right)^2 \right] \mathbb{E}[(\delta_j^{(l+1)})^2]$$

Then

$$\begin{aligned} \mathbb{E} \left[\left(\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right)^2 \right] &= \lambda^2 \mathbb{E}[(S_{ji}^{(l+1)})^2] + 2\lambda(1 - \lambda) \mathbb{E}[S_{ji}^{(l+1)} W_{ji}^{(l+1)}] + (1 - \lambda)^2 \mathbb{E}[(W_{ji}^{(l+1)})^2] \\ &\approx \lambda^2 / N_l + (1 - \lambda)^2 \sigma_w^2 / N_l \end{aligned}$$

where we approximated $\mathbb{E}[S_{ji}^{(l+1)}] \approx 1/N_l$, that is, each entry of the r.v. $(\mathbf{y}^{(l)} + \mathbf{a}_j^{(l+1)})$ has an equal probability of being the $r^{(l+1)}$ -th smallest entry. The expectation of the product of $S_{ji}^{(l+1)}$ and $W_{ji}^{(l+1)}$ is zero because they're independent and $W_{ji}^{(l+1)}$ is zero-mean.

Therefore, for the diagonal we have:

$$\begin{aligned} \mathbb{E} \left[(f'(z_i^{(l)}))^2 \sum_j^{N_{l+1}} \left(\lambda S_{ji}^{(l+1)} + (1 - \lambda) W_{ji}^{(l+1)} \right)^2 (\delta_j^{(l+1)})^2 \right] &\approx \frac{1}{N_l} \mathbb{E}[(f'(z_i^{(l)}))^2] (\lambda^2 + (1 - \lambda)^2 \sigma_w^2) \sum_{j=1}^{N_{l+1}} \mathbb{E}[(\delta_j^{(l+1)})^2] \\ &= \frac{N_{l+1}}{N_l} \mathbb{E}[(f'(z_i^{(l)}))^2] (\lambda^2 + (1 - \lambda)^2 \sigma_w^2) \mathbb{E}[(\delta_j^{(l+1)})^2] \\ &\quad (\{\delta_j^{(l+1)}\}_{j=1}^{N_{l+1}} \text{ identically distr.}) \end{aligned}$$

Now for the off-diagonal:

$$\begin{aligned} & \sum_{j \neq k} \mathbb{E} \left[(f'(z_i^{(l)}))^2 (\lambda S_{ji}^{(l+1)} + (1-\lambda)W_{ji}^{(l+1)}) (\lambda S_{ki}^{(l+1)} + (1-\lambda)W_{ki}^{(l+1)}) \delta_j^{(l+1)} \delta_k^{(l+1)} \right] \\ & \approx \mathbb{E} \left[(f'(z_i^{(l)}))^2 \right] \sum_{j \neq k} \mathbb{E} \left[(\lambda S_{ji}^{(l+1)} + (1-\lambda)W_{ji}^{(l+1)}) (\lambda S_{ki}^{(l+1)} + (1-\lambda)W_{ki}^{(l+1)}) \right] \mathbb{E} \left[\delta_j^{(l+1)} \delta_k^{(l+1)} \right] \end{aligned}$$

For the middle term:

$$\begin{aligned} & \mathbb{E} \left[(\lambda S_{ji}^{(l+1)} + (1-\lambda)W_{ji}^{(l+1)}) (\lambda S_{ki}^{(l+1)} + (1-\lambda)W_{ki}^{(l+1)}) \right] \\ & = \lambda^2 \mathbb{E}[S_{ji}^{(l+1)} S_{ki}^{(l+1)}] + \lambda(1-\lambda) \left(\mathbb{E}[S_{ji}^{(l+1)} W_{ki}^{(l+1)}] + \mathbb{E}[W_{ji}^{(l+1)} S_{ki}^{(l+1)}] \right) + (1-\lambda)^2 \mathbb{E}[W_{ji}^{(l+1)} W_{ki}^{(l+1)}] \\ & = \lambda^2 \mathbb{E}[S_{ji}^{(l+1)} S_{ki}^{(l+1)}] + 0 + 0 + (1-\lambda)^2 \mathbb{E}[W_{ji}^{(l+1)} W_{ki}^{(l+1)}] \quad (S_{ji}^{(l+1)} \perp W_{ki}^{(l+1)}, \mathbb{E}[W_{ki}^{(l+1)}] = 0) \\ & = \lambda^2 \mathbb{E}[S_{ji}^{(l+1)} S_{ki}^{(l+1)}] \quad (\{W_{ij}^{(l+1)}\}_{j=1, i=1}^{N_{l+1}, N_l} \text{ i.i.d.}) \\ & \approx \lambda^2 / N_l^2, \end{aligned}$$

where in the final line we used the approximation $\mathbb{E}[S_{ji}^{(l+1)} S_{ki}^{(l+1)}] \approx \mathbb{E}[S_{ji}^{(l+1)}] \mathbb{E}[S_{ki}^{(l+1)}] \approx 1/N_l^2$.

Therefore:

$$\begin{aligned} & \sum_{j \neq k} \mathbb{E} \left[(f'(z_i^{(l)}))^2 (\lambda S_{ji}^{(l+1)} + (1-\lambda)W_{ji}^{(l+1)}) (\lambda S_{ki}^{(l+1)} + (1-\lambda)W_{ki}^{(l+1)}) \delta_j^{(l+1)} \delta_k^{(l+1)} \right] \\ & \approx \frac{1}{N_l^2} \mathbb{E} \left[(f'(z_i^{(l)}))^2 \right] \lambda^2 \sum_{j \neq k} \mathbb{E}[\delta_j^{(l+1)} \delta_k^{(l+1)}] \\ & \approx \frac{1}{N_l^2} \mathbb{E} \left[(f'(z_i^{(l)}))^2 \right] \lambda^2 \sum_{j \neq k} \mathbb{E}[\delta_j^{(l+1)}] \mathbb{E}[\delta_k^{(l+1)}] \\ & \approx \frac{1}{N_l^2} \mathbb{E} \left[(f'(z_i^{(l)}))^2 \right] \lambda^2 \sum_{j \neq k} \left(\mathbb{E}[\delta_j^{(l+1)}] \right)^2 \quad (\{\delta_j^{(l+1)}\}_{j=1}^{N_{l+1}} \text{ ident. distr.}) \\ & = \frac{N_{l+1}(N_{l+1}-1)}{N_l^2} \mathbb{E} \left[(f'(z_i^{(l)}))^2 \right] \lambda^2 \left(\mathbb{E}[\delta_j^{(l+1)}] \right)^2 \end{aligned}$$

In the third-to-last line we use the empirically supported approximation that $\text{Cov}(\delta_j^{(l+1)}, \delta_k^{(l+1)}) \approx 0$.

Finally, giving us that:

$$\mathbb{E}[(\delta_i^{(l)})^2] \approx \frac{N_{l+1}}{N_l} \mathbb{E}[(f'(z_i^{(l)}))^2] (\lambda^2 + (1-\lambda)^2 \sigma_w^2) \mathbb{E}[(\delta_j^{(l+1)})^2] + \frac{N_{l+1}(N_{l+1}-1)}{N_l^2} \mathbb{E}[(f'(z_i^{(l)}))^2] \lambda^2 \left(\mathbb{E}[\delta_j^{(l+1)}] \right)^2 \quad (\text{C.5.1})$$

What only remains is $\mathbb{E}[\delta_i^{(l)}]$, similarly:

$$\begin{aligned} \mathbb{E}[\delta_i^{(l)}] & = \mathbb{E} \left[f'(z_i^{(l)}) \sum_{j=1}^{N_{l+1}} \delta_j^{(l+1)} (\lambda S_{ji}^{(l+1)} + (1-\lambda)W_{ji}^{(l+1)}) \right] \\ & \approx \mathbb{E}[f'(z_i^{(l)})] \sum_{j=1}^{N_{l+1}} \mathbb{E}[\delta_j^{(l+1)}] (\lambda \mathbb{E}[S_{ji}^{(l+1)}] + (1-\lambda) \mathbb{E}[W_{ji}^{(l+1)}]) \\ & = \frac{N_{l+1}}{N_l} \lambda \mathbb{E}[f'(z_i^{(l)})] \mathbb{E}[\delta_j^{(l+1)}] \end{aligned}$$

If we denote

$$\mathbb{E}[\delta_i^{(l)}] = \tilde{\mu}^{(l)} \quad \text{and} \quad \mathbb{E}[(\delta_i^{(l)})^2] = \tilde{q}^{(l)}$$

Then we get the following coupled first and second moment recurrence relation for the $\delta_i^{(l)}$:

$$\begin{aligned}\tilde{q}^{(l)} &= \mathbb{E}[(f'(z_i^{(l)}))^2] \left[\frac{N_{l+1}}{N_l} (\lambda^2 + (1-\lambda)^2 \sigma_w^2) \tilde{q}^{(l+1)} + \frac{N_{l+1}(N_{l+1}-1)}{N_l^2} \lambda^2 (\tilde{\mu}^{(l+1)})^2 \right] \\ (\tilde{\mu}^{(l)})^2 &= \left(\frac{N_{l+1}}{N_l} \right)^2 \lambda^2 \mathbb{E}^2[f'(z_i^{(l)})] (\tilde{\mu}^{(l+1)})^2\end{aligned}$$

Moreover, we empirically found that $\tilde{q}^{(l)}/(\tilde{\mu}^{(l)})^2 \gg 1$, as such we may approximate:

$$\tilde{q}^{(l)} \approx \frac{N_{l+1}}{N_l} \mathbb{E}[(f'(z_i^{(l)}))^2] (\lambda^2 + (1-\lambda)^2 \sigma_w^2) \tilde{q}^{(l+1)}$$

And if we use the fact that $q^{(l)} \approx q^*$ since the depth scale for the variance is short ranged and take exclusively constant width networks (i.e. $N_l = N_{l+1}$), we obtain a formula similar to Schnoeholz et al. in [4]:

$$\tilde{q}^{(l)} \approx \chi_1 \left(\frac{\lambda^2}{(1-\lambda)^2 \sigma_w^2} + 1 \right) \tilde{q}^{(l+1)}$$

This gives us the following depth scale for the backward propagation of the gradients:

$$\tilde{q}^{(l)} = e^{-\frac{L-l}{\xi_\nabla}} \tilde{q}^{(L)}$$

where

$$\xi_\nabla = -\frac{1}{\ln(\chi_1) + \ln(1 + \lambda^2 / ((1-\lambda)^2 \sigma_w^2))}$$

Bibliography

- [1] L. F. C. Pessoa and P. Maragos, “Neural networks with hybrid morphological/rank/linear nodes: A unifying framework with applications to handwritten character recognition,” *Pattern Recognition*, vol. 33, no. 6, pp. 945–960, 2000. DOI: 10.1016/S0031-3203(99)00157-0.
- [2] J. L. Davidson and F. Hummer, “Morphology neural networks: An introduction with applications,” *Circuits, Systems, and Signal Processing*, vol. 12, no. 2, pp. 177–210, 1993. DOI: 10.1007/BF01189873.
- [3] L. F. C. Pessoa and P. Maragos, “Morphological/rank neural networks and their adaptive optimal design for image processing,” in *Proceedings of the 1996 IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, vol. 6, Atlanta, GA, USA, 1996, pp. 3398–3401. DOI: 10.1109/ICASSP.1996.550607.
- [4] S. S. Schoenholz, J. Gilmer, S. Ganguli, and J. Sohl-Dickstein, “Deep information propagation,” in *5th International Conference on Learning Representations (ICLR)*, 2017. [Online]. Available: <https://openreview.net/forum?id=H1W1UN9gg>.
- [5] W. S. McCulloch and W. Pitts, “A logical calculus of the ideas immanent in nervous activity,” *Bulletin of Mathematical Biophysics*, vol. 5, no. 4, pp. 115–133, 1943. DOI: 10.1007/BF02478259.
- [6] F. Rosenblatt, “The perceptron: A probabilistic model for information storage and organization in the brain,” *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958. DOI: 10.1037/h0042519.
- [7] M. Minsky and S. Papert, *Perceptrons: An Introduction to Computational Geometry*. Cambridge, MA, USA: MIT Press, 1969.
- [8] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, 1986. DOI: 10.1038/323533a0.
- [9] Y. LeCun et al., “Backpropagation applied to handwritten ZIP code recognition,” *Neural Computation*, vol. 1, no. 4, pp. 541–551, 1989. DOI: 10.1162/neco.1989.1.4.541.
- [10] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems 25 (NIPS)*, Curran Associates, Inc., 2012, pp. 1097–1105. [Online]. Available: <https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks>.
- [11] M. Telgarsky, “Benefits of depth in neural networks,” in *29th Annual Conference on Learning Theory (COLT)*, ser. Proceedings of Machine Learning Research, vol. 49, 2016, pp. 1517–1539. [Online]. Available: <https://proceedings.mlr.press/v49/telgarsky16.html>.
- [12] R. M. Neal, “Priors for infinite networks,” in *Bayesian Learning for Neural Networks* (Lecture Notes in Statistics), Lecture Notes in Statistics. New York, NY, USA: Springer, 1996, vol. 118, pp. 29–53. DOI: 10.1007/978-1-4612-0745-0_2.
- [13] A. Jacot, F. Gabriel, and C. Hongler, “Neural tangent kernel: Convergence and generalization in neural networks,” in *Advances in Neural Information Processing Systems 31 (NeurIPS)*, 2018, pp. 8571–8580. [Online]. Available: https://papers.nips.cc/paper_files/paper/2018/hash/5a4be1fa34e62bb8a6ec6b91d2462f5a-Abstract.html.
- [14] A. Jacot, “Implicit bias of large depth networks: A notion of rank for nonlinear functions,” in *11th International Conference on Learning Representations (ICLR)*, 2023. [Online]. Available: <https://openreview.net/forum?id=6iDHce-0B-a>.
- [15] G. X. Ritter, P. Sussner, and J. L. Diaz-de-Leon, “Morphological associative memories,” *IEEE Transactions on Neural Networks*, vol. 9, no. 2, pp. 281–293, 1998. DOI: 10.1109/72.661123.
- [16] P. Maragos and R. W. Schafer, “Morphological filters—part ii: Their relations to median, order-statistic, and stack filters,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 35, no. 8, pp. 1170–1184, 1987. DOI: 10.1109/TASSP.1987.1165254.

- [17] N. Dimitriadis and P. Maragos, “Advances in morphological neural networks: Training, pruning and enforcing shape constraints,” in *Proceedings of the 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2021, pp. 3825–3829. DOI: 10.1109/ICASSP39728.2021.9415123.
- [18] K. Fotopoulos and P. Maragos, *Training deep morphological neural networks as universal approximators*, 2025. arXiv: 2505.09710 [cs.LG]. [Online]. Available: <https://arxiv.org/abs/2505.09710>.
- [19] A. S. Lewis, “Nonsmooth analysis of eigenvalues,” *Mathematical Programming*, vol. 84, no. 1, pp. 1–24, 1999. DOI: 10.1007/s10107980004a.
- [20] F. H. Clarke, *Optimization and Nonsmooth Analysis*. New York, NY, USA: Wiley, 1983.
- [21] B. Poole, S. Lahiri, M. Raghu, J. Sohl-Dickstein, and S. Ganguli, “Exponential expressivity in deep neural networks through transient chaos,” in *Advances in Neural Information Processing Systems 29 (NIPS)*, 2016, pp. 3360–3368. [Online]. Available: <https://papers.nips.cc/paper/6322-exponential-expressivity-in-deep-neural-networks-through-transient-chaos>.
- [22] H. A. David and H. N. Nagaraja, *Order Statistics*, 3rd ed. Hoboken, NJ, USA: Wiley-Interscience, 2003.
- [23] P. Maragos, *Topics in Computer Vision and Machine Learning*. Kallipos, Open Academic Editions, 2025, Postgraduate textbook, ISBN: 978-618-228-346-2. DOI: 10.57713/kallipos-1097.
- [24] A. W. van der Vaart, *Asymptotic Statistics* (Cambridge Series in Statistical and Probabilistic Mathematics). Cambridge, UK: Cambridge University Press, 1998.
- [25] K. Fotopoulos, P. Maragos, and P. Misiakos, “TropNNC: Structured neural network compression using tropical geometry,” *Transactions on Machine Learning Research*, Jun. 2026, ISSN: 2835-8856. [Online]. Available: <https://openreview.net/forum?id=u7DRq1icmY>.